

基于权重共享的多用户拆分学习投毒攻击研究

作者姓名 _____ 吕硕

指导教师姓名、职称 _____ 肖阳 副教授

申请学位类别 _____ 工学硕士

学校代码 10701
分类号 TP309

学号 23151214183
密级 公开

西安电子科技大学

硕士学位论文

基于权重共享的多用户拆分学习投毒攻击研究

作者姓名：吕硕

一级学科：网络空间安全

二级学科（研究方向）：网络空间安全

学位类别：工学硕士

指导教师姓名、职称：肖阳 副教授

学院：网络与信息安全学院

提交日期：2026 年 5 月

Research on Weight-Sharing-Based Poisoning Attacks in Multi-Client Split Learning

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Cyber Security

By
Lyu Shuo
Supervisor: Xiao Yang Title: Associate Professor
May 2026

西安电子科技大学 学位论文独创性（或创新性）声明

秉承学校严谨的学风和优良的科学道德，本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同事对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文若有不实之处，本人承担一切法律责任。

本人签名：_____ 日 期：_____

西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权属于西安电子科技大学。学校有权保留送交论文的复印件，允许查阅、借阅论文；学校可以公布论文的全部或部分内容，允许采用影印、缩印或其它复制手段保存论文。同时本人保证，结合学位论文研究成果完成的论文、发明专利等成果，署各单位为西安电子科技大学。

保密的学位论文在____年解密后适用本授权书。

本人签名：_____ 导师签名：_____

日 期：_____ 日 期：_____

摘 要

随着数据隐私保护需求的提升，拆分学习（SL）作为一种适用于资源受限场景的分布式训练范式，能够通过模型切分实现原始数据不出域的联合建模。随着协同训练由两方扩展至多参与方场景，多客户端拆分学习（MCSL）逐渐成为重要研究方向。在 MCSL 中，多个客户端通常采用串行训练机制，并在训练过程中顺序传递共享权重。然而，这种顺序流动机制在降低端侧负担的同时也引入了新型安全风险。一旦恶意客户端篡改共享权重，异常扰动便可能沿传递链路不断扩散并破坏全局模型性能。现有拆分学习安全研究主要聚焦于端云交互过程中的隐私与标签泄露，而对多客户端场景下由权重共享传播引发的投毒风险关注不足，缺乏场景针对性的攻防建模。

针对上述问题，本文系统研究了多客户端拆分学习中的共享权重投毒攻击及其防御方法。首先，本文对 MCSL 中的串行训练与权重传递机制进行形式化建模，揭示了共享权重作为异常扰动传播载体的隐蔽性与级联破坏机理。在此基础上，本文提出了一种面向共享权重传播链路的投毒攻击方法 DASH-MSL。该方法首先利用 Fisher 信息矩阵等指标对共享权重进行参数敏感性分析，精准筛选出对模型性能最具影响力的关键参数位置；随后，在有限扰动预算下，通过构建最大化目标损失函数的优化问题，为关键参数定制可控的异常更新，使恶意扰动能够绕过常规数值隐蔽检测，并在后续客户端的串行训练中持续累积与级动放大。进一步地，针对串行训练缺乏横向统计冗余、传统鲁棒聚合方法失效的问题，本文设计了一种基于异常检测与历史权重恢复的防御机制。该机制通过对共享权重的时间上演化序列进行稳健统计分析（如中位数绝对偏差，MAD），动态识别参数的异常突变；一旦检测到投毒行为，立即启动历史权重恢复策略，对涉嫌受污染的参数实施修复或状态回滚，从而有效切断扰动在客户端队列中的扩散路径。

为验证所提方法的有效性，本文在标签共享（Label-sharing）与标签保护（Label-protected）两类典型拆分学习架构下，结合多种视觉与图数据任务开展了系统实验。实验结果表明，DASH-MSL 攻击在多种任务场景下均展现出显著且稳定的性能破坏能力，在复杂视觉任务中可使受害者模型准确率逼近随机分类水平；与现有的联邦学习迁移投毒方法（如 poisonFL、FedGhost、ScaleSign 等）相比，所提攻击具有更强的破坏烈度与级联效应。此外，实验分析证实，恶意客户端的队列位置、扰动比例及协同策略是影响攻击持续性的关键因素。最后，防御实验表明，本文设计的基于稳健统计的修复机制能够有效抑制权重污染，在不同模型结构下均表现出较好的适用性与可用性，为多客户端协同训练系统的安全部署提供了理论与方法支撑。

关键词：多客户端拆分学习、权重共享、投毒攻击、异常检测、参数敏感性

ABSTRACT

With the growing demand for data privacy protection, Split Learning (SL), as a distributed training paradigm tailored for resource-constrained scenarios, enables collaborative modeling while keeping raw data local by partitioning the model network. As collaborative training expands from two-party to multi-party environments, Multi-Client Split Learning (MCSL) has emerged as a crucial research direction. In MCSL, multiple clients typically adopt a sequential training mechanism, sequentially transferring shared weights across the client chain during the training process. However, this sequential propagation mechanism reduces the computational burden on edge devices but simultaneously introduces novel security risks. Once a malicious client tampers with the shared weights, abnormal perturbations can propagate along the transmission chain, continuously contaminating subsequent models and destroying global model performance. Existing security research on split learning primarily focuses on privacy leakage and label inversion during client-cloud interactions, leaving the poisoning risks induced by shared weight propagation in multi-client scenarios largely unexplored and lacking targeted threat modeling and defense mechanisms.

To address these issues, this thesis systematically investigates the shared-weight poisoning attack and its corresponding defense methods in multi-client split learning. First, we formalize the sequential training and weight propagation mechanisms in MCSL, revealing the concealment and cascade destruction principles of shared weights acting as a vector for anomaly propagation. On this basis, we propose DASH-MSL, a targeted poisoning attack designed against the shared-weight propagation chain. This method first performs parameter sensitivity analysis using the Fisher Information Matrix to precisely identify key parameter locations that exert the most critical impact on model performance. Subsequently, under a constrained perturbation budget, it formulates an optimization problem aimed at maximizing the objective loss function to synthesize controllable abnormal updates for these vital parameters. This allows the malicious perturbations to bypass conventional numerical anomaly detection and continuously accumulate and amplify during the sequential training of subsequent clients. Furthermore, since sequential training lacks horizontal statistical redundancy, rendering traditional robust aggregation protocols ineffective, this thesis designs a defense mechanism based on anomaly detection and historical weight recovery. By conducting robust statistical analysis (such as Median Absolute Deviation, MAD) on the temporal evolution sequence of

shared weights, the mechanism dynamically detects parameter mutations. Once a poisoning behavior is detected, a historical weight recovery strategy is immediately triggered to repair or roll back the suspected contaminated parameters, effectively cutting off the propagation path of perturbations along the client queue.

To validate the effectiveness of the proposed methodology, systematic experiments are conducted under two typical split learning architectures, namely label-sharing and label-protected, across various vision and graph learning tasks. The experimental results demonstrate that the DASH-MSL attack exhibits significant and stable destructive capabilities across diverse task scenarios, driving the accuracy of victim models close to that of random classification in complex vision tasks. Compared with existing federated learning transfer poisoning baselines (e.g., poisonFL, FedGhost, ScaleSign), the proposed attack demonstrates stronger destruction intensity and cascading effects. In addition, experimental analysis confirms that the malicious client's position in the queue, perturbation budget, and collaboration strategy serve as key factors influencing attack persistence. Finally, defense experiments indicate that our proposed robust-statistics-based recovery mechanism can effectively suppress weight contamination and exhibits strong adaptability and utility across different model architectures, providing theoretical and methodological support for the secure deployment of multi-client collaborative training systems.

Keywords: Multi-Client Split Learning; Weight Sharing; Poisoning Attack; Anomaly Detection; Parameter Sensitivity

插图索引

图 1.1	拆分学习三种经典架构示意图	2
图 1.2	RingSFL 示意图	3
图 2.1	多客户端场景下的拆分学习示意图	14
图 2.2	拆分学习中的攻击类型示意图	20
图 3.1	权重共享机制对多客户端拆分学习模型训练性能的影响	31
图 3.2	DASH-MSL 共享权重投毒攻击整体流程示意图	44
图 3.3	基于异常检测与历史权重恢复的防御机制示意图	50
图 4.1	CORA 与 CORA-ML 数据集下不同队列位置的攻击效果	67
图 4.2	SVHN 与 CIFAR-10 数据集下不同队列位置的攻击效果	68
图 4.3	MNIST 与 FMNIST 数据集下不同扰动比例的攻击效果	70
图 4.4	SVHN 与 CIFAR-10 数据集下不同扰动比例的攻击效果	71
图 4.5	MNIST 与 FMNIST 数据集下不同攻击策略的攻击效果	74
图 4.6	MNIST 与 FMNIST 数据集下组合攻击策略的攻击效果	75

表格索引

表 3.1	不同参数重要性评估方法的计算复杂度与攻击可利用性对比	36
表 4.1	实验环境硬件信息	55
表 4.2	实验环境软件信息	56
表 4.3	标签共享 SL 架构下投毒攻击对系统分类性能的影响（分类准确率，%）	62
表 4.4	标签保护 SL 架构下投毒攻击对系统分类性能的影响（分类准确率，%）	63
表 4.5	DASH-MSL 与迁移后的联邦投毒攻击的性能对比（分类准确率，%）	65
表 4.6	防御机制对投毒攻击的缓解效果验证（分类准确率，%）	76

符号对照表

符号	符号名称
$\mathbf{w}$	全局共享权重向量
$\mathbf{w}'$	投毒后的共享权重
S	服务器
C_i	第 i 个客户端
C_m	恶意客户端
N	客户端总数
T	训练轮次数
D_i	客户端 i 的本地数据集
$\mathcal{M}$	参数重要性掩码
β	攻击强度参数
α	扰动比例系数
$f_{\text{perturb}}(\cdot)$	扰动函数
$\Delta \mathbf{w}$	权重扰动向量
$\mathcal{L}$	损失函数
$\nabla \mathcal{L}$	损失函数梯度
$F(\cdot)$	Fisher 信息矩阵
p	恶意客户端在队列中的位置
$\mathcal{Q}$	客户端训练队列
r	当前训练轮次索引
$\mathbf{g}$	梯度向量
θ	模型参数
θ'	投毒后的模型参数
μ	权重更新均值
σ	权重更新标准差
MAD	中位数绝对偏差
$\mathcal{A}$	异常参数集合
$\mathcal{R}$	历史权重恢复操作

缩略语对照表

缩略语	英文全称	中文对照
SL	Split Learning	拆分学习
MCSL	Multi-Client Split Learning	多客户端拆分学习
FL	Federated Learning	联邦学习
MAD	Median Absolute Deviation	中位数绝对偏差
CNN	Convolutional Neural Network	卷积神经网络
GNN	Graph Neural Network	图神经网络
DNN	Deep Neural Network	深度神经网络
SGD	Stochastic Gradient Descent	随机梯度下降
ReLU	Rectified Linear Unit	线性整流函数
U-shape SL	U-shaped Split Learning	U 形拆分学习
Vanilla SL	Vanilla Split Learning	标准拆分学习
Label-sharing SL	Label-sharing Split Learning	标签共享拆分学习
Label-protected SL	Label-protected Split Learning	标签保护拆分学习
Fisher	Fisher Information Matrix	Fisher 信息矩阵
PoisonFL	Poisoning Attack in Federated Learning	联邦学习投毒攻击

目 录

摘要.....	I
ABSTRACT.....	III
插图索引.....	V
表格索引.....	VII
符号对照表	IX
缩略语对照表	XI
第一章 绪论	1
1.1 选题背景与研究意义.....	1
1.2 国内外研究现状	4
1.2.1 拆分学习与多客户端拆分学习研究现状	4
1.2.2 拆分学习的安全威胁研究现状	6
1.3 研究内容.....	8
1.4 章节安排.....	10
第二章 相关理论与技术研究	11
2.1 分布式机器学习基础.....	11
2.1.1 联邦学习基本原理	11
2.1.2 拆分学习基本原理	12
2.1.3 多客户端拆分学习机制	13
2.2 深度神经网络与模型训练机制	15
2.2.1 神经网络基本结构	15
2.2.2 前向传播与反向传播机制	16
2.2.3 模型参数更新与敏感性分析	17
2.3 拆分学习中的攻击算法	18
2.3.1 基于恶意服务器主体的攻击方法	20
2.3.2 基于恶意客户端主体的攻击方法	22
2.3.3 现有攻击算法的局限性与多客户端拆分学习中的潜在风险	24
2.4 本章小结.....	26
第三章 多客户端拆分学习下的权重投毒攻击与防御方案	29
3.1 系统模型与威胁建模.....	29
3.1.1 串行训练与权重共享机制	29
3.1.2 权重共享的必要性分析	30

3.1.3	攻击者能力假设与攻击目标	31
3.2	基于参数敏感性的权重评估方法	32
3.2.1	理论分析	33
3.2.2	参数重要性度量指标	33
3.2.3	关键权重的构建与筛选	37
3.3	DASH-MSL 投毒攻击方案设计与算法实现	39
3.3.1	权重扰动构造与攻击向量设计	39
3.3.2	攻击目标函数的构建与优化	40
3.3.3	DASH-MSL 攻击流程与算法化描述	43
3.4	防御机制	48
3.4.1	设计动因	48
3.4.2	基于异常检测的关键权重识别机制	49
3.4.3	基于历史权重恢复的传播抑制机制	52
3.5	本章小结	53
第四章	实验结果与分析	55
4.1	实验环境	55
4.2	实验整体内容与评估指标	55
4.3	实验准备	57
4.3.1	系统与参数设置	57
4.3.2	数据集	57
4.3.3	受害者模型	58
4.3.4	对比攻击迁移	59
4.4	DASH-MSL 串行投毒攻击的有效性验证	61
4.4.1	标签共享与标签保护架构下的攻击表现	61
4.4.2	与传统联邦学习投毒方法的对比分析	64
4.5	DASH-MSL 攻击持续性与关键影响因素分析	66
4.5.1	恶意客户端队列位置对攻击效果的影响	66
4.5.2	扰动比例对攻击效果的影响	69
4.5.3	不同攻击策略对攻击效果的影响	72
4.6	防御实验	76
4.7	本章小结	77
第五章	总结与展望	79
5.1	工作总结	79
5.2	未来展望	80

目录

参考文献.....	83
致谢.....	89
作者简介.....	91

第一章 绪论

1.1 选题背景与研究意义

近年来，深度学习技术在图像识别、自然语言处理、医学影像分析、金融风控与网络安全等领域取得了显著进展，模型训练范式也逐渐由“单机构集中训练”向“多参与方协同训练”演化。在理想条件下，集中式训练能够通过汇聚多源数据扩大样本规模、增强数据多样性，从而提升模型的泛化能力与鲁棒性。然而在实际应用中，高价值数据通常分散存储于不同机构或终端设备侧，例如医院、银行、政务部门、工业企业以及移动端、物联网节点和车联网节点等。这些数据往往受到隐私法规、伦理审查、行业合规要求以及商业竞争关系的约束，难以在不暴露敏感信息的前提下实现集中共享。由此，“数据难以汇聚”与“模型性能依赖多源数据协同”的矛盾长期存在，并推动了隐私保护协同学习（privacy-preserving collaborative learning）的持续发展。

以多中心医疗场景为例^{[1][2]}，不同医院通常掌握不同人群、不同设备或不同病种条件下采集的数据。若仅依赖单中心数据训练模型，往往容易受到样本规模不足和数据分布偏移的影响，导致模型在跨机构部署时性能下降；而多中心联合训练则有助于在不突破数据管理边界的前提下提升模型的覆盖能力与泛化性能。类似的需求同样存在于金融风控、反欺诈以及工业互联网等场景中。不同机构所掌握的交易行为、风险特征、传感数据和质量信息往往具有显著互补性，协作建模有助于提升异常检测能力、减轻数据偏置影响，并增强模型在复杂环境下的适应性。然而，这些场景中的原始数据通常具有高度敏感性，集中式共享不仅面临较高的隐私泄露风险，也受到带宽成本、数据主权和算力异构等工程因素的制约^{[3][4][5]}。因此，如何在满足隐私保护要求的前提下实现多参与方协同训练，已成为分布式智能系统研究与落地过程中的关键问题。

在隐私保护协同学习的研究体系中，联邦学习（Federated Learning, FL）是最具代表性的分布式训练范式之一。FL 通过要求各参与方在本地训练完整模型，并将梯度或模型参数上传至中心服务器进行聚合，从而在一定程度上实现了“数据不出域”的协作训练目标。经过多年发展，FL 已形成较为成熟的理论基础与工程框架，并在跨终端、跨机构协同建模中得到广泛研究。然而，随着模型规模持续增大以及终端异构性不断增强，FL 也逐渐暴露出新的局限。一方面，客户端需要维护并训练完整模型，这会给资源受限终端带来较大的计算和存储压力；另一方面，多轮参数交换与集中聚合会引入较高的通信成本，并在弱网络环境下进一步放大同步等待与训练时延问题^[6]。特别是在边缘计算、移动终端和物联网环境中，设备通常受到算力、存储、

电量和链路质量的多重约束，使得“本地训练完整模型”在很多场景下难以满足实际部署需求^{[6][3]}。因此，在保证原始数据不离开本地的同时，进一步降低端侧训练负担、提升分布式训练可部署性，成为隐私保护学习范式继续发展的重要方向。




图 1.1 拆分学习三种经典架构示意图

拆分学习 (Split Learning, SL) 为解决上述问题提供了另一种可行思路。SL 的基本思想是在某一切分层 (cut layer) 处将神经网络划分为客户端侧子模型和服务端侧子模型：客户端负责执行前若干层的前向计算，并将中间激活发送至服务器；服务器完成后续计算并基于标签求取损失，再将相应梯度回传至客户端以继续反向传播。通过这种“模型切分 + 激活/梯度交互”的方式，SL 能够将深层模型的大部分计算与存储压力卸载到服务器侧，从而显著降低客户端负担，并使资源受限数据拥有方具备参与复杂模型训练的能力^[7]。与 FL 相比，SL 在系统组织方式上具有明显差异：FL 主要交换模型参数或梯度，客户端需维护完整模型；SL 则主要交换中间激活与梯度，客户端仅保留部分模型，但训练过程中需要更频繁的交互。这一机制使 SL 在医疗协作、边缘智能和物联网等场景中表现出较强的应用潜力。例如，在医疗协作训练中，客户端仅需保留浅层特征提取模块即可参与较深模型的联合训练；在无线边缘环境中，SL 也更容易与任务卸载、资源调度和链路管理机制结合，从而提高异构环境下协同训练的可行性^{[8][5][9][10]}。因此，SL 已逐渐成为联邦学习之外的重要隐私保护协同训练范式。

随着协同训练需求由“两方协作”进一步扩展到“多方共同参与”，拆分学习也逐渐发展出多客户端拆分学习 (Multi-Client Split Learning, MCSL) 这一重要设置。典型的 MCSL 场景中，多个客户端通常按照预定队列依次参与训练，服务器侧子模型在训练过程中持续保留并累积来自不同客户端的数据特征；与此同时，为了保证训练过程的连续性与一致性，客户端侧子模型或其关键权重往往会在客户端之间共享或顺序传递，使后续客户端能够在前序客户端训练结果的基础上继续更新同一套共享参数^{[11][12]}。与 FL 的“并行本地更新 + 集中聚合”机制不同，MCSL 更突出的结构特征在于“串行训练”和“共享权重的顺序流动”。这一机制降低了对多参与方同时在线的要求，也使资源受限节点能够以较低负担参与协作，因此具有较强的现实部

署价值。围绕这一方向，已有研究进一步探索了将 SL 与 FL 融合的训练模式，以及面向客户端异构性和非独立同分布数据条件的自适应优化策略^{[13][14]}。这些工作表明，多客户端拆分学习不仅是拆分学习的重要扩展形式，也是面向真实复杂场景开展协同训练的一条具有应用前景的技术路线。




图 1.2 RingSFL 示意图

然而，协同训练机制在提升隐私保护能力与部署灵活性的同时，也会引入新的安全风险^{[15][16]}。现有拆分学习安全研究已经表明，仅仅保证原始数据不出域，并不意味着训练过程本身天然安全。在 SL 中，客户端与服务器之间需要持续交换中间激活、梯度以及相关训练信息，这些交互内容可能被攻击者利用，用于恢复原始输入^[17]、推断标签信息^{[18][19][20][21]}、窃取模型知识^[18]，甚至破坏模型训练过程^{[18][22][23]}。此外，后门攻击和投毒攻击等完整性威胁也已在拆分学习中展现出较强的破坏性，说明拆分学习系统不仅面临隐私泄露风险，也面临训练可用性与可信性受损的问题^{[24][25]}。

值得注意的是，现有拆分学习安全研究大多围绕单客户端或两方交互场景展开，攻击面主要集中在客户端与服务器之间的中间信息交互过程。而在多客户端拆分学习中，系统的训练组织方式和信息流动路径发生了明显变化，共享权重在客户端之间持续传递，使其不仅是协同训练得以实现的核心机制，也可能成为异常扰动跨客户端传播的关键载体。一旦恶意客户端在训练过程中对共享权重实施篡改，这种异常更新便可能沿客户端队列向后传播，并在后续训练中不断累积和放大，最终对系统整体模型性能造成级联影响。与此同时，由于 MCSL 缺少 FL 中常见的“同轮并行更新 + 聚合统计”过程，许多依赖横向统计冗余的鲁棒聚合或异常检测方法也难以直接迁移到该场景^{[26][12]}。因此，相较于传统 FL 和单客户端 SL，MCSL 在安全威胁形态上具有更强的传播性、隐蔽性和系统性，其攻防问题值得单独开展研究。

从应用角度看，这一问题具有明确的现实意义。在医疗、金融、政务和关键基础设施等高敏感领域，协同训练系统不仅需要具备较高模型性能，更需要满足训练过程可信、结果可靠与部署可控等要求。如果多客户端拆分学习过程遭受投毒攻击，攻击影响可能通过共享权重在多个诚实客户端之间扩散，进而导致全局模型出现系统性性能退化，甚至在关键任务中产生隐蔽且稳定的错误行为。这类风险一旦发生，不仅可能削弱协同训练的应用价值，还可能对实际业务决策与系统安全造成严重影响。因此，围绕多客户端拆分学习中的共享权重传播机制，研究其潜在攻击面、分析攻击传播机理，并进一步设计具有场景针对性的防御方法，具有重要的理论价值与工程意义。

基于上述背景，本文聚焦多客户端拆分学习中的共享权重安全问题，围绕共享权重在客户端队列中的顺序传播机制，研究其可能引发的投毒攻击风险及相应防御思路。本文认为，MCSL 中“串行训练 + 权重共享”的结构特征是区别于联邦学习和单客户端拆分学习的关键所在，也是现有攻防方法难以直接迁移的重要原因。为此，本文从攻击与防御两个角度出发，一方面研究恶意客户端如何利用共享权重传播链路构造有效扰动并实现跨客户端扩散，另一方面研究在缺乏聚合统计冗余的条件下如何对异常权重更新进行检测与修复。通过对上述问题的系统研究，本文旨在为多客户端拆分学习在多中心协作、边缘智能等场景中的安全应用提供理论依据与方法支撑。

1.2 国内外研究现状

1.2.1 拆分学习与多客户端拆分学习研究现状

拆分学习作为一种面向隐私保护协同训练的分布式学习范式，其研究演进大致经历了“基本范式提出—应用场景验证—系统优化扩展—多客户端与融合式框架发展”几个阶段。总体来看，相关研究始终围绕两个核心目标展开：一是在不共享原始数据的条件下实现多参与方协同训练，二是在资源受限、终端异构和网络条件复杂的环境中提升训练过程的可部署性与可扩展性^[7]。因此，拆分学习的发展不仅体现了分布式机器学习在隐私保护方向上的持续推进，也反映了其在真实场景部署需求驱动下的不断演化。

从基本范式的提出看，早期研究主要聚焦于如何通过模型切分实现端云协同训练。Gupta 等人在 2018 年围绕多主体场景下的分布式深度网络训练进行了初步探索，为后续拆分学习研究提供了早期思路^[27]。同年，Vepakomma 等人提出面向医疗场景的 split learning 框架（常被称为 SplitNN），较为系统地给出了客户端侧子模型与服务器侧子模型协同训练的完整流程：客户端执行前若干层前向传播并上传中间激活，服务器完成后续计算并将梯度回传客户端，从而在不共享原始患者数据的前提下实现

联合训练^[1]。该工作奠定了拆分学习的基本机制，也明确了其与联邦学习的差异：联邦学习要求客户端训练完整模型，而拆分学习通过模型切分将更多计算压力转移到服务器侧，使资源受限节点也能够参与较深模型的协同训练。

在基本范式确立之后，研究者开始关注拆分学习在具体场景中的适用性及其与其他分布式训练范式之间的差异。Poirot 等人在 2019 年将拆分学习应用于医疗多中心协作训练，通过眼底图像分类和胸片多标签分类等任务验证了其在“数据不出域”约束下的协同建模能力^[2]。同样在 2019 年，Singh 等人从通信效率角度对比了拆分学习与联邦学习，指出二者在不同网络条件和资源约束下具有不同的适用边界：联邦学习主要交换模型参数或梯度，客户端需维护完整模型；拆分学习则主要交换中间激活与梯度，客户端仅保留部分模型，但对训练交互频率和链路稳定性更为敏感^[6]。这一阶段的研究使拆分学习不再仅被视为“是否能够实现协同训练”的技术方案，而开始被放入更具体的系统约束条件下进行评估和比较。

随着应用环境由多中心协作进一步扩展到无线网络、边缘计算和物联网等复杂场景，拆分学习研究的重点又逐渐转向系统层面的优化问题。已有工作围绕资源自适应调度、交互式通信开销控制、无线环境下的并行化设计以及边缘算力协同等方向展开研究，以缓解拆分学习在高频交互条件下所带来的训练时延和系统负担。例如，Samikwa 提出的 ARES 框架强调根据终端设备的算力和网络状态动态调整训练流程，以提升异构环境下的部署可行性^[10]；面向无线环境的相关研究则进一步从并行化设计和资源管理角度优化训练与通信流程，以提升整体吞吐和系统稳定性^{[11][9]}；在 6G 边缘智能场景下，研究者又将拆分学习与任务卸载、链路调度以及无线资源分配等问题结合起来，强调需要从系统层面对模型切分与资源分配进行联合优化^[5]。这些工作表明，拆分学习在工程上具有较强吸引力，但其部署优势往往依赖于针对具体系统条件所进行的协同优化。

在此基础上，拆分学习进一步发展出多客户端拆分学习这一重要研究方向。与传统单客户端拆分学习主要关注客户端与服务器之间的两方协同不同，多客户端拆分学习面向多个数据拥有方共同参与训练的场景，通常采用串行训练协议：多个客户端按照预定顺序依次参与训练，服务器侧子模型在训练过程中持续保留来自不同客户端的特征表征；同时，为保证训练连续性与参数一致性，客户端侧子模型或其关键权重往往在客户端之间共享或顺序传递，使后续客户端能够在前序客户端训练结果的基础上继续更新同一套共享参数^{[11][12]}。相较于联邦学习中“并行本地训练 + 服务器聚合”的组织方式，多客户端拆分学习更突出的特点在于串行训练过程及共享权重在客户端队列中的顺序流动。该机制降低了对全局同步在线的依赖，使其更适用于参与方上线时间不一致、网络条件波动较大或节点资源受限的实际环境；但与此同时，这种顺序训练机制也使模型收敛行为更容易受到数据异质性、客户端顺序和参数传

递路径的影响。

除纯粹的串行多客户端设置外,近年来研究者还提出了多种拆分学习与联邦学习的融合式框架,以在端侧负担、通信开销和系统同步成本之间取得新的平衡。例如,Abedi 和 Khan 提出的 FedSL 将联邦学习与拆分学习结合,并扩展到分布式顺序数据和循环神经网络场景,表明融合式框架可以适配更复杂的数据组织形式^[28]。Thapa 等人提出的 SplitFed 则尝试将拆分训练与服务器聚合机制结合,使多个客户端在拆分学习框架下并行参与训练,并通过聚合策略提升训练效率和系统可扩展性^{[13][28]}。此后,针对客户端异构性和非独立同分布数据条件下的训练不稳定问题, RingSFL 等工作进一步通过调整参与方交互结构来提升训练的鲁棒性与公平性^[14]。此外,还有研究从隐私机制角度讨论了客户端侧本地权重共享所带来的潜在风险,并提出削弱或取消本地权重共享的训练策略,以增强多客户端场景下的隐私保护能力^[12]。这些研究共同说明,多客户端拆分学习已不再是对传统拆分学习的简单扩展,而是逐步形成了兼具系统复杂性与应用价值的重要分支。

总体而言,现有拆分学习研究已经从早期的机制提出和应用验证,发展到涵盖系统优化、多客户端扩展以及与联邦学习融合的较完整研究体系。相关工作一方面不断强化拆分学习在医疗、边缘计算和物联网等场景中的现实价值,另一方面也揭示出多客户端设置下串行训练和共享权重机制对训练过程的深刻影响。尤其是在多客户端拆分学习场景中,共享权重的顺序传递不仅改变了模型训练的组织方式,也改变了系统中的信息流形态和参数演化路径。现有研究更多关注的是训练效率、异构适配和框架设计,而对于共享权重在多客户端场景中可能带来的安全风险,尤其是其作为异常扰动传播载体的潜在问题,仍缺乏充分研究。这也为后续围绕多客户端拆分学习安全性的分析与建模提供了研究空间。

1.2.2 拆分学习的安全威胁研究现状

随着拆分学习研究不断深入,学术界逐渐认识到,“数据不出域”并不等同于“训练过程天然安全”。尽管拆分学习通过模型切分避免了原始数据的直接共享,但客户端与服务器之间仍需持续交换中间激活、梯度以及相关训练信息,这些交互内容可能为攻击者提供可利用的线索。基于此,拆分学习安全研究逐步从早期的隐私泄露可行性验证,发展为围绕不同威胁模型和攻击目标展开的系统性研究,主要涉及输入推断与特征重构、标签泄露与标签推断、投毒与后门攻击、模型窃取与伪客户端攻击等多个方向^{[29][7]}。总体来看,现有研究较为充分地揭示了拆分学习在交互式训练条件下面临的隐私性与完整性风险,也为后续的安全防护研究奠定了基础。

在隐私泄露方向,现有研究首先关注的是服务器侧在不直接接触原始输入的条件下,是否仍能够通过交互信息恢复客户端隐私。Pasquini 等人于 2021 年提出的相

相关工作表明,即便服务器无法直接访问原始数据,也可以利用中间激活和训练过程动态实施推断攻击,从而恢复客户端侧输入或敏感属性信息^[15]。这一研究的重要意义在于,它将拆分学习的隐私问题从“是否共享原始数据”扩展为“中间交互信息是否足以泄露私有信息”。在此基础上,研究者又围绕中间激活的可逆性和中间表征的语义信息提出了多种重构与反演攻击方法。例如,Zhang 等人提出特征导向的重构攻击,说明攻击者可以利用中间特征的结构信息和任务相关性恢复输入的关键语义内容^[17]; EXACT 等工作则尝试从更全面的攻击目标和可观测信息出发,对拆分学习的攻击面进行系统刻画^[30]。这些研究共同表明,在服务器具备观察中间激活和梯度的前提下,拆分学习的隐私泄露风险是客观存在的,并且会受到模型结构、切分位置和训练策略等因素的显著影响。

在标签安全方面,相关研究进一步揭示了“两方拆分学习”中标签信息可能通过交互过程被间接恢复的风险。由于早期拆分学习通常默认标签由服务器侧持有或可由服务器侧参与损失计算,标签是否泄露一度未受到充分关注。然而,在很多实际场景中,标签本身同样具有较高敏感性,因此研究者开始系统讨论标签是否会通过中间激活、梯度结构或训练动态暴露给攻击者。He 等人的研究指出,在两方拆分学习设置下,即便标签并未显式共享,服务器仍可能通过交互信息推断标签,从而说明“标签不上传”并不必然意味着“标签安全”^[23]。随后,Fu 等人从梯度与优化过程出发研究了标签推断攻击的可行性,Yu 等人进一步提出在线标签推断攻击,说明攻击者甚至可以在训练过程中实时推断样本标签^{[21][19]}。此外,基于聚类分析的标签推断、面向回归任务的标签泄露研究也进一步扩展了该方向的适用范围^{[20][31]}。这一系列工作表明,标签泄露已经成为拆分学习安全研究中的重要问题之一。

除隐私泄露外,近年来研究者也开始将注意力转向拆分学习的完整性安全问题,即攻击者能否通过干扰训练过程破坏模型性能或植入后门行为。与输入重构和标签推断不同,投毒或后门攻击的目标通常不是恢复隐私信息,而是操控模型训练结果,使模型在正常样本上保持较高性能的同时,在特定触发条件下产生攻击者预期的错误输出。由于这类攻击往往具有较强隐蔽性,其危害在实际部署中更具破坏性。围绕这一问题,已有研究从不同攻击者能力假设出发验证了拆分学习中投毒与后门攻击的可行性。例如,面向拆分学习的慢性投毒与持续性后门攻击表明,攻击者可以在多轮交互过程中逐步注入恶意信号,使其随训练过程累积并嵌入模型参数,从而在无明显破坏训练表现行为的情况下形成稳定后门^[24]。此外,服务器侧后门攻击研究也进一步指出,若服务器不可信,则其凭借对模型后半部分和损失计算过程的控制能力,同样可以在训练过程中注入恶意行为^[25]。针对这类完整性威胁,已有工作也开始探索训练劫持检测与防御策略,例如 SplitGuard 从训练过程异常检测角度出发,为拆分学习完整性保护提供了初步思路^[32]。

除了上述典型方向之外,拆分学习的攻击面还在不断扩展。部分研究表明,攻击者即使不访问真实训练数据,也可能通过构造性优化过程对拆分学习实施模型反演、模型窃取或标签推断,从而形成数据无关攻击路线^[18]。另一些研究则提出伪客户端攻击,说明攻击者可以通过伪装为合法客户端参与训练或协议交互,从而实现模型功能窃取或数据窃取^[33]。此外,在引入差分隐私机制的拆分学习背景下,也有研究指出攻击者仍可能借助特征空间结构实施劫持或绕过隐私保护^[34]。这些工作说明,拆分学习的安全风险并不局限于单一攻击目标,而是涉及隐私性、完整性、协议可信性和参与者身份可信性等多个层面。

值得注意的是,尽管现有研究已经较为系统地揭示了拆分学习中的多类安全威胁,但其研究对象大多仍集中于单客户端拆分学习或两方拆分学习场景,分析重点主要围绕客户端与服务器之间的交互过程展开,即考察中间激活、梯度、标签或服务器控制权所带来的攻击面。相比之下,对于多客户端拆分学习场景下共享权重在客户端之间持续传递所引发的传播式攻击风险,现有工作关注仍相对不足。尤其是在串行训练机制下,共享权重不仅是参数更新的载体,也可能成为异常扰动在多个客户端之间扩散的传播通道;同时,由于该场景缺乏联邦学习中常见的并行聚合冗余,许多现有防御方法也难以直接迁移^{[12][26]}。因此,从多客户端拆分学习特有的训练组织方式和参数传播路径出发,专门研究共享权重上的投毒攻击及其防御机制,具有明确的研究必要性。

综上所述,现有拆分学习安全研究已经形成了较为丰富的攻击谱系,并从不同角度揭示了其在交互式训练过程中的隐私泄露风险与完整性威胁。然而,已有工作主要基于单客户端或两方交互场景展开,对多客户端拆分学习中共享权重顺序传递所带来的系统级传播风险尚缺乏专门建模与深入分析。基于这一不足,本文将聚焦多客户端场景下共享权重的传播特性,研究异常扰动如何沿权重传递链路扩散,并进一步讨论相应的检测与修复方法。

1.3 研究内容

针对多客户端拆分学习场景下共享权重在客户端之间顺序传递所带来的新型安全风险,本文围绕共享权重投毒攻击问题展开系统研究。与现有拆分学习安全研究主要关注客户端与服务器之间中间激活、梯度或标签信息泄露不同,本文将研究重点放在多客户端拆分学习特有的“串行训练—权重共享—持续传播”机制上,分析恶意客户端如何借助共享权重这一跨客户端传播载体实施投毒攻击,并进一步研究在缺乏联邦学习式聚合冗余的条件下,如何对异常权重更新进行识别与修复,从而抑制攻击影响在训练链路中的持续扩散。围绕这一目标,本文的主要研究内容如下。

首先,本文针对多客户端拆分学习的系统运行机制进行分析与建模,明确共享权

重在串行训练协议中的传播方式及其对系统安全性的影响。本文从系统模型与威胁建模出发,对多客户端拆分学习中的客户端顺序训练过程、共享权重传递关系以及恶意客户端的攻击能力进行形式化描述,揭示共享权重不仅是实现多客户端协同训练的重要基础,同时也可能成为攻击传播的关键通道。在此基础上,本文进一步分析多客户端拆分学习与传统联邦学习、单客户端拆分学习在训练组织方式和安全威胁面上的差异,为后续攻击方法设计与防御机制构建奠定基础。

其次,本文提出一种面向共享权重传播链路的投毒攻击方法 DASH-MSL,用于研究恶意客户端在多客户端拆分学习环境下对系统整体性能的破坏能力。该方法结合参数敏感性分析思想,从共享权重中筛选对模型性能更为关键的参数位置,并在有限扰动预算下对其注入可控异常更新,以提高攻击的有效性与隐蔽性。围绕该攻击方法,本文进一步研究了权重扰动的构造方式、攻击目标函数的建立以及攻击强度的优化过程,使所设计的投毒扰动能够在共享权重的顺序传递过程中不断传播并放大,最终对后续客户端训练和全局模型性能产生持续影响。通过这一过程,本文实现了从攻击机理分析到攻击算法设计的完整构建。

再次,针对所提出攻击在多客户端拆分学习中的传播特性,本文设计了一种基于异常检测与历史权重恢复的防御机制。考虑到多客户端拆分学习采用串行训练方式,缺乏并行聚合场景中可用于异常识别的横向统计冗余,本文从共享权重的时间演化序列出发,引入关键权重识别与稳健异常检测思想,对共享权重更新过程中的异常变化进行识别,并结合历史权重恢复策略对异常参数进行修复或回滚,以降低投毒扰动在客户端队列中的进一步扩散风险。该防御方法面向多客户端拆分学习的顺序训练特点进行设计,具有较强的场景针对性。

最后,本文通过系统实验对所提出攻击与防御方法进行全面验证与分析。实验部分分别在两类典型拆分学习架构、多个代表性数据集以及不同模型配置下展开,重点评估所提出攻击对系统性能的破坏效果,并进一步分析恶意客户端队列位置、扰动比例以及不同攻击策略对攻击效果的影响。在此基础上,本文将 DASH-MSL 与迁移到该场景的现有投毒方法进行对比,验证所提方法在攻击强度与稳定性方面的优势。同时,本文还通过防御实验评估所设计防御机制对攻击影响的缓解能力,从实验层面对所提出方法的有效性、适用性与实用价值进行了验证。

综上,本文围绕多客户端拆分学习中的共享权重传播机制,系统开展了攻击建模、攻击设计、防御构建与实验验证等研究工作,形成了一套面向该场景的共享权重投毒攻击与防御分析框架,为理解多客户端拆分学习中的新型安全威胁及其防护方法提供了有针对性的研究基础。

1.4 章节安排

本文共分为五章，各章节内容安排如下：

第一章为绪论，介绍本文的研究背景、研究意义、国内外研究现状以及研究内容。

第二章介绍多客户端拆分学习相关基础知识，包括拆分学习的基本原理、多客户端拆分学习架构及相关安全威胁模型。

第三章提出面向共享权重传播链路的投毒攻击方法 DASH-MSL，并介绍攻击模型、关键参数筛选方法以及扰动构造策略。

第四章对所提出方法进行实验验证与分析，包括不同数据集、模型结构及攻击配置下的攻击效果分析，并对防御机制的有效性进行验证。

第五章对全文工作进行总结，并对未来研究方向进行展望。

第二章 相关理论与技术研究

2.1 分布式机器学习基础

随着大数据技术的快速发展以及人工智能应用场景的不断扩展，机器学习模型对数据规模与多样性的依赖日益增强。然而，在医疗、金融、政务等实际场景中，数据往往分散在不同机构或终端设备中，受限于隐私保护法规、商业利益以及安全策略等因素，原始数据难以集中存储与统一处理。传统集中式机器学习范式在此背景下面临显著挑战：一方面，集中采集与存储数据容易引发隐私泄露风险；另一方面，跨机构数据共享的合规成本与协调成本较高，严重制约了模型训练效率与效果。

为解决上述问题，分布式机器学习逐渐成为学术界与工业界关注的重点方向。该方法通过在多个参与方之间协同训练模型，在不直接交换原始数据的前提下实现模型参数的优化，从而在一定程度上兼顾数据隐私保护与模型性能需求^{[6][7]}。根据模型部署方式与训练机制的不同，分布式机器学习可以划分为多种实现形式，其中联邦学习与拆分学习是近年来最具代表性的两种框架。二者均以“数据不出本地”为核心设计原则，但在模型切分方式、通信模式以及参数更新机制等方面存在本质差异^{[6][7]}。本节将系统介绍联邦学习、拆分学习以及多客户端拆分学习的基本原理与训练流程，为后续系统建模与攻击分析奠定理论基础。

2.1.1 联邦学习基本原理

联邦学习是一种典型的隐私保护型分布式机器学习框架，其目标是在不集中原始数据的前提下，通过多方协同的方式训练共享模型^[6]。设系统包含 K 个客户端 $\{C_k\}_{k=1}^K$ ，每个客户端 C_k 持有本地数据集 $\mathcal{D}_k$ ，中央服务器维护全局模型参数 w 。联邦学习的核心优化目标可表示为：

$$\min_w F(w) = \sum_{k=1}^K \frac{|\mathcal{D}_k|}{|\mathcal{D}|} F_k(w), \quad (2-1)$$

其中 $F_k(w)$ 表示客户端 C_k 上的本地损失函数， $\mathcal{D} = \bigcup_{k=1}^K \mathcal{D}_k$ 表示全体数据集。

在典型的联邦学习训练流程中，系统以轮次（round）为单位进行迭代。第 t 轮训练开始时，服务器将当前全局模型参数 $w^{(t)}$ 下发至各客户端；客户端基于本地数据对模型进行若干步梯度下降更新，得到本地模型参数 $w_k^{(t+1)}$ ；随后，客户端将更新后的参数或梯度信息上传至服务器。服务器对来自不同客户端的更新结果进行聚合，生成新的全局模型参数 $w^{(t+1)}$ ，并进入下一轮训练。

在众多联邦学习算法中，FedAvg 算法是最具代表性的基础方法之一。其聚合过

程可表示为：

$$w^{(t+1)} = \sum_{k=1}^K \frac{|\mathcal{D}_k|}{|\mathcal{D}|} w_k^{(t+1)}, \quad (2-2)$$

即服务器对各客户端本地模型参数进行加权平均，权重与各客户端数据规模成正比。由于结构简单、易于实现，FedAvg 已成为联邦学习领域广泛采用的默认优化策略。在此基础上，研究者还提出了多种改进算法，以应对客户端异构性、通信效率以及非独立同分布（Non-IID）数据等问题。

从优势上看，联邦学习通过将模型训练过程分散至各客户端，有效避免了原始数据的集中存储与传输，在一定程度上实现了“数据可用不可见”^[6]。然而，该框架仍存在明显局限。一方面，客户端需要具备完整模型结构及相应的计算能力，对于算力受限设备不够友好；另一方面，联邦学习依赖频繁的模型参数或梯度通信，当客户端数量较多或模型规模较大时，通信开销将成为系统瓶颈^{[6][3]}。此外，在高度异构的数据分布场景下，各客户端本地目标函数 $F_k(w)$ 差异显著，容易导致模型收敛速度下降甚至震荡，从而影响最终性能。

正是由于上述限制，研究者开始探索更加轻量化、更加适合资源受限场景的分布式学习范式，拆分学习由此应运而生。

2.1.2 拆分学习基本原理

拆分学习是一种通过模型切分实现隐私保护与计算卸载的分布式学习框架，其基本思想是将完整的深度神经网络沿网络层方向划分为两个子模型：前半部分部署在客户端，后半部分部署在服务器端^{[1][7]}。设完整模型为 $M_w : X \rightarrow Y$ ，其中 w 表示模型参数，则其可被划分为客户端侧子模型 M_{w_c} 与服务器侧子模型 M_{w_s} ，满足：

$$M_w(x) = M_{w_s}(M_{w_c}(x)), \quad x \in X. \quad (2-3)$$

在拆分学习框架下，客户端首先将本地数据 x 输入其持有的前半部分网络 M_{w_c} ，得到中间激活结果：

$$h = M_{w_c}(x), \quad (2-4)$$

该中间表示通常被称为中间激活^[1]。客户端将 h 发送至服务器，服务器继续执行后续网络层的前向传播，得到预测结果：

$$\hat{y} = M_{w_s}(h), \quad (2-5)$$

并根据真实标签 y 计算损失函数 $\mathcal{L}(\hat{y}, y)$ 。

在反向传播阶段，服务器首先计算关于中间激活 h 的梯度：

$$\frac{\partial \mathcal{L}}{\partial h} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial h}, \quad (2-6)$$

并将该梯度回传给客户端。客户端据此继续计算关于自身参数 w_c 的梯度并更新模型：

$$w_c \leftarrow w_c - \eta \frac{\partial \mathcal{L}}{\partial w_c}, \quad (2-7)$$

其中 η 表示学习率。通过上述过程，拆分学习在不共享原始数据的前提下完成了端到端的前向与反向传播^{[1][2]}。

根据标签是否由客户端提供，拆分学习通常可以分为两种基本形式。一种是标签共享模式 (Label-sharing SL)，即客户端在发送中间激活结果的同时，将对应的标签一并发送至服务器，由服务器负责损失计算与反向传播；另一种是标签保护模式 (Label-protected SL)，即客户端仅发送中间激活结果，标签保留在本地，由客户端完成损失计算并参与反向传播。后者在一定程度上进一步降低了标签泄露风险，更适用于对标签敏感性要求较高的应用场景^{[1][23]}。

相较于联邦学习，拆分学习在资源受限场景下具有明显优势。由于客户端只需执行前几层网络计算，其计算量和存储开销大幅降低，适用于边缘设备、移动终端等算力有限的环境。同时，拆分学习避免了完整模型参数在客户端之间的频繁交换，在一定程度上降低了通信负担^{[6][3]}。然而，拆分学习也引入了新的挑战，例如中间激活结果 h 可能泄露输入数据的语义信息，客户端与服务器之间的协同效率对系统性能具有较大影响等，这些问题在后续研究中逐渐受到关注^{[15][7]}。

2.1.3 多客户端拆分学习机制

早期拆分学习研究主要聚焦于单客户端场景，即一个客户端与服务器协同完成模型训练。然而，在实际应用中，往往存在多个数据拥有方需要共同参与模型构建的需求，例如跨医院联合诊断、跨机构金融建模以及跨终端行为分析等场景。在此背景下，多客户端拆分学习逐渐成为一种重要的扩展形式^{[2][13][14]}。

设系统包含 N 个客户端 $\{C_i\}_{i=1}^N$ ，其中 $N \geq 2$ 。每个客户端 C_i 持有自身的本地数据集 $\mathcal{D}_i$ ，并部署相同结构的客户端侧子模型 $M_{w_{c_i}}$ ，服务器则维护统一的服务器侧子模型 M_{w_s} 。整体模型函数可表示为：

$$M_w(x_i) = M_{w_s}(M_{w_{c_i}}(x_i)), \quad x_i \in \mathcal{D}_i. \quad (2-8)$$

与联邦学习中“并行更新、集中聚合”的训练方式不同，多客户端拆分学习通常采用串行训练机制，即各客户端按照预定顺序依次参与模型训练^{[11][12]}。设客户端顺序为 $(C_1, C_2, \dots, C_N)$ ，在一轮训练过程中，服务器首先将当前模型参数 $w_c^{(t)}$ 发送给

C_1 。客户端 C_1 基于本地数据完成一次前向与反向传播，更新参数得到 $w_{c,1}^{(t+1)}$ ，并将其传递给 C_2 作为初始参数。后续客户端依次重复上述过程：

$$w_{c,i}^{(t+1)} = w_{c,i-1}^{(t+1)} - \eta \frac{\partial \mathcal{L}_i}{\partial w_{c,i-1}}, \quad i = 1, 2, \dots, N, \quad (2-9)$$

其中 $\mathcal{L}_i$ 表示客户端 C_i 上的本地损失函数。

上述过程体现了多客户端拆分学习的核心特征：客户端侧模型参数在不同客户端之间连续传递，即前一客户端训练得到的参数将直接作为后一客户端的初始参数继续参与训练。这一机制被称为权重共享机制^{[11][12]}。与联邦学习中各客户端模型相互独立、仅通过服务器聚合间接关联不同，多客户端拆分学习中客户端模型参数之间存在显式的顺序依赖关系。

在每一轮训练中，客户端首先完成前向传播并将中间激活发送至服务器，服务器继续完成后续计算并回传梯度；客户端根据接收到的梯度更新本地参数后，将其传递给下一个客户端，直至所有客户端完成一次训练轮次。最终得到的模型参数将被用于后续推理阶段。由于多个客户端依次对同一组参数进行更新，模型能够融合来自不同数据源的特征分布，从而提升整体泛化能力^{[13][14]}。




图 2.1 多客户端场景下的拆分学习示意图

从系统角度看，多客户端拆分学习在通信复杂度上具有一定优势。由于不存在集中聚合过程，服务器仅需在客户端之间转发参数，避免了大规模并行通信带来的拥塞问题。同时，串行训练机制在一定程度上缓解了客户端算力差异导致的“拖慢效应”，使整体训练过程更加平滑^{[6][9]}。然而，该机制也引入了新的安全隐患。由于客户端之间存在显式的参数传递链路，恶意客户端一旦对模型参数进行篡改，其影响可能沿着传递路径逐步扩散，对后续客户端训练产生持续干扰。这种顺序传播特性使得多客户端拆分学习在安全性方面呈现出不同于单客户端场景的新挑战^{[26][32]}。

2.2 深度神经网络与模型训练机制

深度神经网络作为当前人工智能领域最核心的模型形式之一，已经在计算机视觉、自然语言处理、语音识别等多个任务中取得了显著成功^{[35][36]}。其通过多层非线性映射结构对输入数据进行逐层特征抽象，从而能够自动学习复杂数据分布中的高阶语义信息。在分布式学习场景下，无论是联邦学习、拆分学习还是多客户端拆分学习，其本质仍然是对深度神经网络参数的协同优化。因此，理解深度神经网络的基本结构与训练机制，是分析模型参数敏感性、设计权重投毒攻击以及构建防御策略的基础。

本节将从神经网络基本结构、前向传播与反向传播机制以及模型参数更新过程三个方面展开介绍，为后续章节中参数重要性评估与权重篡改分析提供理论支撑。

2.2.1 神经网络基本结构

典型的深度神经网络由多层神经元单元堆叠而成，每一层由线性变换与非线性激活函数组成。设输入样本为 $x \in \mathbb{R}^d$ ，第 l 层网络的线性变换过程可表示为：

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}, \quad (2-10)$$

其中 $W^{(l)}$ 表示第 l 层的权重矩阵， $b^{(l)}$ 表示偏置向量， $a^{(l-1)}$ 表示上一层的输出激活值。

随后，通过非线性激活函数 $\sigma(\cdot)$ 得到当前层的输出：

$$a^{(l)} = \sigma(z^{(l)}). \quad (2-11)$$

通过多层上述变换，神经网络能够逐层提取输入数据的特征表示。在图像分类任务中，浅层网络通常学习边缘、角点等低级特征，而深层网络则逐渐学习到更加抽象的语义特征^{[35][36]}。在图神经网络或序列模型中，不同层次则对应不同范围的结构依赖关系^{[37][38]}。正是这种逐层抽象能力，使得深度神经网络在复杂模式建模中具备显著优势。

从参数角度看，深度神经网络的全部可学习参数可表示为：

$$\Theta = \{W^{(1)}, b^{(1)}, W^{(2)}, b^{(2)}, \dots, W^{(L)}, b^{(L)}\}, \quad (2-12)$$

其中 L 表示网络总层数。模型训练的目标即是通过优化这些参数，使得网络在给定任务上的预测结果尽可能接近真实标签。

在拆分学习场景中，参数集合 Θ 会被划分为客户端侧参数 Θ_c 与服务器侧参数

Θ_s ，即：

$$\Theta = \Theta_c \cup \Theta_s, \quad \Theta_c \cap \Theta_s = \emptyset. \quad (2-13)$$

其中 Θ_c 通常对应前若干层网络参数， Θ_s 对应后续网络参数。这种结构划分为后续权重传播与篡改分析提供了直接切入点^{[1][7]}。

2.2.2 前向传播与反向传播机制

神经网络训练过程本质上是一个基于梯度的参数优化过程，其核心由前向传播与反向传播两部分组成。

在前向传播阶段，输入样本 x 依次通过各层网络映射，得到模型输出 $\hat{y}$ ：

$$\hat{y} = f(x; \Theta), \quad (2-14)$$

其中 $f(\cdot)$ 表示由参数 Θ 所确定的整体网络映射函数。根据具体任务类型（如分类或回归），模型输出将与真实标签 y 一同用于计算损失函数 $\mathcal{L}(\hat{y}, y)$ ，例如交叉熵损失或均方误差损失。

在反向传播阶段，网络根据损失函数对各层参数的偏导数逐层计算梯度。以第 l 层参数为例，其梯度可表示为：

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \frac{\partial \mathcal{L}}{\partial z^{(l)}} \cdot \frac{\partial z^{(l)}}{\partial W^{(l)}}, \quad (2-15)$$

其中：

$$\frac{\partial \mathcal{L}}{\partial z^{(l)}} = \frac{\partial \mathcal{L}}{\partial a^{(l)}} \cdot \sigma'(z^{(l)}). \quad (2-16)$$

通过链式法则，梯度信息可以从输出层逐层向输入层传播，从而实现对全部参数的更新。在标准随机梯度下降（SGD）框架下，参数更新规则可表示为：

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial W^{(l)}}, \quad b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial b^{(l)}}, \quad (2-17)$$

其中 η 表示学习率。

在拆分学习场景中，前向传播与反向传播过程被分割在客户端与服务器两端执行。客户端首先执行前半部分网络映射：

$$h = f_c(x; \Theta_c), \quad (2-18)$$

并将中间激活 h 发送至服务器；服务器继续完成后续映射：

$$\hat{y} = f_s(h; \Theta_s), \quad (2-19)$$

并计算损失函数 $\mathcal{L}(\hat{y}, y)$ 。在反向传播阶段，服务器首先计算关于 h 的梯度：

$$\frac{\partial \mathcal{L}}{\partial h} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial h}, \quad (2-20)$$

并将其回传给客户端，客户端再继续计算关于 Θ_c 的梯度并完成参数更新^{[11][2]}。

这种“前向分离、反向回传”的训练机制，使得客户端无需暴露原始数据即可参与模型训练，同时也使得中间激活与梯度成为潜在的攻击与防御对象^{[15][29]}。

2.2.3 模型参数更新与敏感性分析

在基于梯度的优化框架下，深度神经网络的训练过程本质上是对模型参数集合 Θ 的迭代更新过程。设损失函数为 $\mathcal{L}(\Theta)$ ，在标准梯度下降方法中，参数 $\theta \in \Theta$ 在一次迭代中的更新形式可表示为：

$$\Delta \theta = -\eta \frac{\partial \mathcal{L}}{\partial \theta}, \quad (2-21)$$

其中 η 为学习率，用于控制参数更新的步长。

该更新公式表明，模型参数的变化幅度直接受梯度大小与学习率共同影响。不同参数在训练过程中所承担的优化作用并不相同，其对损失函数变化的影响程度存在显著差异。因此，从参数更新角度对模型参数的重要性与敏感性进行分析，对于理解模型训练行为具有重要意义。

(1) 基于梯度幅值的参数重要性

在一阶优化视角下，参数梯度的幅值常被用作衡量参数重要性的直观指标。梯度 $|\frac{\partial \mathcal{L}}{\partial \theta}|$ 描述了损失函数对参数 θ 的局部敏感程度：当梯度幅值较大时，说明该参数的微小变化可能引起损失函数的显著波动；反之，梯度接近零的参数在当前训练阶段对模型输出的影响相对较弱。

基于梯度幅值的参数重要性评估方法具有计算开销低、实现简单等优点，已被广泛应用于模型剪枝、参数压缩以及模型分析等任务中^{[39][40]}。该类方法通常假设，在给定扰动幅度约束下，对梯度较大的参数进行修改将对模型性能产生更显著的影响。

(2) Fisher 信息矩阵

除了一阶梯度信息外，参数的重要性还可以从统计角度通过二阶信息进行刻画。Fisher 信息矩阵是一种常用的参数敏感性度量工具，其定义为：

$$F(\theta) = \mathbb{E}_{x \sim \mathcal{D}} \left[\left(\frac{\partial \log p(y|x; \theta)}{\partial \theta} \right)^2 \right], \quad (2-22)$$

其中 $p(y|x; \theta)$ 表示模型在参数 θ 下对样本 (x, y) 的条件概率分布。

Fisher 信息反映了参数扰动对模型输出分布变化的期望影响程度。直观而言, Fisher 值较大的参数对模型预测分布具有更强的控制能力, 其变化更容易引起模型行为的显著改变。由于无需显式计算 Hessian 矩阵, Fisher 信息在实际应用中兼具表达能力与计算可行性, 因而被广泛用于参数重要性评估与模型敏感性分析^{[41][42]}。

(3) Taylor 一阶近似分析

在小扰动假设下, 参数变化对损失函数的影响可通过 Taylor 展开进行近似分析。对损失函数 $\mathcal{L}(\theta)$ 在当前参数点进行一阶 Taylor 展开, 当参数 θ 发生扰动 $\Delta\theta$ 时, 有:

$$\Delta\mathcal{L} \approx \frac{\partial\mathcal{L}}{\partial\theta}\Delta\theta. \quad (2-23)$$

该近似表明, 在扰动幅度受限的条件下, 损失函数的变化主要由梯度项决定。因此, 梯度较大的参数在相同扰动约束下更容易导致损失函数的显著变化。基于 Taylor 一阶近似的分析方法为参数重要性建模提供了一种直观且有效的理论依据, 在模型分析与参数选择任务中具有广泛应用^{[43][44]}。

上述分析表明, 模型参数在优化过程中并非等价: 不同参数对模型性能的贡献程度存在显著差异。这一特性在模型剪枝、参数压缩等任务中被广泛利用, 同时也为权重投毒攻击提供了重要切入点。攻击者若能够精准定位对模型性能影响较大的关键参数, 并对其施加定向扰动, 则可能在较小扰动幅度下实现对模型性能的显著破坏。

在多客户端拆分学习场景中, 参数更新过程具有额外的结构特征。由于客户端侧参数在不同客户端之间顺序传递, 前一客户端对参数的修改将直接影响后一客户端的训练起点。这意味着, 针对关键参数的微小篡改可能通过多轮顺序更新逐步累积, 其影响范围不仅局限于单一客户端, 而可能扩散至整个系统。这种“顺序依赖 + 累积放大”的特性, 使得多客户端拆分学习在参数层面具有更高的攻击敏感性^{[11][12]}。

从攻击视角看, 模型参数更新机制决定了攻击干预的基本路径: 攻击者可以通过操纵梯度、篡改权重或注入异常更新来影响模型收敛方向; 从防御视角看, 参数更新轨迹及其统计分布也为异常检测与回退机制提供了重要观测信号。对模型训练机制的深入理解, 是后续构建权重投毒攻击模型与防御框架的理论基础。

2.3 拆分学习中的攻击算法

随着拆分学习在隐私保护协同建模场景中的广泛应用, 其潜在安全风险逐渐引起研究者关注。拆分学习的基本思想是在客户端与服务器之间对深度神经网络进行切分: 客户端负责前半部分模型的前向计算, 并将中间激活上传至服务器; 服务器完成后续计算、损失评估以及部分反向传播, 再将对应梯度信息返回给客户端, 以完成参数更新。与联邦学习主要围绕“本地完整模型训练—服务器聚合”展开不同, 拆分

学习的训练过程更加依赖客户端与服务器之间的连续交互，其安全问题也因此表现出与联邦学习不同的特征。

从表面上看，拆分学习通过避免原始数据直接离开客户端，似乎能够天然降低隐私泄露风险。然而，已有研究表明，原始数据不直接上传并不意味着训练过程天然安全。在拆分学习中，客户端与服务器之间反复交换的中间激活、梯度、标签相关信息以及模型参数状态，本质上都可能成为攻击者利用的对象。一方面，中间激活虽然不是原始输入，但往往仍保留了较强的语义结构与任务相关特征，攻击者可能利用其恢复输入数据、推断标签信息或窃取模型知识；另一方面，服务器返回的梯度信息、客户端持有的局部模型参数以及训练过程中的状态变化，也可能为攻击者提供额外的侧信道，使其能够实施更加隐蔽和更具破坏性的攻击。

从系统交互路径上看，拆分学习中的攻击面主要集中在两类信息通道上：其一，是客户端向服务器传输的中间激活及与之相关的前向特征表示；其二，是服务器向客户端回传的梯度、预测结果或参数更新信息。围绕这两类交互信息，不同角色的攻击者可以形成不同的攻击策略。例如，若服务器是不可信的，则其可利用自身接收到的中间激活、梯度或标签相关信息，对客户端输入进行重构、推断或劫持训练过程；若客户端是不可信的，则其可通过伪造输入、篡改训练状态、注入恶意扰动或构造后门行为，对服务器侧模型乃至整个协同训练过程施加影响。因此，从攻击发起方的角度出发，现有拆分学习攻击方法大体可以分为两类：由服务器发起的攻击，以及由客户端发起的攻击。

需要指出的是，这两类攻击在能力边界、可利用信息以及攻击目标上均存在明显差异。服务器通常掌握后半段模型、损失函数以及更强的全局观察能力，因此更容易实施输入重构、标签推断和训练劫持等攻击；而客户端虽然在全局视角上受限，但其更贴近实际分布式协同场景中的潜在威胁来源，可以通过操控本地训练过程、伪装合法参与方身份或注入恶意更新来影响模型行为。现有研究已经围绕这两个方向提出了多种具有代表性的攻击方法，并逐步揭示出拆分学习在隐私性、完整性与可用性方面的多重安全风险。

基于上述认识，本节将围绕拆分学习中的典型攻击算法展开介绍。首先，分析由服务器发起的攻击，重点说明服务器如何利用其在训练流程中的信息优势，对客户端数据、标签或训练状态实施恢复、推断与操控；随后，讨论由客户端发起的攻击，说明客户端如何借助本地训练权限与协议参与身份，对拆分学习过程实施投毒、后门或伪装式攻击；最后，结合现有攻击方法的适用前提与能力边界，进一步分析其在多客户端拆分学习（MCSL）环境中的局限性，以及共享权重顺序传播机制可能带来的新型潜在风险。




图 2.2 拆分学习中的攻击类型示意图

2.3.1 基于恶意服务器主体的攻击方法

在典型拆分学习架构中，服务器负责执行模型后半部分的前向与反向计算，并在训练过程中持续接收来自客户端的中间激活以及与损失计算相关的反馈信息。尽管客户端的原始输入数据并未直接上传至服务器，但中间激活并不是“无信息”的抽象表示，它通常仍保留了输入样本的大量语义结构、类别相关特征甚至局部纹理信息。因此，一旦服务器是不可信的，其便可以利用自身在训练流程中的中心位置和信息优势，对客户端的隐私数据、标签信息以及局部模型状态实施多种形式的攻击。

现有研究中，服务器侧攻击大多建立在“半诚实但好奇” (honest-but-curious) 或“遵循协议但试图推断隐私”的威胁假设下。也就是说，服务器在形式上仍按照拆分学习既定流程完成后半段模型计算、损失评估和梯度回传，不会显式中断训练过程，但会在此过程中额外分析所接收到的中间激活、梯度或标签相关信号，以恢复客户端数据、推断监督信息，甚至进一步操控训练行为。在这一威胁模型下，服务器侧攻击的主要目标并不一定是立即破坏模型精度，而更多体现为对客户端隐私的窃取、对局部模型功能的逼近、对训练特征空间的操控以及对模型学习过程的隐式干预。

从现有研究脉络来看，服务器发起的攻击大体可以归纳为四类：模型反演与输入重构攻击、标签推断攻击、模型窃取攻击，以及特征空间劫持或训练劫持类攻击。

首先，模型反演攻击 (model inversion) 或输入重构攻击是服务器侧最具代表性的攻击形式之一。其基本思想是：服务器将接收到的中间激活视为关于原始输入的压缩表征，然后通过优化求解、特征匹配或重建网络等方式，反推出能够产生相同或相似中间激活的输入样本。由于客户端前半部分模型本质上执行的是从输入空间到

特征空间的映射，因此若切分位置较浅，或者客户端局部模型对输入结构保留较多细节信息，则服务器有可能从中间激活中恢复出具有较高可识别度的原始输入内容。例如，在图像分类任务中，攻击者可随机初始化一个伪造输入，并不断调整该输入，使其经过客户端局部模型后得到的中间激活与真实中间激活尽可能接近。随着优化过程迭代进行，恢复结果会逐渐逼近真实图像，从而泄露用户样本的外观轮廓、类别语义甚至某些局部纹理特征。相关研究表明，即使服务器无法直接访问客户端原始数据，只要能够持续观察中间激活和模型状态，仍有可能实现有效的输入恢复或特征重建^{[15][17][30]}。

其次，标签推断攻击 (label inference attack) 关注的并不是恢复原始输入本身，而是从训练交互信息中推断样本对应的监督信号。在很多拆分学习场景中，标签被视为与原始数据同等敏感的信息，因为其往往直接反映样本所属类别、用户状态或任务目标。虽然某些拆分学习变体通过“标签保护”机制避免客户端显式上传标签，但已有研究发现，服务器仍可能借助中间激活、梯度结构或模型输出分布间接推断标签信息。其基本原理在于：不同类别样本在特征空间中通常呈现出一定的聚类结构，而损失函数对不同标签所产生的梯度响应也往往具有可区分性。服务器可以利用这些统计差异，通过距离度量、聚类分析、梯度匹配或预测分布分析等手段，推断样本的真实标签。与模型反演攻击相比，标签推断攻击在实现上往往更隐蔽、代价更低，因为其不需要恢复高维输入空间中的具体样本，只需从中间表示中识别出类别相关模式即可。现有研究表明，无论是在两方拆分学习还是更一般的标签保护场景下，服务器侧均可能实现在线或离线形式的标签推断，这说明“标签不直接上传”并不能从根本上消除监督信息泄露的风险^{[23][21][19][20]}。

再次，服务器还可能借助训练过程实施模型窃取攻击 (model stealing attack)。与输入重构或标签推断不同，模型窃取攻击的目标并非恢复客户端私有数据，而是尽可能恢复客户端局部模型的功能行为、参数特征或决策边界信息。在拆分学习中，服务器虽然无法直接访问客户端前半部分模型的全部参数，但其能够持续观察客户端输出的中间激活，并结合自身持有的后半部分模型、损失反馈以及训练过程中的交互轨迹，对客户端局部模型形成间接刻画。若服务器通过构造辅助输入、分析中间表示变化模式，或利用训练过程中的可观测反馈建立替代映射关系，则有可能逐步逼近客户端模型的特征提取行为，从而实现对局部模型功能的窃取。现有研究进一步指出，拆分学习中的攻击者甚至可以在不依赖真实训练数据的条件下，对模型实施反演、窃取与标签推断等复合攻击，这说明客户端侧模型本身也可能成为服务器窃取的重要对象^{[18][33]}。

最后，除隐私恢复、标签推断与模型窃取之外，近年来研究者还开始关注服务器对客户端特征空间和训练过程的主动操控问题，这类工作通常被概括为特征空间劫

持 (feature space hijacking) 或训练劫持 (training hijacking) 类攻击。与前几类攻击主要“被动观察、主动恢复”不同, 这类攻击更强调服务器利用其控制后半段模型和反向传播路径的能力, 对客户端的局部表示学习过程施加影响。由于客户端模型的参数更新高度依赖服务器回传的梯度信息, 服务器理论上可以通过构造带偏置的训练反馈, 引导客户端学习到对攻击者更有利、而对真实任务不利的特征表示。例如, 服务器可以通过操控损失函数、修改梯度方向、干预特征分布对齐过程等方式, 使客户端逐渐学习到更易于被推断、窃取或利用的中间表示, 从而实现对特征空间的隐式塑形。此类攻击未必会立刻表现为模型精度的大幅下降, 因此更具隐蔽性; 但从安全角度看, 它意味着服务器不仅是信息的观察者, 还可能成为训练过程的主动操控者。已有研究进一步指出, 即便在差分隐私或部分防护机制存在的条件下, 服务器仍可能通过特征空间层面的操控与劫持实现攻击目标, 说明拆分学习的服务器侧威胁已经从“数据恢复”逐步扩展到了“表示学习过程控制”这一更深层面^{[34][32]}。

总体来看, 服务器侧攻击的核心关注点主要包括隐私泄露、标签推断、模型窃取以及训练过程操控等方面, 其主要威胁对象既可能是客户端私有数据本身, 也可能是客户端局部模型及其学习到的特征表示, 而不一定直接体现为模型整体性能的立即下降。这类攻击通常并不依赖服务器显式偏离训练协议, 而是在“表面合法”的训练过程中悄然完成, 因此具有较强的隐蔽性和现实威胁。与此同时, 也应看到, 现有服务器侧攻击研究大多围绕单客户端或两方拆分学习场景展开, 其攻击面主要集中于客户端与服务器之间的信息交互链路, 而较少涉及多个客户端之间顺序训练和共享权重传播所引入的新型风险。也正因为如此, 当拆分学习扩展到多客户端场景后, 现有服务器侧攻击虽然仍然重要, 但已不足以完整刻画系统所面临的全部威胁, 这也为后续客户端侧攻击以及多客户端拆分学习中的新型投毒风险分析提供了进一步研究空间。

2.3.2 基于恶意客户端主体的攻击方法

与服务器侧攻击主要围绕输入恢复、标签推断与特征窃取展开不同, 客户端侧攻击更关注模型训练过程本身的完整性与可用性问题。客户端作为拆分学习协议中的直接参与方, 掌握本地数据、前半部分模型以及本地训练流程, 因此其一旦是恶意的, 便可以借助“合法参与者”身份在训练过程中实施更加隐蔽的攻击。相较于服务器侧攻击更多体现为隐私威胁, 客户端侧攻击往往直接面向模型行为操控, 包括后门注入、训练劫持、伪客户端攻击以及参数/梯度层面的恶意扰动等, 其最终目标通常是降低模型整体性能、诱导特定输入产生错误输出, 或使训练过程朝着有利于攻击者的方向偏移。

从实现机制上看, 客户端侧攻击之所以在拆分学习中具有现实威胁, 根本原因在

于客户端掌握着训练链路的起点。一方面，客户端直接接触原始输入数据，并负责前半部分模型的特征提取过程，这意味着其可以在数据层和表示层同时实施操控；另一方面，客户端本地训练所产生的中间激活、局部梯度或参数更新会进一步影响服务器侧模型的优化方向，从而使恶意影响沿训练链路向后传播。特别是在拆分学习中，服务器通常默认客户端是“遵循协议”的良性参与方，因此只要恶意客户端在形式上不破坏通信格式、不显著中断训练过程，其恶意行为就很可能被包装为正常训练更新，从而具备较强的隐蔽性。

现有研究中，客户端发起的攻击主要可以归纳为以下几类：后门攻击、训练劫持与模型操控攻击，以及伪客户端或恶意参与方注入攻击。

首先，后门攻击（backdoor attack）是客户端侧最具代表性的攻击类型之一。其基本思想是：攻击者在本地数据中注入带有特定触发器（trigger）的恶意样本，并将这些样本标记为攻击者期望的目标类别，从而使模型在正常测试样本上仍保持较高准确率，但在遇到带有触发器的输入时输出攻击者指定的错误结果。由于后门攻击不会显著破坏模型在普通样本上的表现，因此其隐蔽性通常较强。在拆分学习场景中，客户端掌握输入端和前半部分模型，因此其不仅可以在原始数据层注入触发器，还可以在中间激活层或局部特征表示层面植入后门行为。这意味着攻击者不一定需要直接篡改服务器侧模型参数，仅通过操控客户端本地训练数据和特征提取过程，就可能使后门特征在后续服务器侧模型中被稳定学习下来。已有研究表明，无论是在传统两方拆分学习，还是在更复杂的垂直拆分学习场景中，客户端侧后门攻击均具有较强可行性；而对应的防御研究也从侧面说明，这类攻击已经成为拆分学习安全研究中的重要威胁方向^{[24][26][45][46]}。

其次，客户端还可以通过训练劫持（training hijacking）或更一般的模型操控方式影响拆分学习的收敛路径。这类攻击与后门攻击不同，其目标不一定是让特定触发样本产生预设输出，而更强调通过操控本地训练行为，使全局模型逐渐偏离正常优化方向。例如，恶意客户端可以在本地训练阶段刻意修改梯度方向、放大某些敏感参数的更新幅度，或注入带有偏置的特征表示，使服务器侧模型在看似正常的训练过程中逐步学习到被扭曲的决策边界。由于拆分学习的训练是依赖客户端—服务器连续交互完成的，服务器通常只能观察到来自客户端的中间激活和部分训练反馈，而难以完整验证客户端本地训练是否“真正诚实”，这就给了恶意客户端在局部训练环节中进行隐蔽操控的空间。相关研究已经表明，客户端可利用这种能力对拆分学习实施训练劫持，并在不显著破坏训练表面行为的前提下干扰模型收敛或植入恶意影响^{[32][26]}。

再次，除显式后门和局部训练操控之外，客户端侧攻击还包括伪客户端攻击（pseudo-client attack）或恶意参与方注入攻击。这类攻击强调攻击者并不一定需要直接控制已有合法客户端，也可以通过伪装成协议中的合法参与者加入训练过程，并

利用其身份位置窃取信息或操控模型。与传统意义上的“内部恶意客户端”相比，伪客户端攻击更突出协议身份层面的威胁，即攻击者通过模拟正常客户端的交互行为，在不被系统立即识别的情况下接入训练流程，从而实施数据窃取、功能窃取或恶意更新注入。相关研究表明，拆分学习协议若缺乏足够严格的参与方校验与行为约束，攻击者可能借助伪客户端身份对系统造成实际威胁，这说明客户端侧风险不仅来自“已有客户端作恶”，也可能来自“非法参与者伪装接入”这一更广泛的攻击面^[33]。

总体来看，客户端侧攻击的共同特点在于：攻击者处于训练流程的前端位置，能够直接控制原始输入、本地训练数据以及前半部分模型行为，因此其攻击方式天然更贴近真实多参与方协同场景。与服务器侧攻击相比，客户端侧攻击往往更直接地影响模型完整性与最终行为，而不只是被动窃取隐私信息。特别是在后门攻击和训练劫持场景中，客户端发起的恶意行为能够在表面遵循协议的前提下持续影响模型学习过程，从而具有较强的隐蔽性与现实危害。

然而，需要注意的是，现有针对拆分学习的客户端攻击研究，大多仍建立在两方拆分学习或单客户端—服务器交互的基本设定之上。在这类场景中，攻击效果通常局限于客户端与服务器之间的局部训练链路，其攻击传播路径主要体现为“恶意客户端影响服务器侧模型”，而尚未系统考虑多个客户端按顺序参与训练时，恶意影响如何沿客户端队列持续传播的问题。也就是说，现有客户端攻击虽然已经证明了拆分学习中的参与方本身可能成为重要威胁源，但其研究重点仍更多停留在“单点作恶”层面，而对于多客户端拆分学习中共享权重顺序传递所带来的跨客户端扩散风险，仍缺乏专门而系统的研究。这一点也正是后续分析现有攻击算法局限性以及引出多客户端拆分学习潜在新风险的重要基础。

2.3.3 现有攻击算法的局限性与多客户端拆分学习中的潜在风险

综合现有研究可以发现，当前拆分学习安全分析虽然已经从输入重构、标签推断、后门注入到训练劫持等多个方向展开，但其整体研究范式仍然存在一个较为明显的局限：大多数攻击模型与防御分析都建立在两方拆分学习或单客户端—服务器交互的基本假设之上。在这一设定中，系统的核心信息流主要表现为“客户端上传中间激活—服务器完成后续计算并回传梯度”，因此现有攻击的关注重点也主要集中在客户端与服务器之间的交互链路：服务器侧攻击更多聚焦于隐私泄露与特征窃取，客户端侧攻击更多聚焦于局部后门注入、训练劫持或协议伪装^{[15][21][33][24]}。在这种研究框架下，攻击的影响范围通常局限于单个客户端与服务器之间的训练过程，尚未充分触及多参与方串行协作条件下更复杂的传播机制。

然而，随着拆分学习应用场景从两方协作逐步拓展到多数据拥有方共同参与的协同建模任务，越来越多的系统开始采用多客户端拆分学习模式。在这一模式下，系统

结构已经不再是简单的“单客户端—单服务器”交互，而是多个客户端按照一定顺序或规则共同参与模型训练，并通过共享权重或局部参数状态维持训练连续性^{[11][12][13]}。与传统两方拆分学习相比，MCSL的核心变化并不只是客户端数量增加，而是模型参数在系统中的流动方式发生了根本性改变：模型状态不再仅在客户端与服务器之间往返，而是沿着客户端队列在多个参与方之间形成连续传播链路。

在串行训练与权重共享机制下，每个客户端的训练结果都会作为下一个客户端的初始模型状态。这意味着，不同客户端之间不再是彼此独立的局部训练单元，而是通过共享权重形成了显式的参数耦合关系。前序客户端对共享权重所做的更新，将直接影响后序客户端的训练起点、梯度方向以及特征表示学习过程。也正因为如此，一旦某个客户端在权重层面引入异常扰动，其影响将不再局限于当前轮次或当前客户端本地训练阶段，而可能随着共享权重的持续传递不断参与后续训练，并在多个客户端之间逐步扩散。换言之，在MCSL中，恶意更新不再只是“局部污染”，而可能转化为一种沿客户端链路传播的系统级扰动。

这一点使得MCSL在安全性上呈现出与两方拆分学习和联邦学习均不相同的特征。相较于两方拆分学习，MCSL中攻击者的影响对象不再只是服务器侧模型或单次交互结果，而可能通过共享权重间接影响多个后续客户端的本地训练过程；相较于联邦学习，MCSL又不存在“同轮并行更新—服务器聚合”的缓冲结构，恶意客户端的更新不会在聚合过程中被其他客户端的正常更新平均稀释，也无法通过Krum、Trimmed Mean等基于横向统计比较的鲁棒聚合方法直接过滤^{[26][32]}。在联邦学习中，恶意更新通常需要与多个良性更新共同进入聚合阶段，其影响会受到聚合规则的制约；而在MCSL中，异常权重一旦被传递给下一客户端，便会直接成为后续训练的“合法初始状态”，从而具有更强的隐蔽性与持续性。

更进一步地，从攻击传播机制角度分析，MCSL的风险不只是“单次更新更危险”，而是“攻击具备了天然的时序扩散条件”。在共享权重串行流动的过程中，恶意扰动可能经历三个阶段的累积效应：首先，攻击者在自身轮次中注入异常权重；其次，后续客户端在不知情的情况下继续基于受污染权重进行本地训练，使异常信号与正常更新发生耦合；最后，这种被再训练、再封装后的共享权重继续向后传递，从而使原始恶意扰动在多轮训练中不断重分布、累积甚至放大。现有针对两方拆分学习的攻击研究通常并不需要考虑这种“跨客户端、跨轮次”的持续传播链，而这恰恰是MCSL中最值得警惕的结构性风险来源。

另一方面，现有拆分学习攻击方法大多仍以隐私窃取或局部后门注入为主要目标，对“模型整体性能持续退化”“恶意扰动沿权重链路逐步扩散”等问题关注不足。即使已有部分客户端侧攻击或防御工作已经意识到拆分学习中存在训练劫持、客户端后门以及局部恶意更新等威胁^{[24][26][45]}，其研究重点仍主要停留在两方交互条件下

的局部完整性破坏，而尚未系统刻画多客户端顺序协同场景中恶意扰动的传播路径、放大规律及其与共享权重机制之间的内在关系。也就是说，现有工作已经证明“拆分学习中的参与方可能作恶”，但尚未充分回答“在多个客户端共享权重的条件下，少量恶意节点为何能够对整个系统产生持续性破坏”这一更接近实际部署场景的问题。

因此，可以认为，多客户端拆分学习在参数交互层面引入了一个不同于传统两方拆分学习与联邦学习的新型攻击面：共享权重既是实现协同训练的关键机制，也是恶意扰动得以跨客户端传播的天然载体。围绕这一攻击面，现有研究仍缺乏系统的攻击建模与针对性分析，特别是缺乏对恶意扰动在客户端序列中如何传播、何时被放大、为何会导致系统级性能持续退化等问题的专门研究。这一理论与方法上的空白，正构成了本文后续工作的直接切入点。基于此，本文进一步将研究重心聚焦于 MCSL 中共享权重的传播机制，分析恶意客户端如何借助这一机制实施权重投毒攻击，并在此基础上设计相应的检测与恢复策略。

2.4 本章小结

本章围绕分布式机器学习的基础理论与关键技术展开系统论述，为后续多客户端拆分学习场景下的安全建模与攻击方法设计奠定了理论基础。首先，从联邦学习与拆分学习两种典型分布式学习范式出发，介绍了其模型部署方式、训练流程及参数交互机制，并重点分析了多客户端拆分学习所采用的串行训练与权重共享机制，指出其在系统结构上与联邦学习并行更新与集中聚合模式存在本质差异。

随后，从深度神经网络的训练过程入手，系统阐述了前向传播与反向传播中的参数更新机理，分析了梯度信息在模型优化中的作用以及不同参数对损失函数的敏感性差异，并结合梯度幅值、Fisher 信息矩阵与 Taylor 一阶近似等分析方法，对模型参数重要性与敏感性进行了理论刻画。这为后续从参数层面对模型行为进行分析与干预提供了必要的数学基础。

在模型攻击分析部分，本章重点围绕拆分学习场景下已有攻击算法展开讨论，从攻击发起角色出发，系统梳理了由服务器与客户端发起的典型攻击形式，并分析了现有攻击方法在单客户端假设下的适用范围及其局限性。进一步地，结合多客户端拆分学习所采用的串行训练与权重共享机制，指出现有攻击范式难以刻画参数在客户端序列中的传播与累积效应，从而揭示了多客户端拆分学习在参数层面所引入的潜在安全风险。

综合以上分析可以看出，多客户端拆分学习在实现隐私保护与协同建模的同时，由于其串行训练与权重共享机制，在参数交互层面引入了新的攻击面与传播路径，使模型更容易受到参数篡改与恶意干扰的影响。基于此，下一章将对多客户端拆分学习系统进行形式化建模，并构建相应的威胁模型，为后续权重投毒攻击方法的设计与分

析提供统一的问题定义框架。

第三章 多客户端拆分学习下的权重投毒攻击与防御方案

在前文中，本文系统介绍了分布式机器学习与拆分学习的基本原理，并对现有拆分学习与联邦学习场景下的攻击方法进行了分析，总结了多客户端拆分学习环境中潜在的安全风险。在此基础上，本章将围绕多客户端拆分学习场景，系统研究权重共享机制下的投毒攻击问题，并进一步给出相应的防御方案设计。

本章首先对多客户端拆分学习的系统模型与威胁模型进行建模，明确系统架构、串行训练与权重共享机制，以及攻击者的能力假设与攻击目标，为后续攻击与防御方法的设计提供统一的分析基础。随后，本文提出一种针对多客户端拆分学习环境的权重投毒攻击框架（DASH-MSL），详细介绍攻击的整体流程、设计思路以及关键组成模块，并重点分析权重重要性评估与扰动构造策略在攻击过程中的作用。

在此基础上，本章进一步从攻击强度控制与权重传播机制的角度，对多客户端拆分学习中投毒攻击的累积效应与扩散特性进行分析，揭示串行训练与权重共享机制对攻击效果的放大作用。随后，本文将多种联邦学习中的典型投毒攻击方法适配至多客户端拆分学习场景，对其攻击机理与效果进行对比分析，以全面评估不同攻击策略在该环境下的适用性与局限性。

最后，针对所提出的权重投毒攻击，本章设计了一种基于权重异常检测与历史权重回退的防御机制，并给出相应的算法流程与复杂度分析，对防御方案的可行性与有效性进行讨论。本章的研究为后续实验评估与安全分析奠定了理论与方法基础。

3.1 系统模型与威胁建模

在本章中，为了对多客户端拆分学习环境下的权重投毒攻击进行系统性分析，有必要首先明确系统的整体架构、训练机制以及攻击者的能力假设与攻击目标。本节将围绕多客户端拆分学习的系统模型展开描述，并在此基础上给出本文所采用的威胁建模，为后续攻击方法与防御机制的设计提供统一的分析框架。

3.1.1 串行训练与权重共享机制

在多客户端拆分学习系统中，模型训练通常采用串行训练（sequential training）或轮转训练（round-robin training）机制^{[11][12]}。在该机制下，多个客户端按照预先设定的顺序依次与服务器交互完成模型训练过程，模型权重在客户端队列中持续传递与更新^{[11][12]}。

具体而言，在每一轮全局训练过程中，模型权重首先由第一个客户端进行初始化或加载。随后，客户端 C_i 在接收到来自前一个客户端 C_{i-1} 的模型权重后，基于自身

本地数据与服务器协同完成若干步训练更新。在训练结束后, 客户端 C_i 将更新后的模型权重传递给下一个客户端 C_{i+1} , 以继续后续训练流程。当所有客户端均完成一次训练后, 即构成一轮完整的全局训练轮次, 系统进入下一轮训练^[11]。

该串行训练与权重共享机制在实际部署中具有一定优势。首先, 相较于并行训练与集中聚合的方式, 串行训练能够有效降低通信带宽需求, 并避免由客户端算力差异带来的同步阻塞问题^{[6][9]}。其次, 通过权重在客户端之间的持续传递, 模型能够逐步融合不同客户端的数据特征, 从而提升整体泛化性能^{[13][14]}。然而, 这种训练机制也使得模型权重在系统中形成了一条连续的传播路径, 一旦某一阶段的权重被异常篡改, 其影响可能在后续训练过程中不断累积并放大。

从安全角度来看, 权重共享机制使得客户端之间形成了一种隐式的信任关系: 每个客户端默认信任来自前一个客户端的模型权重, 并在此基础上继续训练^{[12][26]}。这种假设在良性环境下通常是合理的, 但在存在恶意客户端的情况下, 可能被攻击者利用, 从而对系统整体性能造成潜在威胁。因此, 串行训练与权重共享机制虽然是多客户端拆分学习的重要特征之一, 但同时也是其安全风险的重要来源。

3.1.2 权重共享的必要性分析

在多客户端拆分学习中, 权重共享机制是实现多客户端协同训练的核心组成部分。与传统集中式训练或联邦学习不同, MCSL 并不依赖于并行更新与集中聚合, 而是通过模型权重在客户端之间的顺序传递, 使模型能够逐步吸收来自不同客户端的数据特征^{[11][12]}。因此, 权重是否在客户端之间进行共享, 将直接影响模型的训练效率、收敛行为以及最终性能表现。

从直观角度来看, 若在多客户端拆分学习过程中不进行权重共享, 则每个客户端仅能基于自身本地数据对模型进行独立训练。由于各客户端数据分布通常存在显著差异, 这种相互隔离的训练方式难以充分融合多源数据的信息, 模型在不同客户端之间反复重置或割裂, 容易导致训练过程不稳定, 且最终模型性能受限^{[12][14]}。在极端情况下, 该过程将退化为多个彼此独立的单客户端拆分学习任务, 从而失去多客户端协同训练的实际意义。

相反, 引入权重共享机制后, 模型参数在客户端之间得以连续传递与更新。当前客户端的训练结果将作为下一客户端训练的初始状态, 使模型能够在多个数据分布上逐步积累知识。这种顺序更新方式在一定程度上模拟了集中式训练中“全数据参与优化”的效果, 有助于模型在更广泛的数据空间中进行参数搜索, 从而提升整体收敛速度与泛化性能^{[13][14][11]}。

为进一步验证权重共享机制在多客户端拆分学习中的必要性, 本文对比分析了“启用权重共享”与“不启用权重共享”两种训练设置下的模型性能表现。实验结果

如图3.1所示，在相同模型结构和训练配置下，引入权重共享机制能够显著提升模型的收敛速度，并在训练后期获得更高且更加稳定的分类准确率。这一现象表明，权重共享不仅有助于加快模型训练过程，同时也是保障多客户端拆分学习有效性的关键因素。




图 3.1 权重共享机制对多客户端拆分学习模型训练性能的影响

需要强调的是，权重共享机制在提升模型性能的同时，也在系统中引入了新的依赖关系。由于模型参数在客户端之间持续传递，后续客户端默认信任来自前一客户端的权重更新结果。这种隐式信任关系在良性环境下是合理且必要的，但在存在恶意客户端的情况下，可能被攻击者利用，从而使异常权重通过共享机制在系统中扩散^{[12][26]}。正是由于权重共享机制在多客户端拆分学习中具有不可替代的作用，对其进行针对性的安全分析与攻击研究才具有现实意义。

综上所述，权重共享机制既是多客户端拆分学习实现协同训练与性能提升的关键前提，同时也是潜在安全风险的重要来源。对该机制进行深入分析，为后续权重投毒攻击的建模与防御方案设计提供了必要的系统背景与研究动机。

3.1.3 攻击者能力假设与攻击目标

在本研究中，重点关注由客户端发起的恶意攻击行为。该假设基于现实应用场景中的合理考虑：在多客户端协同训练环境中，客户端数量通常较多，其来源和运行环境也更加复杂多样，相较于由平台方统一维护的服务器，客户端更容易被攻击者控制或伪装^{[33][24]}。

具体而言,本文假设系统中存在少量恶意客户端,其数量远小于系统中的客户端总数,其余客户端及服务器均为诚实参与方。恶意客户端在协议层面严格遵循多客户端拆分学习的训练流程,不会中断训练过程、篡改通信格式或引入明显异常行为,从而避免被服务器或其他客户端直接检测。在完成正常训练过程后,恶意客户端在模型权重共享阶段对即将传递给下一个客户端的模型权重进行细粒度篡改。

在攻击能力方面,攻击者不具备服务器端的任何特殊权限,也无法直接访问其他客户端的本地数据、模型参数或训练过程信息。攻击者仅能够获取自身训练过程中可见的模型权重与梯度信息,并基于这些信息实施攻击操作。该设定符合客户端侧攻击或弱白盒攻击假设,也更贴近真实系统部署环境^{[33][25]},同时有助于验证攻击方法在不同应用场景中的通用性。

在攻击目标方面,本文关注的是系统级性能退化,而非针对特定样本的定向误分类或后门触发攻击。攻击者的目标是通过持续对共享模型权重的持续投毒,逐步干扰后续客户端的训练过程,使得模型在整体训练过程中出现性能退化现象,例如分类准确率显著下降。由于模型权重在客户端之间不断传递,即使攻击最初仅由单一恶意客户端发起,其影响也可能在多轮训练过程中逐步扩散,从而对整个多客户端拆分学习系统产生长期且隐蔽的破坏^{[24][26]}。

上述系统模型与威胁假设构成了本文后续权重投毒攻击方法与防御机制设计的基础,为多客户端拆分学习环境下的安全性分析提供了统一且清晰的建模前提。

3.2 基于参数敏感性的权重评估方法

在多客户端拆分学习场景中,模型训练过程具有显著的串行特征。模型参数需要在多个客户端的数据分布上依次更新,而非通过并行聚合的方式进行统一优化。这种串行训练机制在提升多方协作建模能力的同时,也使模型面临类似于连续学习(Continual Learning)中的灾难性遗忘(catastrophic forgetting)问题^{[41][47]}。具体而言,当模型在后续客户端上进行训练时,新数据所驱动的参数更新可能覆盖先前客户端所学习到的判别信息,从而导致模型在早期客户端数据上的性能显著退化。类似的现象在顺序式拆分学习环境中同样被观察到,说明训练顺序与参数传递机制可能显著影响模型对已有知识的保持能力^[48]。

已有研究表明,灾难性遗忘的本质在于模型中少量关键参数发生了不可逆的偏移^[41]。针对该问题,弹性权重固化(Elastic Weight Consolidation, EWC)等方法通过引入正则化项限制重要权重的变化幅度,以缓解模型在连续任务中的性能退化^{[41][47]}。然而,与防御连续遗忘问题的研究目标相反,本文从攻击者视角出发,刻意采用相反的思路:通过有针对性地扰动模型中的关键权重,主动放大串行训练过程中的遗忘效应,从而增强权重投毒攻击在多客户端拆分学习中的破坏力与隐蔽性。与此同时,

近期联邦学习中的相关研究也表明，若攻击者能够识别并操控对模型保持既有知识至关重要的关键参数，则可显著放大系统级性能退化，这为本文从参数敏感性角度构造攻击提供了重要启发^[49]。

基于上述动机，本文首先对模型参数的重要性进行系统评估，以识别对模型损失函数和预测性能具有关键影响的权重参数，为后续权重投毒扰动的构造提供精确的攻击目标。

3.2.1 理论分析

在深度神经网络中，不同参数对模型预测结果的贡献程度存在显著差异。大量研究表明，模型性能的变化往往由少量关键权重主导，而非所有参数的均匀变化^{[39][40]}。无论是在网络压缩、结构剪枝还是连续学习中，参数重要性评估都被广泛用于识别对模型行为具有关键影响的连接、通道或权重^{[50][51][41]}。这一现象在串行训练和权重共享机制下尤为明显。

在 MCSL 环境中，模型参数会在不同客户端之间不断传递和复用。若攻击者对所有权重进行无差别扰动，不仅会引入明显的异常行为，还可能被后续客户端的正常训练部分抵消，导致攻击效果不稳定。相反，若攻击者能够精准定位对模型损失函数高度敏感的权重参数，并仅对这些关键权重施加方向性扰动，则能够在不显著破坏整体训练流程的前提下，持续放大灾难性遗忘效应，使模型逐步偏离原有的收敛轨迹。这一思路本质上与参数重要性评估和显著性分析中的基本假设一致，即模型中总存在一部分对当前任务更敏感、更关键的参数^{[52][53][54]}。

因此，关键权重识别方法的设计需遵循以下原则：第一，参数重要性评估应能够刻画参数微小变化对模型损失的直接影响；第二，评估过程应仅依赖于攻击者在训练过程中可获得的信息，避免引入额外的系统假设；第三，方法应具备较低的计算复杂度，以适应攻击场景下的现实约束。

基于上述原则，本文采用基于一阶梯度信息的参数敏感性度量方法，对模型权重的重要性进行量化评估。

3.2.2 参数重要性度量指标

设模型参数集合为 $\mathbf{w} = \{w_i\}_{i=1}^N$ ，损失函数记为 $L(\mathbf{w})$ 。参数重要性的核心思想在于评估单个参数 w_i 发生微小扰动时，对损失函数值所产生的影响程度。为此，本文引入两种基于一阶信息的参数重要性度量指标，分别来源于 Fisher 信息与一阶 Taylor 展开^{[41][44]}。

(1) 基于 Fisher 信息的参数重要性评估

Fisher 信息矩阵在统计学习理论中用于刻画模型参数对观测数据分布的敏感程度。直观而言，若某一参数的微小变化会显著改变模型在样本上的预测分布，则该参数对当前任务具有更高的重要性。在深度神经网络的监督学习场景中，参数重要性也可从损失函数角度理解：当参数发生微小扰动时，损失函数变化越剧烈，说明该参数越“关键”^{[41][42]}。

在一般形式下，Fisher 信息矩阵可写为

$$\mathbf{F} = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\nabla_{\mathbf{w}} \log p(y|x; \mathbf{w}) \nabla_{\mathbf{w}} \log p(y|x; \mathbf{w})^{\top}], \quad (3-1)$$

其中 $p(y|x; \mathbf{w})$ 表示模型的预测分布， $\nabla_{\mathbf{w}}$ 为关于参数的梯度算子。直接计算完整 Fisher 信息矩阵不仅需要对全参数维度进行二阶规模的存储与运算，在深度模型中开销极高，而且也不符合攻击场景下“轻量、可执行”的现实约束。因此，本文采用对角近似（diagonal approximation）的方式，将 Fisher 信息矩阵简化为逐参数的敏感性评估，从而将参数重要性转化为可直接排序的标量分数^{[41][42]}。

具体而言，攻击者在训练过程中可获得服务器回传的梯度 $\frac{\partial L(\mathbf{w})}{\partial w_i}$ 。基于 Fisher 对角近似，本文将第 i 个权重的重要性度量定义为

$$\text{Saliency}(w_i) = \left(\frac{\partial L(\mathbf{w})}{\partial w_i} \right)^2, \quad (3-2)$$

其中 $L(\mathbf{w})$ 为训练损失函数。式 (3-2) 的含义可以从两个层面理解：其一，梯度的绝对值反映了损失函数在当前参数点的局部变化率，梯度越大，说明该参数对损失越敏感；其二，平方操作消除了梯度符号带来的正负抵消，使重要性度量仅关注“影响强度”，从而更适用于对参数进行全局排序与筛选。

考虑到梯度在不同 mini-batch 之间存在波动，为获得更稳定的参数重要性估计，本文采用跨批次累积的方式对重要性进行平滑统计。设在攻击者客户端本地训练过程中共观察到 T 次梯度（可对应 T 个 mini-batch 或 T 个本地 step），则可使用如下累积形式：

$$\widehat{\text{Saliency}}(w_i) = \frac{1}{T} \sum_{t=1}^T \left(\frac{\partial L_t(\mathbf{w})}{\partial w_i} \right)^2, \quad (3-3)$$

其中 $L_t(\mathbf{w})$ 表示第 t 次计算所对应的损失。该累积操作能够降低单次梯度异常所造成的评估偏差，使得筛选出的关键权重更加贴合模型在当前训练阶段的总体敏感性分布。

在攻击可行性方面，基于 Fisher 的重要性评估具有三点优势：第一，仅依赖一阶梯度信息，攻击者无需访问或估计二阶导数；第二，计算复杂度与存储复杂度均为

$O(N)$ ，其中 N 为模型参数量，与常规反向传播的计算量处于同一量级，不会引入明显的异常开销；第三，该方法对模型结构和损失函数形式的依赖较弱，可广泛适用于不同任务与不同拆分学习架构（如 label-sharing 与 label-protected 设置）^{[42][40]}。

更重要的是，在本文的威胁模型下，攻击者恰好能够获得用于更新模型的梯度信息。换言之，Fisher 重要性评估可以视为对攻击者“已拥有信息”的再利用：攻击者并不需要额外的系统权限即可完成关键权重识别，从而为后续针对性权重扰动提供可靠的攻击对象基础。

(2) 基于一阶 Taylor 展开的参数重要性评估

尽管 Fisher 对角近似能够有效刻画梯度幅值与参数敏感性的关系，但仅依赖梯度信息在某些情况下可能产生偏差：例如，当不同层或不同模块的参数尺度差异较大时，单纯的梯度平方可能更偏向于选择梯度数值较大的层，而忽略参数本身的数值大小对损失变化的贡献。为缓解该问题，本文进一步引入基于一阶 Taylor 展开的参数重要性评估方法，从“损失变化量”的角度对参数重要性进行近似估计^{[43][44]}。

设攻击者对第 i 个参数施加微小扰动 Δw_i ，则损失函数的变化可由一阶 Taylor 展开近似表示为

$$\Delta L \approx \frac{\partial L(\mathbf{w})}{\partial w_i} \cdot \Delta w_i. \quad (3-4)$$

由式 (3-4) 可知，损失变化量与梯度以及扰动幅值共同决定。若将“参数被移除”或“参数发生相对变化”作为一种典型扰动情形，则可令 Δw_i 与当前参数值 w_i 相关。基于这一思想，本文采用如下重要性度量：

$$\text{Saliency}(w_i) = \left| \frac{\partial L(\mathbf{w})}{\partial w_i} \cdot w_i \right|. \quad (3-5)$$

式 (3-5) 的直觉解释是：该指标刻画了对参数进行“与其当前幅值同量级”的相对扰动时，损失函数可能产生的变化幅度。相比 Fisher 指标仅关注梯度幅值，Taylor 指标同时引入了参数数值尺度，使得重要性评估更接近于“参数变化对损失的实际影响”，从而在不同层尺度差异显著的深度网络中往往更加稳健^{[43][44]}。

类似地，为降低单次梯度噪声带来的不稳定性，本文同样可对 Taylor 重要性进行跨步累积。设在 T 次梯度观测下得到的 Taylor 重要性为

$$\widehat{\text{Saliency}}(w_i) = \frac{1}{T} \sum_{t=1}^T \left| \frac{\partial L_t(\mathbf{w})}{\partial w_i} \cdot w_i \right|. \quad (3-6)$$

该形式在实现上仅需在每次梯度回传后额外执行一次逐元素乘法与绝对值运算，整体复杂度仍为 $O(N)$ ，不会显著增加攻击者的计算负担。

从攻击视角看，Taylor 指标具有两个额外的优势：其一，它能够自然地偏向于筛

选“梯度大且参数值也大”的权重，这类权重通常对应模型中对输出影响更直接的关键连接；其二，在某些训练阶段，梯度幅值可能由于优化器动量、学习率调度或批次噪声等因素出现短期波动，而参数值往往更稳定，引入 w_i 能够在一定程度上提升重要性排序的平滑性与一致性。

需要强调的是，本文采用 Taylor 重要性度量的目的并非与 Fisher 指标相互替代，而是在不同模型、不同数据异质性程度以及不同训练阶段下，提供一种同样高效但可能更稳健的关键权重识别方式。在后续实验中，本文将分别基于 Fisher 与 Taylor 构建关键权重集合，并在一致的攻击框架下进行对比评估，以展示不同重要性度量在多客户端拆分学习权重投毒场景中的适用性与效果差异。

(3) 其他参数重要性评估方法的适用性分析

表 3.1 不同参数重要性评估方法的计算复杂度与攻击可利用性对比

方法	计算复杂度	攻击可利用性
Fisher Pruning	$O(N)$	✓
Taylor Expansion	$O(N)$	✓
SNIP	$O(N)$	×
SynFlow	$O(N^2)$	×
GraSP	$O(N^2)$	✓
Optimal Brain Surgeon (OBS)	$O(N^3)$	✓

在模型剪枝与网络压缩领域，已有大量工作围绕参数重要性评估提出了不同的方法。这些方法在静态模型压缩或训练前结构优化等场景中取得了良好效果^{[39][50][51][40]}。然而，在多客户端拆分学习的权重投毒攻击场景下，攻击者的能力和可获取信息受到显著限制，使得部分参数重要性评估方法在实际攻击中难以直接应用。

首先，SNIP 方法通过在训练开始前评估参数对损失函数的敏感性，从而决定哪些参数应当被保留^[52]。该方法依赖于模型尚未经过训练时的梯度信息，其核心假设是参数重要性在训练初期即可被可靠估计。然而，在本文所考虑的攻击场景中，攻击者通常无法在模型初始化或训练前阶段介入参数评估过程，而只能在模型已经参与多轮训练并不断被更新之后获取梯度信息。因此，SNIP 所要求的“训练前评估”假设在现实攻击模型中难以满足。

其次，SynFlow 方法通过构造特殊形式的损失函数，并在无数据或弱监督条件下传播梯度，以评估参数在网络结构中的全局重要性^[53]。尽管该方法在避免梯度消失问题方面具有一定优势，但其实现过程需要对原始训练目标进行显式修改，并引入额外的前向与反向传播步骤。这不仅增加了计算与实现复杂度，也可能在攻击过程中引入异常的训练行为，从而降低攻击的隐蔽性。此外，SynFlow 所构造的重要性度

量更偏向于结构层面的连通性分析，而非直接刻画参数对当前任务损失的敏感程度，因此并不完全契合本文以放大灾难性遗忘为目标的攻击需求。

进一步地，GraSP 和 Optimal Brain Surgeon (OBS) 等方法通过显式或隐式地利用 Hessian 矩阵刻画参数之间的二阶依赖关系，从而实现更加精细的参数重要性评估^{[54][55]}。这类方法在理论上能够更准确地衡量参数移除或扰动对模型性能的影响，但其代价是显著增加的计算与存储开销。在深度模型中，Hessian 矩阵的维度通常与参数数量的平方甚至立方成正比，使得相关计算在攻击者受限的客户端环境中难以高效执行。此外，二阶方法通常需要对训练流程进行额外控制或修改，这与本文所设定的被动攻击威胁模型并不相符。

从攻击可行性的角度来看，多客户端拆分学习场景下的攻击者通常只能获取服务器返回的一阶梯度信息，而无法访问其他客户端的数据或服务器端的全局状态。因此，参数重要性评估方法若依赖于二阶信息、特殊损失函数设计或训练前阶段的全局访问权限，将在现实攻击中难以部署。相比之下，基于 Fisher 信息和一阶 Taylor 展开的参数重要性评估方法仅依赖于训练过程中自然产生的一阶梯度信息，既不需要修改原有训练流程，也不会引入额外的系统假设，更符合攻击者在实际环境中的能力约束^{[41][42][44]}。

此外，从攻击目标的角度看，本文的核心目的并非获得最精确的参数重要性排序，而是在保证隐蔽性和可执行性的前提下，识别出一组对模型性能高度敏感的关键权重。基于一阶信息的方法虽然在精度上可能略逊于二阶方法，但其所筛选出的关键权重已足以在串行训练与权重共享机制下放大灾难性遗忘效应，从而对模型性能产生持续且累积的破坏性影响。

综上所述，本文未采用部分在模型剪枝领域中表现良好的参数重要性评估方法，并非出于方法性能的考虑，而是基于攻击威胁模型、可执行性约束以及多客户端拆分学习训练机制的综合权衡。在上述条件下，基于 Fisher 信息和一阶 Taylor 展开的参数重要性评估方法在计算复杂度、实现难度与攻击效果之间取得了更为合理的平衡，因此被本文选为关键权重识别阶段的核心技术手段。

3.2.3 关键权重的构建与筛选

在获得模型中各参数的重要性评分后，攻击者需要进一步将连续的参数重要性度量结果转化为可操作的关键权重集合。需要指出的是，参数重要性评估本身仅提供了不同权重对模型损失敏感程度的相对刻画，而权重投毒攻击的实际执行则要求攻击者明确哪些参数应当被选中并施加扰动。因此，如何基于参数重要性评分构建一个规模可控且具有高攻击价值的关键权重子集，是连接重要性评估与后续攻击操作的关键步骤^{[52][44]}。

具体而言,攻击者根据参数重要性排序,从所有参数中筛选出重要性评分位于前列的一部分参数作为关键权重子集。该筛选过程的核心思想在于:并非所有重要参数都需要被同时扰动,而是通过对少量高敏感性权重施加针对性扰动,即可在串行训练与权重共享机制下对模型性能产生显著影响。这一思路与参数剪枝和显著性筛选方法中的基本做法是一致的,即先利用重要性度量对参数进行排序,再基于排序结果构造可操作的参数子集^{[52][39]}。

为实现上述目标,本文引入基于阈值的筛选策略。设参数重要性阈值为 τ ,则可构造掩码矩阵 $\mathbf{M}$:

$$\mathbf{M}_i = \begin{cases} 1, & \text{Saliency}(w_i) \geq \tau, \\ 0, & \text{otherwise.} \end{cases} \quad (3-7)$$

其中, $\text{Saliency}(w_i)$ 表示由前述参数重要性评估方法得到的第 i 个权重的重要性评分。通过该阈值筛选机制,攻击者能够从全体参数中自动区分出关键权重与非关键权重,从而避免对模型进行无差别扰动。

通过引入掩码矩阵,攻击者在后续攻击过程中仅对被标记为重要的权重参数施加扰动,而保持其余参数不变。这种选择性扰动策略在显著提升攻击效果的同时,有效降低了模型整体参数分布发生异常变化的风险。一方面,关键权重往往在模型预测行为中起主导作用,对其进行扰动能够更高效地破坏模型性能;另一方面,限制扰动范围也有助于避免参数统计特征发生剧烈变化,从而增强攻击在训练过程中的隐蔽性。

此外,需要注意的是,模型参数的重要性分布并非在整个训练过程中保持不变。在多客户端拆分学习的串行训练过程中,模型会不断适配来自不同客户端的数据分布,参数对损失函数的敏感程度也随之发生变化。基于这一特性,本文允许关键权重集合在不同训练轮次中进行动态更新。具体而言,攻击者可在每次本地训练完成后,基于最新的梯度信息重新评估参数重要性,并据此调整关键权重集合。这种基于当前梯度信息的迭代式更新方式与一阶显著性评估方法的基本思想相一致,即参数重要性应随模型状态变化而动态调整,而非被视为一次性静态结果^{[44][53]}。

这种动态更新机制能够使攻击策略始终贴合模型当前训练状态,使权重投毒操作持续作用于最敏感的参数子集。在多轮权重共享过程中,该策略有助于不断放大模型在不同客户端之间的灾难性遗忘效应,从而使模型性能随着训练轮次的推进逐步退化。

通过上述关键权重集合的构建与筛选过程,本文将参数重要性评估结果有效转化为可执行的攻击目标集合,为后续权重扰动构造与攻击优化策略提供了精确且高效的参数选择基础。

3.3 DASH-MSL 投毒攻击方案设计与算法实现

3.3.1 权重扰动构造与攻击向量设计

在多客户端拆分学习 (MCSL) 环境中, 模型参数通过串行方式在不同客户端之间不断传递。对于攻击者而言, 其核心目标并非在单一训练轮次中立即破坏模型性能, 而是通过在权重共享过程中引入系统性的偏移, 使模型参数逐步远离正常的收敛轨迹, 从而在多轮训练后造成显著且难以恢复的性能退化。因此, 权重投毒攻击的关键在于如何构造一种具有明确方向性且可持续累积影响的扰动形式。

设攻击者在某一轮次获得即将被传递给下一个客户端的模型权重 $\mathbf{w}$ 。攻击者在不改变模型结构的前提下, 通过对权重取值施加反向扰动, 构造扰动后的权重 $\mathbf{w}'$ 并将其传递给后续客户端。本文将这一权重投毒过程统一表示为:

$$\mathbf{w}' = \mathbf{w} - \beta \cdot f_{\text{perturb}}(\mathbf{w}), \quad (3-8)$$

其中, β 为缩放因子, 用于控制扰动强度; $f_{\text{perturb}}(\cdot)$ 为扰动函数, 用于刻画不同的扰动模式。式中采用减号的形式, 表示攻击者有意将权重值沿着与模型正常收敛趋势相反的方向进行偏移, 从而对训练过程产生持续干扰。

需要指出的是, 在实现层面, 攻击者仅对权重张量的数值进行修改, 而不改变其维度或结构。因此, 扰动函数 $f_{\text{perturb}}(\mathbf{w})$ 的输出与 $\mathbf{w}$ 具有完全相同的形状, 扰动操作以逐元素 (element-wise) 的方式施加。这一设计保证了模型在后续客户端中仍可正常参与训练, 避免由于结构异常而导致攻击行为被直接察觉。

在扰动函数的具体设计上, 本文参考联邦学习中模型投毒攻击的相关思想, 但将攻击对象从聚合过程中的梯度或模型更新转移至多客户端拆分学习中的共享权重本身^[56]。考虑到权重张量蕴含的是模型当前的参数状态信息, 本文在权重投毒过程中引入两类基础扰动向量, 分别刻画权重的单位幅值信息与符号方向信息。具体而言, 扰动函数定义为:

$$f_{\text{perturb}}(\mathbf{w}) \in \{\text{unit}(\mathbf{w}), \text{sign}(\mathbf{w})\}. \quad (3-9)$$

- **Unit 向量:** 以二维权重矩阵 $\mathbf{w}$ 为例, 对于其中的元素 w_{ij} , 其对应的 unit 向量定义为

$$\text{unit}(w_{ij}) = \frac{w_{ij}}{\|w_{ij}\|_2}. \quad (3-10)$$

在实际实现中, 本文对权重张量执行逐元素运算, 从而得到与 $\mathbf{w}$ 形状一致的 $\text{unit}(\mathbf{w})$ 。该向量反映了权重取值的单位化结果, 使扰动在数值层面与权重本身的尺度保持一致。通过这种方式, 攻击者能够在不引入突兀大幅变化的情况下, 对权重进行方向一致的反向扰动, 从而在多轮权重共享过程中逐步放大参数偏

移。

- **Sign 向量**：符号向量用于刻画权重取值的方向信息，其逐元素定义为

$$\text{sign}(w_{ij}) = \begin{cases} 1, & w_{ij} > 0, \\ 0, & w_{ij} = 0, \\ -1, & w_{ij} < 0. \end{cases} \quad (3-11)$$

对权重张量逐元素施加符号函数，可以得到与 $\mathbf{w}$ 形状一致的 $\text{sign}(\mathbf{w})$ 。与 **unit** 向量相比，**sign** 向量不包含权重幅值信息，而仅保留方向特征，使得扰动在数值上更加均匀，便于通过缩放因子 β 对整体扰动强度进行精确控制。

需要注意的是，尽管在形式上权重张量与梯度张量在维度上具有一致性，但二者所承载的信息存在本质差异。梯度反映的是损失函数在当前参数点的局部变化方向，而权重张量则描述了模型的参数状态本身。因此，基于权重构造扰动的投毒方式在机制上不同于联邦学习中直接操纵梯度或模型更新的投毒攻击^[56]。后续实验结果也表明，不同扰动向量在攻击效果上存在明显差异，这进一步验证了针对权重本身进行投毒的独立研究价值。

通过上述权重扰动公式与扰动向量设计，本文为权重投毒攻击提供了统一且可控的数学表达形式。在此基础上，攻击者可通过调节缩放因子 β 来平衡攻击强度与隐蔽性，其具体约束机制与跨轮次优化策略将在下一小节中进行详细讨论。

3.3.2 攻击目标函数的构建与优化

在多客户端拆分学习框架下，模型训练采用客户端顺序执行与共享权重逐轮传递的机制。各客户端并非并行地对模型进行更新，而是依次基于上一客户端传递的共享权重继续本地训练。在这一过程中，模型参数的演化具有显著的时序依赖性，单次权重更新的影响往往不会立即体现在模型性能上，而是通过多轮训练与权重传递逐步累积，最终决定全局模型的收敛状态与测试性能。

在第 3.3.1 节中，本文给出了权重投毒攻击的基本形式，即攻击者在共享权重中引入反向扰动，使模型参数偏离其正常的收敛方向。该过程由扰动方向函数与攻击强度参数共同决定，其中扰动方向由 **unit** 或 **sign** 向量刻画，而攻击强度参数则控制扰动在权重空间中的幅度。然而，仅给出扰动形式并不足以刻画攻击的实际效果，还需要进一步回答一个关键问题：在多客户端顺序训练机制下，何种攻击强度能够在保证攻击可传播的前提下，对最终模型性能造成最大破坏。

在已有的联邦学习投毒攻击研究中，攻击目标函数通常构建在梯度空间或模型更新空间之上，例如通过最大化恶意更新与正常更新之间的差异，使聚合后的全局更

新偏离原有优化方向^[56]。然而，该类目标函数在多客户端拆分学习场景下并不适用，主要体现在以下几个方面。首先，MCSL 中不存在中心化的梯度聚合过程，客户端之间仅通过共享权重进行协作训练，梯度差异无法直接映射为全局更新偏移；其次，梯度变化本身并不能直接反映模型最终的推理性能，而模型权重在轮训练中的整体演化轨迹才是决定测试准确率的关键因素；此外，在本文所考虑的黑盒攻击假设下，攻击者无法获取其他客户端的梯度或训练信息，进一步限制了基于梯度差异构建攻击目标的可行性。

基于上述分析，本文从模型性能退化的角度出发，构建了一种更加直接且适用于多客户端拆分学习环境的攻击目标函数。具体而言，攻击者以模型在测试集上的分类准确率下降幅度作为攻击效果的衡量指标，通过调节攻击强度参数，使引入恶意权重后的模型性能与正常训练模型之间的差异最大化。该目标函数定义如下：

$$\arg \max_{\beta} \|\text{Acc}_M(\mathbf{w}) - \text{Acc}_M(\mathbf{w} \cup \mathbf{w}')\|_2, \quad (3-12)$$

其中， $\text{Acc}_M(\mathbf{w})$ 表示模型 M 在仅包含正常权重 $\mathbf{w}$ 时，在测试集上的分类准确率； $\text{Acc}_M(\mathbf{w} \cup \mathbf{w}')$ 表示在轮权重共享与顺序训练过程中，引入恶意扰动权重 $\mathbf{w}'$ 后，最终模型在测试集上的分类准确率。该目标函数直接刻画了权重投毒攻击在多客户端顺序训练机制下对模型整体性能所造成的累积性破坏效果，而非局限于单次训练阶段或局部更新的影响。

从训练动态的角度来看，该目标函数隐含地度量了权重扰动对模型参数演化轨迹的长期影响。攻击者在某一轮训练中注入的恶意权重，会随着共享权重在客户端队列中的传递不断参与后续训练过程，其影响可能被部分放大、削弱或重新分配，最终反映在模型的收敛状态与决策边界上。因此，相较于基于瞬时梯度或单轮损失变化的指标，基于最终测试准确率差异的目标函数能够更全面地反映攻击在多客户端拆分学习环境中的真实破坏能力。

需要注意的是，在该攻击目标函数中，攻击强度参数 β 与模型准确率之间不存在显式的解析关系。攻击者仅能在训练阶段对共享权重施加扰动，而目标函数的评估发生在模型训练完成之后，此时权重已固定，无法再被直接修改。因此，攻击者无法通过梯度信息或解析方法对该目标函数进行直接优化。这一特性使得攻击优化问题本质上转化为一个基于性能反馈的黑盒优化问题。

综上所述，本文所构建的攻击目标函数不仅与多客户端拆分学习的训练机制高度契合，而且在攻击形式与攻击效果之间建立了明确的定量联系。在此基础上，如何在不可微、非凸的优化条件下有效求解该攻击目标函数，成为进一步提升攻击效果的关键问题。然而，该目标函数在形式上不具备可微性，且其数值仅能在模型完成轮训练后通过测试阶段获得，这使得传统基于梯度或解析形式的优化方法难以直接应

用。因此，如何在黑盒条件下有效优化该攻击目标函数，成为提升攻击效果的关键问题。

从优化问题的性质来看，本文所考虑的攻击目标函数具有以下显著特征。首先，该目标函数无法显式表示为攻击强度参数 β 的解析函数，其取值依赖于模型在多轮顺序训练与权重传递后的最终收敛状态；其次，目标函数的评估代价较高，每一次评估均需要完成一次完整或近似完整的模型训练与测试过程；此外，由于多客户端顺序训练机制的复杂性，不同 β 取值对应的攻击效果可能呈现出明显的非线性特征，目标函数整体表现为非凸、可能存在多个局部最优解。在上述条件下，简单的网格搜索或随机搜索方法不仅计算代价较高，而且难以在有限搜索预算内获得稳定的最优解。

基于上述分析，本文采用模拟退火 (Simulated Annealing, SA) 算法对攻击目标函数进行优化。模拟退火是一种典型的基于概率搜索的全局优化方法，能够在搜索过程中以一定概率接受次优解，从而有效跳出局部最优区域，逐步逼近全局最优解^{[57][58]}。该算法不依赖于目标函数的梯度信息，且对目标函数的连续性与凸性要求较低，因而非常适合用于本文所构建的黑盒攻击优化问题。相关研究也表明，模拟退火在复杂、非凸以及鲁棒优化问题中具有较好的适用性^[59]。

模拟退火算法通过引入概率接受机制，对传统的贪心搜索策略进行了扩展，从而在搜索过程中兼顾全局探索能力与局部收敛性^[57]。在本文的攻击优化问题中，模拟退火算法以攻击强度参数 β 作为系统状态，以攻击目标函数的取值作为评价标准，通过随机扰动与概率接受准则对 β 进行迭代更新。

具体而言，设当前迭代状态为 β_t ，对应的攻击目标函数取值为

$$F(\beta_t) = \|\text{Acc}_M(\mathbf{w}) - \text{Acc}_M(\mathbf{w} \cup \mathbf{w}'(\beta_t))\|_2.$$

在每一次迭代中，算法在当前状态附近随机生成候选解 β_{t+1} ，并计算其对应的目标函数值 $F(\beta_{t+1})$ 。若 $F(\beta_{t+1}) > F(\beta_t)$ ，则直接接受该候选解；否则，以一定概率接受该次更新，其接受概率定义为

$$P = \exp\left(\frac{F(\beta_{t+1}) - F(\beta_t)}{T_t}\right),$$

其中 T_t 表示当前迭代步的温度参数。

温度参数 T_t 随迭代过程逐步降低，以控制算法从全局探索向局部收敛的过渡。本文采用指数衰减策略对温度进行更新，其形式为

$$T_t = \lambda \cdot T_{t-1},$$

其中 $\lambda \in (0, 1)$ 为温度衰减系数。较高的初始温度允许算法以较高概率接受次优解，

从而跳出局部最优区域；随着温度的降低，算法逐渐倾向于接受能够显著提升攻击效果的解，使搜索过程稳定收敛^{[57][58]}。

通过上述机制，模拟退火算法能够在不依赖梯度信息的前提下，对攻击目标函数进行有效优化。该过程特别适用于本文所考虑的多客户端拆分学习场景，在该场景中攻击目标函数不可微、评估代价较高且存在多个局部最优解。最终，算法输出的攻击强度参数 β^* 被用于实际攻击阶段，对共享权重施加相应强度的恶意扰动。

在具体实现中，本文将攻击强度参数 β 作为优化变量，并将其搜索空间限制在一个有限区间内。根据实验设置， β 的取值范围设定为 $\beta \in [0, 2]$ ，该区间能够覆盖从弱扰动到强扰动的不同攻击强度水平。在每一次搜索迭代中，攻击者基于当前 β 值构造恶意权重扰动，并将其注入模型参数中，随后通过代理模型（agent model）对攻击目标函数进行评估。该代理模型在结构上与真实攻击目标模型保持一致，并使用攻击者本地可获得的数据集进行测试，从而在不干扰真实训练过程的前提下估计不同 β 取值对应的攻击效果。

模拟退火算法通过引入温度参数控制搜索过程中的探索与收敛行为。在搜索初期，算法允许以较高概率接受攻击效果较差的候选解，从而扩大搜索范围，避免过早陷入局部最优；随着搜索过程的推进，温度逐渐降低，算法对次优解的接受概率随之减小，使搜索过程逐步集中于高质量解附近。通过上述机制，模拟退火算法能够在有限的搜索次数内，较为稳定地找到使攻击目标函数取得较大值的攻击强度参数^{[57][59]}。

需要强调的是，由于攻击者仅能在训练阶段对共享权重进行篡改，而目标函数的评估发生在模型训练完成之后，攻击强度参数 β 必须在攻击实施前通过离线方式预先确定。在实际攻击过程中，攻击者在其轮次到来时，直接采用离线优化得到的最优 β 值，对共享权重施加相应强度的恶意扰动，并将篡改后的权重传递给下一个客户端。随着权重在客户端队列中的顺序传递，恶意扰动得以持续参与后续训练过程，并最终对全局模型性能产生显著影响。

综上所述，本文通过将攻击优化问题形式化为一个黑盒条件下的目标函数优化问题，并采用模拟退火算法对其进行求解，实现了在多客户端拆分学习环境中对攻击强度的系统性优化。该方法不仅避免了对梯度信息或其他客户端训练细节的依赖，而且能够在复杂训练动态下稳定提升权重投毒攻击的整体破坏效果，为后续实验评估与攻击配置分析奠定了方法基础。

3.3.3 DASH-MSL 攻击流程与算法化描述

在多客户端拆分学习环境中，模型训练按照预先设定的客户端顺序依次进行，共享权重在客户端之间逐轮传递。DASH-MSL 共享权重投毒攻击正是嵌入于这一顺序训练与权重共享机制之中，其整体流程既不改变系统的训练协议，也不引入额外的通




图 3.2 DASH-MSL 共享权重投毒攻击整体流程示意图

信行为。攻击者作为普通客户端参与训练，在合法训练轮次内完成对共享权重的篡改，并将投毒后的权重传递给后续客户端。

该攻击的整体流程如图 3.2 所示，可以从系统执行角度划分为以下几个关键步骤。

- 1. 攻击者参与正常训练并获取共享权重。**在攻击者轮次到来之前，多客户端拆分学习系统按照既定顺序完成前序客户端的训练，并将最新的共享权重传递至下一个客户端。攻击者作为队列中的普通客户端，首先加载来自上一客户端的共享权重，并与服务器协同完成本地前向传播与反向传播过程（如图左下角所示）。在该阶段，攻击者严格遵循拆分学习协议，其行为与诚实客户端保持一致，从而保证攻击过程在系统层面的隐蔽性。
- 2. 基于 Fisher 信息的关键权重识别（以 Fisher 剪枝为例）。**完成本轮正常训练后，攻击者利用本地可获取的训练数据与梯度信息，对模型参数的重要性进行评估。如图中左上模块所示，攻击者通过计算 Fisher 信息矩阵，对不同权重在当前任务中的敏感性进行量化，并据此识别出对模型预测性能具有关键影响的参数子集。该过程得到的关键权重在图中以加粗和下划线形式标记，其比例由阈值参数控制，具体的关键权重集合构建与筛选策略已在第 3.2.3 节中给出。该步骤完全在攻击者本地完成，不依赖服务器或其他客户端的任何额外信息。
- 3. 攻击强度参数的离线优化。**为了确定扰动注入的最优幅度，攻击者在离线阶段对攻击目标函数进行优化。如图中右上模块所示，攻击者基于本地测试数据与攻击模型，对不同攻击强度参数对应的攻击效果进行评估，并通过搜索策略获得最优缩放系数 β 。该阶段与在线训练过程解耦，使得攻击者在实际执行投毒时仅需调用已优化的攻击强度参数，而无需引入额外的在线计算开销。

4. **恶意扰动构造与权重投毒。**在完成关键权重标记与攻击强度参数确定后，攻击者开始对共享权重实施投毒操作。首先，基于第 3.2.3 节中定义的参数重要性度量，攻击者构造掩码矩阵 $\mathcal{M}$ ，用于指示需要施加扰动的关键权重位置，其定义形式为

$$\mathcal{M} = \mathbb{I}(\text{Saliency}(w_i) \geq \tau), \quad (3-13)$$

其中 $\text{Saliency}(w_i)$ 表示权重 w_i 的重要性度量， τ 为阈值参数， $\mathbb{I}(\cdot)$ 为指示函数。随后，攻击者仅在掩码矩阵所标记的位置上注入恶意扰动，对共享权重执行如下变换：

$$\mathbf{w}' = \mathbf{w} - \beta \cdot f_{\text{perturb}}(\mathbf{w} \odot \mathcal{M}), \quad (3-14)$$

其中 β 为攻击强度参数， $f_{\text{perturb}}(\cdot)$ 表示扰动构造函数（如 `unit` 或 `sign`）， $\odot$ 表示逐元素乘法运算。如图中部所示，该过程对应“仅对关键权重进行投毒”的情形，在保持权重张量结构与维度不变的前提下，将扰动集中注入到对模型行为最为敏感的参数子集。

5. **投毒权重传递与攻击传播。**完成权重投毒后，攻击者将包含恶意扰动的共享权重传递给队列中的下一个客户端。后续客户端在不知情的情况下基于被篡改的权重继续训练模型，使恶意扰动持续参与后续的参数更新过程。随着共享权重在客户端队列中的多轮传递，投毒影响逐步扩散并累积，最终对全局模型的收敛状态与测试性能产生显著破坏。

通过上述流程，DASH-MSL 共享权重投毒攻击能够在不破坏多客户端拆分学习训练协议的前提下，实现对系统训练过程的持续干扰。为进一步明确攻击者在各步骤中的具体操作顺序与执行逻辑，接下来将从算法层面对该攻击过程进行形式化描述。

为进一步从算法层面刻画攻击者在训练过程中的具体行为，本小节给出算法 3.1 的形式化描述，并围绕其离线准备与在线投毒两部分执行逻辑进行详细说明，使算法步骤与图 3.2 中的关键模块一一对应。

算法 3.1 的输入包括服务器 S 、客户端集合 $\{C_i\}_{i=1}^N$ 、初始共享权重 $\mathbf{w}$ 、恶意客户端 C_m 、训练轮数 T 以及扰动构造函数 $f_{\text{perturb}}(\cdot)$ ；算法输出为经过多轮顺序训练与共享权重投毒后得到的最终模型参数 $\mathbf{w}'$ 。需要强调的是，该算法严格遵循多客户端拆分学习的顺序训练与共享权重传递协议：除恶意客户端在其合法轮次内进行权重篡改外，其余客户端均执行标准训练流程，从而使攻击过程在系统层面具有较强的隐蔽性与可执行性。

(1) 离线准备阶段。在进入在线训练循环之前，攻击者首先完成两项离线准备操作（算法第 1–3 行）。第 2 行通过子过程 `BUILD MASK` 构造掩码矩阵 $\mathcal{M}$ ，用于确定需

算法 3.1 DASH-MSL 共享权重投毒攻击

输入: Server S , clients $\{C_i\}_{i=1}^N$, initial weights $\mathbf{w}$, malicious client C_m , training rounds T , perturbation function $f_{\text{perturb}}(\cdot)$

输出: Compromised global model $\mathbf{w}'$

```

1: /* 离线准备阶段 */
2:  $\mathcal{M} \leftarrow \text{BUILDMASK}(\mathbf{w})$  // 基于 Fisher 显著性分析与阈值筛选生成掩码矩阵
3:  $\beta \leftarrow \text{OPTIMIZEBETA}(\mathbf{w}, \mathcal{M})$  // 在代理模型上通过模拟退火策略优化攻击目标
4: /* 多客户端拆分学习场景下的在线投毒阶段 */
5: for round  $t = 1$  to  $T$  do
6:   for client  $C_i \in \{C_1, \dots, C_N\}$  do
7:      $\mathbf{w} \leftarrow \text{Receive}(\mathbf{w})$ 
8:      $\mathbf{w} \leftarrow \text{LocalTrain}(C_i, \mathbf{w})$ 
9:     if  $C_i = C_m$  then
10:       $\mathbf{w} \leftarrow \mathbf{w} - \beta \cdot f_{\text{perturb}}(\mathbf{w} \odot \mathcal{M})$  // 依据式 (6) 对共享权重实施扰动注入
11:      Send( $\mathbf{w}$ ,  $C_{i+1}$ )
12:      if  $i = N$  then
13:        Broadcast( $\mathbf{w}$ ,  $\{C_1, \dots, C_N\}$ )
14:  $\mathbf{w}' \leftarrow \mathbf{w}$  // 最终受污染的全局模型权重
15: return  $\mathbf{w}'$ 
    
```

Procedure BUILDMASK($\mathbf{w}$) // 根据式 (7) 构造掩码矩阵 $\mathcal{M}$

基于攻击者本地数据计算各参数的显著性得分 $\text{Saliency}(w_j)$

$\mathcal{M} \leftarrow \mathbb{I}(\text{Saliency}(w_j) \geq \tau)$

return $\mathcal{M}$

Procedure OPTIMIZEBETA($\mathbf{w}, \mathcal{M}$) // 依据第 3.3.2 节与第 3.3.3 节优化攻击目标函数

初始化攻击强度参数 β 及温度参数 T_0

repeat

生成候选参数 β' , 并计算目标函数值

$$F(\beta') = \|\text{Acc}_M(\mathbf{w}) - \text{Acc}_M(\mathbf{w} \cup \mathbf{w}'(\beta'))\|_2$$

按照 Metropolis 准则接受或拒绝候选参数 β'

更新当前温度参数

until 满足终止条件

return 最优攻击强度参数 β

要施加扰动的关键权重位置。该过程对应图 3.2 左上角的 Fisher Estimation 模块：攻击者在本地攻击数据上计算权重的重要性度量 (saliency)，并通过阈值 τ 将其二值化为掩码矩阵 (见子过程 BUILDMASK 的第 1–3 行)，从而得到 $\mathcal{M} = \mathbb{I}(\text{Saliency}(w_j) \geq \tau)$ (Eq.(7))。第 3 行通过子过程 OPTIMIZEBETA 获得最优攻击强度参数 β ，对应图 3.2 右上角的 Coefficient Optimization 模块。该子过程以第 3.3.2 节定义的攻击目标函数为优化对象，并采用第 3.3.3 节所述的模拟退火策略进行黑盒搜索：初始化 β 与温度 T_0 后

(子过程 OPTIMIZEBETA 第 1 行), 反复提出候选 β' 并评估目标函数 $F(\beta')$ (第 2–3 行), 再按 Metropolis 准则接受或拒绝候选解并更新温度 (第 4–5 行), 直至满足停止条件并返回最优 β (第 6–7 行)。通过将关键权重位置 $\mathcal{M}$ 与攻击强度 β 在离线阶段预先确定, 攻击者在在线执行阶段即可直接调用结果, 避免引入额外的在线搜索开销。

(2) 在线投毒阶段。完成离线准备后, 算法进入多客户端拆分学习的在线训练与投毒过程 (算法第 5–16 行)。外层循环在训练轮数 T 上迭代 (第 5 行), 内层循环按照客户端顺序遍历 $\{C_1, \dots, C_N\}$ (第 6 行), 体现了共享权重在客户端之间逐轮传递的训练机制。对于每个客户端 C_i , 其首先接收来自上一客户端的共享权重 $\mathbf{w}$ (第 7 行), 随后在本地数据上执行标准拆分学习训练过程以更新共享权重 (第 8 行)。该更新对应图 3.2 左下角的正常训练流程: 客户端与服务器协同完成前向传播与反向传播, 从而得到新的共享权重。

当内层循环遍历到恶意客户端 C_m 时 (第 9 行), 算法触发权重投毒操作 (第 10 行)。攻击者利用离线阶段获得的掩码矩阵 $\mathcal{M}$ 与攻击强度参数 β , 对共享权重执行投毒变换:

$$\mathbf{w} \leftarrow \mathbf{w} - \beta \cdot f_{\text{perturb}}(\mathbf{w} \odot \mathcal{M}),$$

即算法第 10 行所示的 Eq.(6)。该操作与图 3.2 中部的 “Mark $\rightarrow$ Poison” 过程一致: $\mathcal{M}$ 负责将扰动注入范围限制在关键权重位置, $f_{\text{perturb}}(\cdot)$ 决定扰动方向 (如 unit/sign), β 决定扰动幅度。通过仅对 $\mathcal{M}$ 所标记的参数子集施加扰动, 投毒过程在保持权重张量结构与维度不变的同时, 将扰动集中注入到对模型行为最敏感的参数位置, 从而提升攻击效率与破坏效果。

完成本地训练与 (可能的) 投毒操作后, 客户端将更新后的共享权重传递给下一个客户端 (第 11 行), 使得投毒权重能够继续参与后续客户端的训练并逐步传播。当当前客户端为序列中的最后一个客户端 ($i = N$) 时, 系统将共享权重广播给所有客户端 (第 12–13 行), 用于下一轮训练的初始化; 否则, 权重按照顺序继续向后传递。该 “顺序传递/轮末广播” 机制保证了共享权重在多客户端之间的持续流动, 也是投毒影响得以跨客户端扩散并在多轮训练中累积的关键原因。

在完成所有训练轮次后, 算法返回最终的共享权重参数 (第 15 行), 即受到共享权重投毒影响的全局模型参数 $\mathbf{w}'$ 。由于投毒权重在后续客户端训练过程中持续参与参数更新, 恶意扰动会在多轮顺序训练与共享权重传递机制的共同作用下逐步积累, 最终显著影响模型的收敛状态与测试性能。

3.4 防御机制

前述章节系统分析了多客户端拆分学习场景下基于参数敏感性的共享权重投毒攻击机制，并给出了权重扰动构造方法、攻击目标函数优化策略以及完整算法流程。分析表明，在串行训练与权重共享机制的作用下，即使仅存在少量恶意客户端，其注入的异常扰动也可通过顺序权重传递逐轮扩散，对全局模型性能造成持续性破坏。

不同于联邦学习中的并行梯度聚合机制，MCSL 不存在显式的全局聚合阶段。客户端之间通过顺序共享权重完成协作训练，权重成为唯一的跨客户端信息载体。这种结构性差异导致大量针对 FL 设计的鲁棒聚合算法（如梯度裁剪、Krum、Trimmed Mean 等）无法直接迁移至 MCSL 框架。同时，现有拆分学习防御研究主要集中于两方拆分学习、垂直拆分学习或客户端侧后门/训练劫持等场景，关注点多为局部后门注入、训练劫持检测或隐私泄露缓解，而非多客户端串行训练条件下共享权重的跨客户端传播风险^{[26][32][45][46]}。因此，就本文所研究的“共享权重投毒攻击”而言，由于其是面向 MCSL 场景的一类新型系统级攻击，目前尚缺乏严格对应的专用防御方法可直接复用。

基于这一现实背景，本文并不试图在当前阶段构建一个高度复杂的全新鲁棒训练体系，而是首先提出一种更为直接、轻量且易于嵌入现有训练流程的初步防御框架。该框架的设计目标不是彻底改变 MCSL 的训练机制，而是在尽可能保留原有串行训练与权重共享结构的前提下，对攻击传播链路进行局部拦截与抑制。为此，本文设计了一种嵌入于权重共享阶段的防御机制。该机制包括两个核心环节：其一，在权重传递前对关键权重进行异常检测；其二，在识别到异常后，通过历史权重恢复机制抑制攻击传播效应。整体防御流程示意如图 3.3 所示。

3.4.1 设计动因

在多客户端拆分学习（MCSL）框架下，权重共享机制构成了模型协作训练的核心路径。与联邦学习中的并行更新与全局聚合不同，MCSL 采用串行训练协议，各客户端按照预定顺序依次接收并更新共享权重，模型参数在客户端队列中形成单向流动结构^{[11][12]}。该结构在降低同步开销的同时，也引入了新的安全隐患。

具体而言，在共享权重投毒攻击中，恶意客户端通过篡改关键参数，将异常扰动嵌入当前轮次的模型状态。由于下一客户端的训练初始化依赖于上一客户端输出的权重，异常参数将作为“合法状态”进入后续优化过程，并可能在后续梯度更新中被进一步放大。随着权重在客户端队列中的持续传递，攻击信号逐步累积，最终对全局模型性能产生显著影响。这种由串行传递机制导致的扰动放大现象，使得 MCSL 环境下的投毒攻击具有持续性与隐蔽性^{[26][46]}。

需要特别说明的是，虽然已有工作开始关注拆分学习中的后门攻击、防御与训

训练劫持问题，例如 SafeSplit、SplitGuard 与 SecureSplit 等方法分别从客户端侧后门防御、训练劫持检测以及拆分学习场景下的后门缓解角度开展研究^{[26][32][45]}，但这些工作所针对的主要仍是传统两方拆分学习、垂直拆分学习或局部训练完整性问题。相比之下，本文关注的是多客户端串行训练条件下共享权重在客户端链路中的持续传播及其被投毒后的扩散效应。由于该攻击面本身此前尚未被系统提出，因此自然也尚未形成专门面向该威胁的成熟防御方案。换言之，本文此处提出的防御机制，本质上是一种针对新型攻击面的初步响应：它更强调在现有 MCSL 框架下的可落地性与可嵌入性，而不是追求高度复杂的鲁棒训练重构。

因此，防御机制的设计必须服从 MCSL 的结构约束。一方面，MCSL 不存在集中式鲁棒聚合节点，无法通过多客户端更新结果的统计比较来过滤异常；另一方面，防御策略若引入额外协调阶段，将破坏原有串行训练流程，增加系统复杂度。由此可见，防御机制必须嵌入现有权重共享阶段，在不改变系统架构的前提下完成异常识别与抑制。这一点也与现有拆分学习防御工作的总体趋势一致，即优先在原训练框架上嵌入检测、筛查与修复模块，而不是完全重构训练协议^{[32][45]}。

基于上述结构特征，可以进一步观察到：攻击的核心作用点在于关键权重，而传播路径在于权重传递链路。因此，有效的防御策略应围绕两个层面展开。其一，在权重传递前识别异常更新，避免异常参数进入下一客户端训练阶段；其二，在识别异常后进行局部修复，以削弱攻击在轮训练中的累积效应。前者对应异常检测机制，后者对应历史权重恢复机制。前者在方法上可借助鲁棒统计量对关键参数偏移进行刻画，后者则借鉴中毒恢复研究中“保留历史可信状态并在必要时执行恢复/回滚”的基本思想^{[60][61]}。

综上所述，本节提出的防御框架并非通过重构训练流程或引入额外聚合机制实现鲁棒性提升，而是针对当前尚缺乏专门防御方法的 MCSL 共享权重投毒攻击场景，提出一个轻量、可嵌入且符合系统约束的初步防御方案。该方案通过在权重传递路径上插入检测与恢复模块，对攻击传播链路进行精确干预。下一小节将首先给出基于关键权重筛选与鲁棒统计建模的异常检测方法。

3.4.2 基于异常检测的关键权重识别机制

针对前文提出的共享权重投毒攻击机制，可以观察到攻击者通过篡改关键权重来改变模型的优化轨迹，从而在顺序传递过程中逐步放大扰动效应。因此，在防御层面，核心问题并不在于全面监控所有参数，而在于识别并修正被恶意篡改的关键权重。这一思路与现有拆分学习防御研究中的基本观察相一致，即攻击往往并非均匀作用于全部参数，而是集中体现在少量关键位置或局部更新路径上，因此检测与防御应当尽可能聚焦于高风险参数或关键训练状态^{[26][32][45]}。




图 3.3 基于异常检测与历史权重恢复的防御机制示意图

在 MCSL 训练流程中，每一轮客户端在接收到共享权重后进行本地训练，并将更新后的权重继续传递。若攻击发生，则异常权重将在客户端队列中持续传播。基于此，本文提出在权重传递前嵌入异常检测与恢复机制：客户端首先对关键权重进行异常值检测，识别潜在被篡改的参数；随后利用历史权重进行局部恢复，从而削弱攻击信号在顺序训练过程中的扩散。这种“先检测、后修复”的处理思路，也与现有 poisoning defense 和 recovery-based defense 的总体设计逻辑一致，即优先识别异常更新，再利用可信历史状态执行局部恢复或回滚，以降低恶意扰动的持续影响^{[32][61]}。

如图 3.3 所示，防御机制嵌入于权重共享阶段。在每一轮客户端训练结束后、权重传递至下一客户端之前，首先对当前轮关键权重变化进行异常检测；若判定存在异常参数，则进入历史权重恢复模块进行局部修复，随后再执行权重传递。

可以看到，该机制并未改变 MCSL 原有的串行训练结构，而是在权重流动路径上插入检测与修复节点，从而在不破坏系统架构的前提下实现攻击抑制。

具体而言，本方法首先利用第 3.2 节中提出的参数重要性度量指标（Fisher 信息或 Taylor 一阶近似）对当前模型参数进行重要性评估，构建关键权重集合 $\mathcal{W}_c$ 。由于攻击者通常基于敏感性分析对重要权重实施定向扰动，因此对 $\mathcal{W}_c$ 进行重点检测能够提高防御的针对性与效率。这种基于关键参数优先筛查的思想也与参数显著性分析和轻量级防御设计的基本思路一致，即在不显著增加整体计算负担的情况下，将检测资源集中于最可能影响模型性能的参数子集。

设第 t 轮训练后的共享权重为 $\mathbf{w}^{(t)}$ ，上一轮权重为 $\mathbf{w}^{(t-1)}$ ，则权重变化量为：

$$\Delta \mathbf{w}^{(t)} = \mathbf{w}^{(t)} - \mathbf{w}^{(t-1)}. \quad (3-15)$$

在正常训练条件下，关键权重的变化通常受梯度平滑性约束，其更新幅度呈现出相对稳定的统计特征。而在投毒攻击下，攻击者会人为放大或反向偏移关键权重更新量，使其显著偏离正常分布范围。因此，可以通过刻画关键权重变化幅度的统计离散程度来识别异常扰动。

本文采用基于绝对中位差（Median Absolute Deviation, MAD）的异常检测方法。相较于基于均值和标准差的判别方式，MAD 以数据中位数为中心构建统计量，对极端异常值具有更强鲁棒性^{[60][62]}。在投毒场景下，恶意扰动本身即表现为极端更新值，若采用均值作为统计基准，异常值可能“污染”整体分布，削弱检测能力；而 MAD 不依赖均值估计，因此能够更准确刻画正常更新波动范围。

对于关键权重集合 $\mathcal{W}_c$ 中的更新幅度集合 $\{|\Delta w_i^{(t)}|\}$ ，首先计算其中位数：

$$m = \text{median} \left(\{|\Delta w_i^{(t)}|\} \right), \quad (3-16)$$

随后计算绝对中位差：

$$\text{MAD} = \text{median} \left(\{ ||\Delta w_i^{(t)}| - m | \} \right). \quad (3-17)$$

在此基础上构建标准化判别量：

$$z_i = \frac{|\Delta w_i^{(t)}| - m}{\text{MAD} + \epsilon}, \quad (3-18)$$

其中 ϵ 为避免分母为零的微小常数。当 $z_i > \tau$ 时，判定对应权重 w_i 为异常权重。

与固定阈值方法不同，本文采用动态阈值机制。具体而言，在滑动时间窗口内统计历史若干轮权重变化数据，对阈值 τ 进行自适应调整，从而使检测机制能够跟踪模型训练过程中缓慢的分布漂移或周期性波动。该动态更新机制避免了固定阈值在长时间训练中逐渐失效的问题，提高了检测的稳定性与适应性。类似地，现有 poisoning recovery 与鲁棒防御研究也表明，在长时训练与复杂动态环境中，防御参数若完全固定，往往难以兼顾灵敏度与稳定性，因此需要结合历史信息进行自适应调节^[61]。

在检测到异常权重后，并不直接丢弃当前权重更新，而是将异常参数标记并交由下一阶段的历史权重恢复机制处理。这种分阶段处理方式既保证了检测的准确性，也避免了过度干预对模型正常收敛造成影响。该处理方式也与现有基于检测与恢复相结合的防御思路一致，即检测模块负责识别高风险位置，而恢复模块负责执行最小必要干预，以降低误检和过度修复带来的副作用^{[32][61]}。

从复杂度角度分析，若模型总参数量为 N ，关键权重集合大小为 $|\mathcal{W}_c|$ ，则异常检测复杂度为 $O(|\mathcal{W}_c|)$ 。由于 $|\mathcal{W}_c| \ll N$ ，该机制在多轮在线训练场景下具有良好的

可扩展性。

综上所述，基于关键权重筛选与 MAD 统计建模的异常检测机制，不仅能够有效识别针对性投毒扰动，还能够在保持计算开销可控的前提下嵌入 MCSL 训练流程，为后续历史权重恢复提供可靠依据。

3.4.3 基于历史权重恢复的传播抑制机制

在上一小节中，本文通过基于关键权重筛选与 MAD 统计建模的异常检测机制，识别出可能受到投毒扰动的异常参数。然而，仅完成异常识别并不足以阻断攻击的影响。若异常权重仍然随当前模型状态传递至下一客户端，则其扰动信号仍可能在后续训练中被进一步放大。因此，在检测到异常权重后，必须设计有效的恢复策略，以抑制攻击在客户端队列中的持续传播。这一思路与 poisoning recovery 研究中的基本观点一致，即仅识别异常更新是不够的，还需要结合可信历史状态对模型进行修复或回滚，才能从根本上削弱恶意更新的长期影响^[61]。

如图 3.3 所示，当某些关键权重被判定为异常后，系统并不丢弃整轮更新结果，而是对被标记的异常参数执行局部修复操作。这种“局部恢复”策略既能够消除恶意扰动，又能尽量保留当前轮次中正常参数更新的信息，从而维持模型的收敛稳定性。类似地，现有拆分学习防御研究也表明，相较于对整轮训练结果进行粗粒度舍弃或整体回退，面向局部异常位置的精细化修复更有利于兼顾防御效果与模型可用性^{[32][45]}。

设在第 t 轮检测中，异常权重索引集合为 $\mathcal{A}^{(t)} \subset \mathcal{W}_c$ 。对于每个 $i \in \mathcal{A}^{(t)}$ ，采用历史权重记录进行替换。记历史窗口大小为 K ，则对应参数的历史参考值可表示为：

$$\bar{w}_i^{(t)} = \frac{1}{K} \sum_{k=1}^K w_i^{(t-k)}, \quad (3-19)$$

其中 $w_i^{(t-k)}$ 表示该参数在过去第 $t-k$ 轮的权重值。

随后，对异常参数执行替换操作：

$$w_i^{(t)} \leftarrow \bar{w}_i^{(t)}, \quad \forall i \in \mathcal{A}^{(t)}. \quad (3-20)$$

该恢复机制的核心思想在于利用历史权重轨迹构建“正常状态参考”。在无攻击条件下，关键权重通常沿着相对平滑的优化路径演化，其历史均值能够较好地刻画其合理取值区间。而在攻击条件下，异常扰动往往表现为突发性大幅偏移，与历史轨迹存在明显不一致。通过将异常参数回退至历史参考值，可以有效削弱单轮恶意更新对模型整体状态的影响。该思路与基于历史信息的恢复方法在 poisoning defense 中的基本逻辑一致，即利用历史阶段中相对可信的模型状态作为参考，对当前可疑状态进行

校正,从而恢复训练过程的稳定性^[61]。

从传播机制角度分析,在 MCSL 串行训练框架下,权重在客户端队列中形成单向传递链路。若异常权重未被修复,则其扰动将作为下一客户端训练的初始状态,并可能在后续梯度更新中被进一步放大。通过在权重传递前完成异常修复,可以在源头上阻断攻击信号的扩散路径,从而降低顺序放大效应。这一点也与 SafeSplit 等工作对拆分学习中攻击传播特征观察相一致,即一旦异常状态进入后续训练阶段,其影响往往不再局限于单一轮次,而可能沿训练链路持续累积^[26]。

此外,历史窗口大小 K 的选择影响恢复的平滑程度。较小的 K 值能够更快响应模型演化,但可能对短期波动较为敏感;较大的 K 值则提供更稳定的参考,但可能削弱模型对真实分布变化的适应能力。在实际部署中,可根据训练阶段动态调整 K 的取值,以平衡稳定性与适应性。类似地,已有恢复类研究也指出,历史信息的保留范围与恢复粒度之间通常存在稳定性和适应性之间的权衡关系^[61]。

值得注意的是,该恢复机制仅作用于被判定为异常的关键权重,而非对全部参数进行整体回退。因此,该方法既能够抑制攻击信号的持续传播,又不会对正常权重更新造成过度干扰,从而保持模型整体收敛性能。这种“最小必要修复”的思路与现有轻量级防御方法相一致,即优先对高风险局部状态执行干预,而尽可能保留其余正常训练信息^{[32][45]}。

综上所述,基于历史权重恢复的局部修复机制,与上一小节中的异常检测模块形成完整防御闭环:先检测异常参数,再执行局部恢复,最后将修复后的权重传递至下一客户端。该机制在不引入额外全局聚合节点的前提下,实现了对共享权重投毒攻击的有效抑制。

3.5 本章小结

本章围绕多客户端拆分学习 (MCSL) 环境下的共享权重投毒攻击问题,系统构建了攻击模型与防御机制,形成了完整的攻击-防御对抗框架。

首先,在系统模型与威胁建模部分,结合 MCSL 的串行训练协议与权重共享机制,分析了共享权重在客户端队列中的单向传递特征,指出该结构为投毒攻击提供了天然传播路径。基于攻击者能力假设,明确了攻击目标为通过篡改关键权重影响全局模型性能。

随后,在参数敏感性分析基础上,构建了关键权重筛选方法,为定向扰动提供理论支撑。在此基础上,设计了权重投毒扰动构造方法与攻击目标函数,并给出了完整的攻击算法流程,实现了从敏感性评估到共享权重篡改的系统化攻击机制。

在防御方面,本章进一步分析了 MCSL 框架下防御机制面临的结构约束,提出了一种嵌入权重共享阶段的轻量级防御方案。该方案首先通过关键权重筛选与基于

MAD 的鲁棒统计方法识别异常更新，随后利用历史权重恢复机制对异常参数进行局部修复，从源头抑制攻击在客户端队列中的持续传播。该防御机制无需引入额外聚合节点，能够无缝适配现有 MCSL 架构，并在计算开销可控的前提下提升系统鲁棒性。

综上所述，本章从攻击构造到防御设计，完整刻画了多客户端拆分学习场景下共享权重投毒攻击的威胁模型与应对策略，为后续实验验证与性能评估奠定了理论基础。下一章将通过多组对比实验，系统评估所提出攻击与防御方法在不同数据集与架构下的实际效果。

第四章 实验结果与分析

4.1 实验环境

本文所有实验均在统一软硬件环境下完成，以保证实验结果的稳定性与可复现性。实验平台采用 Ubuntu 18.04 操作系统，基于 CUDA 11.2 与 PyTorch 1.8.0 构建深度学习训练环境，并在 GPU 加速模式下完成模型训练与攻击实验。实验过程中统一设置随机种子，并在相同参数配置下重复运行多次，以减少随机因素对实验结果的影响。硬件与软件环境配置分别如表 4.1 与表 4.2 所示。

表 4.1 实验环境硬件信息

类别	详细信息	数量
硬件设备	处理器：Intel(R) Xeon(R) W-2102 CPU	1
	内存：32G DDR4-2133 RegRAM	4
	硬盘：INTEL SSDSC2KW512G8	1
	显卡：NVIDIA GeForce GTX 1080 Ti (11264MB)	1

4.2 实验整体内容与评估指标

为了系统评估本文所提出共享权重投毒攻击方法在多客户端拆分学习环境中的有效性及其影响因素，并验证所设计防御机制的缓解能力，本章在统一实验环境下开展了一系列针对性实验。通过对攻击传播过程及系统性能变化进行多维度分析，全面考察攻击对模型训练过程的破坏能力以及不同条件下攻击效果的差异。各项实验的主要内容及对应评估指标如下所示。

(1) 测试投毒攻击对系统性能的影响。该实验旨在评估攻击在整体训练过程中的破坏能力。通过比较正常训练条件下模型性能与遭受攻击后的模型性能变化，分析攻击对系统最终分类精度的影响，以验证攻击在顺序权重共享机制中的传播效果。实验以模型在测试集上的分类准确率作为主要评价指标，并通过攻击前后准确率差值衡量攻击强度。

(2) 测试队列位置对攻击效果的影响。由于多客户端拆分学习采用串行训练协议，模型权重在客户端之间依次传递，攻击者所处的训练队列位置可能对攻击传播范围产生重要影响。因此，本实验通过改变恶意客户端在队列中的位置，分析不同位置下攻击对系统性能的影响程度，从而揭示权重传递顺序对攻击扩散能力的作用机制。

表 4.2 实验环境软件信息

类别	名称	版本
操作系统	Ubuntu	18.04
	Linux 内核	4.15.0
	GCC	7.5.0
并行计算架构	CUDA	11.2
Python 环境	Python	3.7.10
	Pytorch	1.8.0
	Torchvision	0.9.0
	Kornia	0.5.6
	Scikit-Image	0.18.1
	NumPy	1.20.2
	ART	1.7.1
	Pandas	1.2.5
	Matplotlib	3.3.4
	Seaborn	0.11.1

评价指标仍采用模型最终分类准确率及其下降幅度。

(3) 测试扰动比例对攻击效果的影响。为研究攻击强度参数对系统性能的影响，本实验通过调整权重扰动比例，分析不同扰动规模下攻击效果的变化趋势。通过对比不同扰动比例条件下模型性能下降情况，评估攻击在不同约束条件下的有效性与稳定性，并探讨扰动规模与攻击破坏能力之间的关系。

(4) 测试不同攻击策略对攻击效果的影响。针对多种扰动构造策略，本实验比较不同攻击策略在相同训练条件下的攻击性能差异，以分析各策略在不同数据集和模型结构上的适用性与优势。通过系统对比不同策略下模型性能变化，进一步验证所提出攻击方法的有效性。

(5) 对比实验。为了更全面地评估本文方法的攻击能力，实验将其与现有典型投毒攻击方法进行对比分析。在相同实验设置下，通过比较不同攻击方法对模型性能的破坏程度，评估本文方法在攻击强度与稳定性方面的优势。

(6) 防御实验。为验证所提出防御机制的有效性，本实验在攻击环境下引入异常检测与权重恢复策略，对比防御前后模型性能变化，分析防御方法对攻击传播的抑制效果以及对正常训练过程的影响。通过比较攻击条件下模型性能的恢复程度，评估防御机制的有效性与实用性。

在评价指标方面，本文主要采用模型在测试集上的分类准确率作为核心指标。由

于投毒攻击的目标是降低模型性能，因此最终准确率越低，说明攻击造成的破坏程度越强。同时，通过攻击前后准确率的差值进一步衡量攻击效果，以便更直观地比较不同实验条件下的攻击强度。所有实验均在相同数据划分与参数设置下重复运行多次，并报告平均结果，以减少随机因素对实验结论的影响。

通过上述实验设计与统一评价标准，本文能够全面分析共享权重投毒攻击在多客户端拆分学习系统中的传播特性、影响因素及其防御效果，为后续实验结果分析提供依据。

4.3 实验准备

为保证实验结果的可比性与可复现性，本文对系统配置、数据集、模型结构以及对比攻击方法进行了统一设置。以下分别介绍实验中的系统参数、数据集、受害者模型以及对比攻击迁移方式。

4.3.1 系统与参数设置

本文实验基于多客户端拆分学习 (MCSL) 框架开展，系统包含 10 个客户端，其中 1 个为恶意客户端，其余客户端及服务器均为诚实参与方。训练过程中采用 round-robin 串行训练协议，模型共享权重在客户端之间依次传递。

实验同时考虑标签共享拆分学习与标签保护拆分学习两种模式。在标签共享模式下，客户端向服务器上传中间特征与标签；在标签保护模式下，标签保留于客户端本地完成损失计算与反向传播。

优化器统一采用 Adam。对于图像分类任务，MNIST 与 Fashion-MNIST 设置 batch size 为 128、训练轮次为 30、学习率为 0.001；SVHN 与 CIFAR-10 设置 batch size 为 64、训练轮次为 50、学习率为 0.001。对于图结构数据集 CORA 与 CORA-ML，训练轮次设置为 200，其中 GCN 学习率为 0.01，GAT 学习率为 0.005。

4.3.2 数据集

为验证共享权重投毒攻击在不同任务场景下的有效性，本文选取多个典型公开数据集开展实验，涵盖图像分类与图结构学习两类任务，包括 MNIST、Fashion-MNIST、SVHN、CIFAR-10、CORA 与 CORA-ML。

(1) MNIST 数据集。MNIST 是一个经典的手写数字图像数据集，包含 70,000 张灰度图像，其中 60,000 张用于训练，10,000 张用于测试。每张图像的尺寸为 28×28 像素，标签对应数字类别 0 至 9。由于其数据分布简单且类别清晰，MNIST 常用于验证模型在基础视觉任务中的性能表现^[63]。

(2) Fashion-MNIST 数据集。Fashion-MNIST 由 Zalando 提供，包含与 MNIST 相

同规模的图像数据，但类别为服饰物品，如上衣、鞋类和包等。该数据集具有更复杂的纹理和轮廓信息，可用于评估模型在中等复杂度图像任务中的性能^[64]。

(3) SVHN 数据集。SVHN (Street View House Numbers) 来源于真实街景图像，包含近 100,000 张彩色数字图像。每张图像尺寸为 32×32 ，包含来自自然场景中的复杂背景与光照变化，能够用于测试模型在真实视觉环境下的鲁棒性^[65]。

(4) CIFAR-10 数据集。CIFAR-10 包含 60,000 张 32×32 的 RGB 彩色图像，涵盖飞机、汽车、鸟类、猫、狗等 10 个类别，其中 50,000 张为训练样本，10,000 张为测试样本。该数据集具有较高的视觉复杂度，常用于评估模型在自然图像分类任务中的表现^[66]。

(5) CORA 数据集。CORA 是一个经典的引文网络数据集，节点表示学术论文，边表示引用关系，节点特征由论文文本构成。该数据集广泛用于图神经网络模型的节点分类任务研究^{[67][68]}。

(6) CORA-ML 数据集。CORA-ML 是 CORA 数据集的扩展版本，具有更大的节点规模和特征维度，能够用于验证攻击方法在更复杂图结构数据上的有效性^{[67][68]}。

在数据划分方面，图像数据集按照类别均衡原则分配至各客户端，每个客户端持有私有训练数据以模拟实际分布式学习场景；测试集保持全局共享，用于评估模型在不同攻击条件下的最终性能。对于图结构数据集，则采用标准训练集、验证集与测试集划分方式，以保证实验结果具有可比性。

上述数据集能够覆盖不同数据复杂度与任务场景，用于综合评估共享权重投毒攻击的有效性与稳定性。

4.3.3 受害者模型

为验证攻击在不同模型结构下的适用性，本文选取卷积神经网络与图神经网络作为受害者模型。

在图像分类任务中，采用 LeNet 与 ResNet-18。其中，LeNet 用于验证攻击在浅层网络中的影响，ResNet-18 用于评估攻击在深层网络中的效果^{[35][36]}。

在图结构学习任务中，采用 GCN 与 GAT 模型。GCN 通过图卷积聚合邻居节点信息，GAT 引入注意力机制对邻居特征进行加权^{[37][38]}。

在 MCSL 场景下，所有模型均按照预设切分位置划分为客户端侧与服务器侧子模型，以模拟实际拆分学习训练流程。所有实验均采用统一训练配置，并在相同条件下比较攻击前后的模型性能变化。

4.3.4 对比攻击迁移

由于本文的投毒攻击是 MCSL 领域下第一个模型投毒攻击，暂时没有相同领域的其他工作可做直接借鉴，所以为全面评估本文所提出共享权重投毒攻击在多客户端拆分学习环境下的有效性与优势，本文选取联邦学习中于 2025 年发表且具有代表性的三类模型投毒方法作为对比攻击，并将其迁移至 MCSL 的串行训练与共享权重传递机制中开展对照实验^{[69][70][71]}。需要指出的是，FL 与 MCSL 在训练范式上存在关键差异：FL 以“并行本地训练 + 服务器聚合”为基本流程，而 MCSL 采用“客户端按队列顺序串行训练 + 共享权重经服务器中继逐个传递”的协议。在 MCSL 中，客户端之间不存在集中式的鲁棒聚合阶段，因此对比攻击的迁移核心在于：将原方法中“操控上传到服务器的梯度/模型更新并影响聚合结果”的攻击面，转化为“直接篡改将要传递给下一客户端的共享权重”，使恶意扰动沿共享权重流传播并逐步累积，从而破坏后续客户端训练并影响最终全局模型性能。本文在迁移时保持各对比方法的关键思想与默认超参数设置不变，以保证比较的公平性（除非在 MCSL 语义下必须做等价替换）。此外，所选取的三种对比攻击方法均来自近年来联邦学习模型投毒领域的最新研究成果，发表于 2025 年的高水平学术期刊或顶级国际会议，代表了当前数据无关模型投毒攻击的先进水平^{[69][70][71]}。通过将这些最新方法迁移至 MCSL 场景进行比较，可以更全面、客观地评估本文所提出攻击在不同分布式学习范式下的有效性与优势。

(a) 统一的迁移接口与注入时机

设第 t 轮串行训练中，恶意客户端 C_m 从服务器接收到待继续训练的共享权重为 $\mathbf{w}^{(t)}$ ，其在本地数据上完成正常训练后得到更新 $\Delta \mathbf{w}_m^{(t)}$ 。对比攻击在 FL^{[72][73]} 中通常通过构造恶意更新向量 $\tilde{\Delta \mathbf{w}_m^{(t)}}$ （或恶意梯度）影响聚合；在 MCSL 中，本文将其等价对“即将转发给下一客户端的共享权重”进行显式篡改，即：

$$\mathbf{w}_{\text{out}}^{(t)} = \mathbf{w}^{(t)} + \Delta \mathbf{w}_m^{(t)} + \mathbf{p}^{(t)}, \quad (4-1)$$

其中 $\mathbf{p}^{(t)}$ 为对比攻击在第 t 轮生成的投毒扰动（或由其原始恶意更新等价变换得到）。服务器仅作为中继转发 $\mathbf{w}_{\text{out}}^{(t)}$ 至后续客户端，从而使扰动在队列中传播。下面分别说明三类对比攻击在 MCSL 下的等价实现方式与保留的关键机制。

(b) FedGhost：基于反馈的自适应投毒增强（数据无关）

FedGhost 的关键思想是：攻击者无需访问其他良性客户端的更新或数据，仅利用训练过程中服务器下发的全局梯度/权重轨迹，预测未来更新方向并注入扰动，同时引入“投毒反馈”来动态调节扰动强度。其框架由“对抗目标检测、投毒反馈估计、

自适应投毒增强”三部分组成，并使用余弦相似度作为反馈信号以迭代优化扰动幅度与方向^[69]。在原方法中，攻击者基于历史梯度变化 $\Delta \mathbf{G}^{(t)}$ 与权重变化 $\Delta \mathbf{W}^{(t)}$ ，利用 L-BFGS 相关过程预测下一步全局梯度变化 $\Delta \mathbf{g}_{\text{pre}}^{(t)}$ ，进而得到预测梯度 $\mathbf{g}_{\text{pre}}^{(t)}$ ；随后以预测变化的单位向量作为扰动基准^[69]。

迁移到 MCSL 时，本文将“全局梯度/聚合更新”的角色替换为“共享权重的跨轮次变化”，即用共享权重的历史差分（例如 $\Delta \mathbf{w}^{(t-1)} = \mathbf{w}^{(t-1)} - \mathbf{w}^{(t-2)}$ ）作为可观测的反馈轨迹，保持其反馈驱动的自适应机制不变：恶意客户端在每轮训练后先生成基础扰动方向，再依据上一轮扰动是否成功“推动共享权重朝恶意方向偏移且未被削弱”的反馈信号调整扰动因子（原文中为 γ ，并设定上下界以避免过小无效或过大易被识别），当反馈低于阈值时降低扰动强度以强化隐蔽性，当反馈高于阈值时提高扰动强度以增强攻击效果^[69]。此外，FedGhost 还区分“隐蔽梯度”和“牺牲梯度”以干扰检测机制：前者尽量贴近预测更新方向以降低可疑性，后者刻意偏离以制造噪声并迷惑防御^[69]。在 MCSL 中，该思想可等价为构造“隐蔽扰动”和“牺牲扰动”并作用于共享权重转发阶段，从而在不依赖数据的前提下实现持续的自适应权重投毒。

(c) PoisonedFL：多轮符号一致性扰动与幅度调度

PoisonedFL 的核心在于“多轮一致性 (multi-round consistency)”：在多个训练轮次中维持恶意更新的符号模式一致，从而避免不同轮次的攻击效应自我抵消，并提升在防御存在时的累积破坏性。其典型做法是固定一个符号向量 $\mathbf{s}$ ，并在每轮以逐轮变化的尺度对其进行放大/缩小，使得恶意更新满足“符号一致、幅度自适应”的特征。原文提出动态设置尺度因子 λ^t ，使其与上一轮聚合更新幅度 $\|\mathbf{w}^{t-1} - \mathbf{w}^{t-2}\|$ 成正比：

$$\lambda^t = c^t \cdot \|\mathbf{w}^{t-1} - \mathbf{w}^{t-2}\|, \quad (4-2)$$

并进一步通过基于假设检验的策略来调整 c^t ：若判定过去 e 轮攻击未成功（可能被过滤或削弱），则按系数 $\beta < 1$ 递减 c^t ，反之保持不变^[70]。

迁移到 MCSL 时，本文将“上一轮聚合更新”的可观测量替换为“共享权重在相邻轮次/相邻转发之间的变化幅度”，用其作为服务器对正常更新幅度的隐含预期，从而实现对 λ^t 的等价调度。具体而言，恶意客户端保持固定符号模式 $\mathbf{s}$ （对应对共享权重中被操控维度的符号一致性扰动），并依据共享权重历史变化设置扰动尺度，使得每轮注入的 $\mathbf{p}^{(t)}$ 在符号上与 $\mathbf{s}$ 一致、在幅度上与系统的正常变化幅度同量纲，从而在串行传播过程中逐步积累并降低被异常规则“简单按幅度过滤”的风险。本文实验中对 PoisonedFL 的超参数遵循其默认设置以保证公平比较。

(d) ScaleSign: 缩放投毒与符号统计保持

ScaleSign 面向基于统计特征的鲁棒聚合/检测策略，其关键目标是：在增强投毒效果的同时，使恶意更新在“整体方向相似度（如余弦相似度）”与“符号统计（正/零/负比例等）”上尽量贴近良性更新，从而绕过基于符号分布或相似度阈值的检测。该方法由“缩放攻击（scaling attack）”与“符号修改（sign modification）”两部分构成：前者通过构造缩放矩阵/系数放大关键维度以增强破坏，后者通过调整符号统计使恶意更新在统计意义上更像良性更新。原文在缩放攻击中采用振荡式搜索来确定关键缩放系数（例如对 γ 逐步增大并配合步长折半细化），直到判别函数不满足为止，并在缩放变化小于搜索精度 ω 时终止搜索^[71]；在符号修改部分，需先确定参考符号统计 (P, Z, N) ，并借鉴 Multi-Krum 思路选择与良性符号统计最接近的参考对象，然后通过对特定排序区间的分量置零或截断替换，使恶意更新的符号统计向参考统计对齐^[71]。

迁移到 MCSL 时，本文将 ScaleSign 的操控对象从“待聚合的梯度/模型更新”替换为“待转发的共享权重更新”，即恶意客户端在转发 $\mathbf{w}_{\text{out}}^{(t)}$ 前先对 $\Delta \mathbf{w}_m^{(t)}$ 或其叠加后的共享权重执行维度缩放与符号修改：一方面通过维度级缩放增强对关键权重的扰动强度；另一方面通过符号修改使得共享权重变化在符号统计与余弦相似度上与正常更新保持一致，从而实现“看起来像正常更新，但破坏性更强”的权重投毒效果。在 MCSL 的串行传递中，这类“统计上伪装”的扰动能够进一步沿队列传播并叠加，放大其对整体模型收敛与最终精度的影响。

(e) 超参数与实现一致性说明

对比攻击的迁移遵循“机制等价、参数尽量保持原设定”的原则：FedGhost 的扰动因子采用其原始的动态反馈调节策略；PoisonedFL 保持其默认关键超参数设置（如 c_0, e, β 等）以维持多轮一致性机制；ScaleSign 采用其默认缩放系数初始化与搜索精度，并保持缩放攻击与符号修改两组件的原始设定，以保证比较结果主要来源于攻击机制差异而非参数调优差异。

4.4 DASH-MSL 串行投毒攻击的有效性验证

4.4.1 标签共享与标签保护架构下的攻击表现

为系统评估所提出共享权重投毒攻击对多客户端拆分学习系统整体性能的破坏能力，本节在多种数据集与模型配置下测试攻击对模型分类性能的影响。实验覆盖两种典型拆分学习架构——Label-sharing SL 与 Label-protected SL (U-shape SL)——以及六个具有代表性的基准数据集，包括 MNIST、FMNIST、SVHN、CIFAR10、CORA

和 CORA-ML, 从而涵盖从低维灰度图像数据到高维自然图像数据以及图结构数据等不同任务场景。通过在多种任务难度与模型结构条件下开展实验, 可以全面分析攻击对系统整体训练过程与最终模型性能的影响。实验结果如表 4.3 和 4.4 所示。

本实验重点关注两个问题: 一是所提出的共享权重投毒攻击是否能够在多客户端拆分学习环境下有效削弱全局模型性能; 二是在攻击过程中引入基于参数重要性的剪枝策略后, 是否能够在保持扰动规模有限的情况下进一步增强攻击效果。通过系统比较不同扰动模式、剪枝策略及数据集条件下的实验结果, 可以分析影响攻击强度的关键因素, 并验证攻击在不同应用场景中的适用性。

从整体趋势来看, 在无攻击情况下, 各数据集上的模型均能够达到较高的分类准确率, 说明多客户端拆分学习系统在正常训练条件下具有良好的收敛性能与泛化能力。例如, 在 Label-sharing SL 架构下, LeNet-5 在 MNIST 数据集上的准确率达到 98.88%, 在 FMNIST 上为 89.45%; ResNet-9 在 SVHN 与 CIFAR10 上分别达到 95.48% 和 85.52%; 图神经网络模型在 CORA 与 CORA-ML 上也分别取得 90.12% 与 88.47% 的准确率。类似地, 在 Label-protected SL 架构下, 各数据集的基线准确率与前者保持高度一致, 例如 MNIST 为 98.95%, CIFAR10 为 84.37%, CORA-ML 为 89.04%。这些结果表明, 在无攻击情况下, 多客户端顺序训练与权重共享机制并不会显著损害模型性能, 反而能够在多数据源条件下稳定完成训练, 为后续评估攻击效果提供了可靠基线。

标签共享的拆分学习架构							
数据集 模型		MNIST LeNet-5	FMNIST LeNet-5	SVHN ResNet-9	CIFAR10 ResNet-9	CORA GCN	CORA-ML GAT
无攻击		98.88	89.45	95.48	85.52	90.12	88.47
DASH-MSL (Unit)	无剪枝	93.14	80.97	93.47	64.03	75.43	79.35
	Fisher	91.86	74.67	58.23	35.12	65.87	71.24
	Taylor	87.37	73.33	92.49	81.36	63.22	69.87
DASH-MSL (Sign)	无剪枝	97.35	79.10	86.39	35.07	72.13	77.14
	Fisher	90.72	77.2	63.22	13.03	68.76	73.92
	Taylor	94.11	78.97	54.07	27.86	70.15	76.15

表 4.3 标签共享 SL 架构下投毒攻击对系统分类性能的影响 (分类准确率, %)

当引入投毒攻击后, 各数据集的分类准确率均出现明显下降, 且下降幅度随任务复杂度显著变化, 表明攻击能够在系统层面破坏模型训练过程。在高维复杂数据集上, 这种破坏尤为明显。例如在 CIFAR10 数据集上, 采用 Sign 向量与 Fisher 剪枝策略时, ResNet-9 的准确率由 85.52% 急剧下降至 13.03%, 性能降低超过 70 个百分点; 在 Label-protected SL 架构下, 同一攻击条件下准确率也从 84.37% 降至 13.19%, 几乎完全失去分类能力。类似地, 在 SVHN 数据集上, Taylor 剪枝攻击将准确率从 95.48%

标签保护的拆分学习架构							
数据集 模型		MNIST LeNet-5	FMNIST LeNet-5	SVHN ResNet-9	CIFAR10 ResNet-9	CORA GCN	CORA-ML GAT
无攻击		98.95	91.33	95.85	84.37	90.65	89.04
DASH-MSL (Unit)	无剪枝	92.96	81.66	93.84	63.87	74.83	78.73
	Fisher	90.77	75.22	57.63	35.04	66.12	72.03
	Taylor	88.04	73.64	91.36	80.62	62.91	68.54
DASH-MSL (Sign)	无剪枝	97.3	78.86	87.06	34.84	71.94	76.98
	Fisher	91.14	76.36	62.53	13.19	69.03	74.23
	Taylor	94.49	80.07	53.52	28.03	71.25	77.56

表 4.4 标签保护 SL 架构下投毒攻击对系统分类性能的影响（分类准确率，%）

降至 54.07%，下降幅度接近 40 个百分点。这些数值表明，在复杂视觉任务中，攻击能够显著破坏模型学习到的判别边界，使模型性能接近随机猜测水平。

相比之下，在低复杂度数据集上，攻击效果相对有限。例如在 MNIST 数据集上，即使在较强攻击条件下，模型准确率仍维持在 87% 以上；在 FMNIST 上，Taylor 攻击下准确率约为 73%，虽然明显低于基线，但仍保持一定分类能力。这说明简单任务中存在较高的特征冗余，模型可以通过剩余未受扰动的权重继续完成基本判别，而复杂数据集中的决策边界更精细，对关键参数更为依赖，因此更容易受到攻击影响。图结构数据集也呈现类似趋势：在 CORA 上，Taylor 攻击将准确率降至约 63%，而在 CORA-ML 上降至约 69%，表现出中等程度的性能退化。

进一步比较两种扰动模式可以发现，Unit 与 Sign 在不同任务上的破坏机制存在差异。在简单数据集上，Unit 向量通常更有效，例如在 FMNIST 上 Unit-Fisher 攻击可将准确率降至约 74%，明显低于 Sign 向量；而在高维复杂数据集上，Sign 向量表现出更强破坏能力，如 CIFAR10 上 Sign-Fisher 将准确率压低至 13% 左右，而 Unit-Fisher 约为 35%。这说明在复杂模型中改变权重更新方向比改变权重幅值更容易破坏模型收敛路径，因为方向性扰动更可能导致梯度更新偏离原有优化轨迹，从而在后续训练中持续放大误差。

为进一步增强攻击效果并提高隐蔽性，本研究引入基于参数重要性的剪枝策略，仅对关键权重进行定向扰动。实验结果显示，相较于对所有权重进行无差别扰动的 Basic 攻击，剪枝策略在多数情况下产生更大的性能退化。例如在 CIFAR10 数据集上，Basic 攻击下准确率仍在 64% 左右，而 Fisher 剪枝可降至 35% 以下；在 SVHN 上，Basic 攻击约为 93%，而 Fisher 攻击可降至约 58%。这表明模型参数的重要性分布高度不均，对关键权重的集中扰动能够在较小扰动规模下引发更大的性能下降。在两种剪枝方法中，Taylor 方法在多数数据集上表现较为稳定，例如在 CORA-ML 上将准确率降至约 68%，而 Fisher 方法在部分场景下能够产生极端攻击效果但波动较大，

如在 CIFAR10 上达到最低准确率 13.03%。这说明不同剪枝策略对模型结构与数据分布具有不同敏感性。

此外,两种拆分学习架构在攻击条件下表现出高度一致的性能变化趋势。无论是 Label-sharing SL 还是 Label-protected SL,各数据集在攻击后的准确率下降幅度基本相近,例如 CIFAR10 在两种架构下均降至约 13%,SVHN 均降至约 54%,CORA-ML 均降至约 68% 左右。这一结果表明攻击效果主要来源于客户端之间的共享权重传递机制,而非标签信息的传输方式。由于多客户端拆分学习采用顺序训练协议,恶意客户端产生的异常权重会沿客户端队列持续传播,使后续客户端在污染权重基础上继续训练,从而逐步影响整个系统的全局模型性能。

综合来看,本节实验结果充分表明,所提出的共享权重投毒攻击能够在多种任务场景与模型结构下显著降低系统预测准确率,其破坏能力与数据集复杂度、扰动模式及剪枝策略密切相关。高维复杂任务对攻击更为敏感,方向性扰动和重要性筛选能够进一步放大攻击效果,而拆分学习架构差异对攻击强度影响有限。这些结果不仅验证了攻击在多客户端拆分学习环境中的有效性,也为后续分析攻击位置、扰动比例以及防御方法提供了实验依据。

4.4.2 与传统联邦学习投毒方法的对比分析

为验证所提出共享权重投毒攻击 (DASH-MSL) 在多客户端拆分学习环境中的相对优势,本节将其与三种具有代表性的分布式学习模型投毒攻击方法进行比较,包括 poisonFL、FedGhost 和 ScaleSign。实验分别在 Label-sharing SL 与 Label-protected SL 两种典型拆分学习架构下进行,并覆盖六个数据集与对应模型,以全面评估不同攻击方法在多任务场景中的表现差异。实验结果如表 4.5 所示。

从整体趋势来看,所有攻击方法均能够在不同程度上降低模型分类准确率,说明在多客户端顺序训练与权重共享机制下,系统普遍存在被投毒攻击破坏的风险。然而,与现有方法相比,所提出的 DASH-MSL 在多数复杂任务中表现出更强的破坏能力,尤其在高维视觉数据集上优势最为显著,其影响甚至可将模型性能降至接近随机分类水平。

首先,在 Label-sharing SL 架构下,各攻击方法在不同数据集上的表现差异明显。在 MNIST 数据集上,DASH-MSL 将准确率从无攻击时的 98.88% 降至 87.37%,性能下降约 11.5 个百分点,虽然低于 FedGhost 的 91.33% 与 poisonFL 的 94.66%,但仍明显优于 ScaleSign 的 95.12%。在 FMNIST 上,DASH-MSL 将准确率降至 73.33%,相较基线 89.45% 下降超过 16 个百分点,低于 poisonFL (82.73%) 与 ScaleSign (83.05%),但与 FedGhost (77.07%) 相比仍具有一定优势。这表明在低复杂度任务中,现有攻击方法已能够产生可观影响,而所提出方法的优势尚未完全体现,原因在于简单任务具

数据集 模型		MNIST LeNet-5	FMNIST LeNet-5	SVHN ResNet-9	CIFAR10 ResNet-9	CORA GCN	CORA-ML GAT
标签共享 拆分学习	无攻击	98.88	89.45	95.48	85.52	90.12	88.47
	poisonFL	94.66	82.73	70.52	56.74	71.33	74.62
	FedGhost	91.33	77.07	50.75	44.39	66.33	68.57
	ScaleSign	95.12	83.05	75.38	61.92	76.41	79.03
	DASH-MSL	87.37	73.33	54.07	13.03	63.22	69.87
标签保护 拆分学习	无攻击	98.95	91.33	95.85	84.37	90.65	89.04
	poisonFL	94.62	82.91	69.12	52.76	72.04	75.92
	FedGhost	91.71	77.42	51.02	43.75	66.73	68.11
	ScaleSign	95.66	82.57	74.89	61.35	75.87	78.54
	DASH-MSL	88.04	73.64	53.52	13.19	62.91	68.54

表 4.5 DASH-MSL 与迁移后的联邦投毒攻击的性能对比（分类准确率，%）

有较高特征冗余度，模型更容易通过后续训练恢复被扰动的参数。

然而，在复杂视觉任务中，DASH-MSL 的优势显著增强。例如在 CIFAR10 数据集上，DASH-MSL 将准确率从 85.52% 降至仅 13.03%，性能下降超过 72 个百分点，远低于 poisonFL (56.74%)、FedGhost (44.39%) 和 ScaleSign (61.92%)。考虑到 CIFAR10 为 10 类分类任务，随机猜测准确率约为 10%，该结果已接近随机水平，说明攻击几乎完全破坏了模型的判别能力。在 SVHN 数据集上，DASH-MSL 也将准确率降至 54.07%，相比基线 95.48% 下降超过 41 个百分点，明显低于 poisonFL (70.52%) 与 ScaleSign (75.38%)。这些结果表明，在高维复杂任务中，针对共享权重传播路径设计的攻击更容易破坏模型的深层特征表示，使得后续客户端训练难以恢复模型性能。

在图结构数据集上，DASH-MSL 同样表现出稳定的攻击能力。在 CORA 数据集上，准确率由 90.12% 降至 63.22%，低于 poisonFL (71.33%) 与 ScaleSign (76.41%)；在 CORA-ML 上降至 69.87%，与 FedGhost (68.57%) 接近，但仍明显低于其他攻击方法。这表明所提出攻击不仅适用于欧式数据任务，也能够通过扰动共享权重影响图神经网络中的消息传递与邻域聚合过程，从而在非欧式数据场景中产生显著影响。

其次，在 Label-protected SL 架构下，各方法的表现趋势与 Label-sharing SL 基本一致，进一步说明攻击效果主要来源于共享权重传递机制，而非标签信息的共享方式。例如在 CIFAR10 上，DASH-MSL 将准确率降至 13.19%，与 Label-sharing 架构下的 13.03% 几乎相同，而其他攻击方法仍保持在 40% 以上。在 SVHN 上，DASH-MSL 将准确率降至 53.52%，同样显著低于 poisonFL (69.12%) 与 ScaleSign (74.89%)。此外，在 MNIST 与 FMNIST 上，两种架构下的准确率差异均较小，说明标签保护机制并未显著削弱攻击传播能力，权重共享阶段仍然是系统最关键的脆弱环节。

从攻击机制角度分析，DASH-MSL 之所以能够在复杂任务中取得更强效果，是因为其直接针对共享权重进行定向扰动，并利用多客户端顺序训练过程实现攻击扩散。相比之下，poisonFL 与 FedGhost 等方法最初针对联邦学习的并行聚合框架设计，在迁移到拆分学习后缺乏针对权重顺序传递机制的优化，因此难以在系统层面产生同等强度的影响。ScaleSign 虽然通过方向性扰动增强攻击效果，但仍主要作用于单次更新，缺乏跨客户端传播的累积机制，导致整体破坏能力受限。

此外，不同数据复杂度对攻击差异具有明显放大作用。在简单数据集（MNIST、FMNIST）上，各攻击方法之间的性能差距相对较小，因为模型参数冗余度较高，部分扰动可以被后续训练修复；而在复杂数据集（CIFAR10、SVHN）上，差距显著扩大，DASH-MSL 能够将模型性能降至接近随机水平，而其他方法仍保持一定分类能力。这表明高维任务中模型对关键权重依赖更强，一旦共享权重被污染，模型决策边界将受到不可逆破坏。

综合来看，对比实验结果充分表明，所提出的 DASH-MSL 在多客户端拆分学习环境中具有显著优势，尤其在复杂视觉任务与图数据任务中能够产生更严重的性能退化。该结果验证了第三章提出攻击设计的有效性，也说明在顺序权重共享框架下，针对权重传播路径的攻击比传统基于梯度或数据的攻击更具系统级破坏能力，为后续防御机制的设计提供了重要依据。

4.5 DASH-MSL 攻击持续性与关键影响因素分析

4.5.1 恶意客户端队列位置对攻击效果的影响

在多客户端拆分学习（MCSL）框架中，客户端按照固定顺序依次参与模型训练并共享权重，模型参数在客户端之间形成单向传递链路。因此，恶意客户端在队列中的相对位置将直接决定其注入扰动在系统中的传播路径、衰减程度以及最终对全局模型的影响范围。为系统分析攻击者位置对投毒攻击效果的影响，本节通过改变恶意客户端在队列中的位置，测量不同位置下最终模型性能的变化情况，从而揭示顺序训练机制下攻击传播的内在规律。

实验结果表明，攻击者位置对攻击效果具有显著影响，并呈现出一致的总体趋势：随着恶意客户端位置由队列前端向后移动，模型最终准确率整体呈下降趋势，即攻击破坏能力逐渐增强。尽管在个别位置存在轻微波动，但所有数据集与攻击策略均表现出相同的宏观规律，说明该现象并非由具体模型结构或数据分布造成，而是源于 MCSL 串行训练与权重共享机制的固有属性。例如，在 CIFAR-10 的 Sign 向量下，当攻击者位于队列前端（Client ID=1 附近）时，模型准确率仍维持在较高水平：Basic 攻击约为 80%，Taylor 与 Fisher 约在 60%–70% 区间；但当攻击者移动至队列末

端 (Client ID=10) 时, Taylor 与 Fisher 可分别下降至约 25% 和 28%, 而 Basic 也降至约 40%。类似地, 在 SVHN 数据集上, Taylor 在队列后端可将准确率压低至约 50%, 而在队列前部则通常高于 60%。这些具体数值表明, 攻击位置越靠近训练流程末端, 其扰动越难被后续训练修复, 从而对全局模型产生更直接和持久的影响。




图 4.1 CORA 与 CORA-ML 数据集下不同队列位置的攻击效果

从机制角度分析, 当恶意客户端位于队列前部时, 其注入的异常权重将在后续多个客户端的训练过程中被反复更新。由于后续客户端基于各自本地数据执行正常梯度下降, 这些更新在一定程度上能够将模型参数重新拉回到合理区域, 从而削弱甚至部分抵消先前的恶意扰动。因此, 在队列前端位置, 攻击虽然能够对后续客户端的训练过程造成干扰, 但其影响会随着训练轮次的推进逐渐被稀释, 最终对模型整体性能的破坏相对有限。这一点在图中表现为前端位置曲线整体较为平缓, 例如在 CIFAR-10 的 Unit 向量下, Taylor 与 Fisher 在 Client ID=1–3 区间内均保持在 65% 左右, 仅呈缓慢下降趋势。

相比之下, 当攻击者位于队列后部时, 其投毒权重在被注入后几乎不会再经过充分的正常训练修复, 甚至可能直接成为该轮训练的最终共享权重。由于缺乏后续客

客户端的梯度更新来纠正异常参数，这些扰动将以较高强度保留并累积至全局模型中，从而导致模型性能出现显著下降。这种现象在实验结果中表现为尾部位置处准确率的明显下滑，尤其在最后若干客户端位置处下降最为剧烈。例如在 CIFAR-10 的 Sign 向量中，Taylor 曲线在 Client ID=8 之后出现陡峭下降，从约 50% 快速跌至 30% 以下；在 SVHN 的 Unit 向量中，Fisher 在尾部位置可从约 80% 降至 55% 左右，明显低于前端位置的表现，表明攻击扰动在系统中实现了最大程度的保留与放大。

进一步观察不同攻击策略的表现可以发现，基于参数重要性筛选的 Taylor 与 Fisher 攻击在绝大多数位置均优于无剪枝的 Basic 攻击，且这种优势在队列后部位置尤为明显。例如在 CIFAR-10 的 Sign 向量下，尾部位置时 Taylor 与 Fisher 可将准确率压低至约 25%–30%，而 Basic 仍保持在约 40% 左右；在 SVHN 的 Unit 向量下，Fisher 在尾部位置约为 55%，而 Basic 与 Taylor 仍在 80% 左右。这说明针对关键权重的定向扰动能够更有效地破坏模型的核心表示能力，使得即使存在少量后续训练步骤也难以恢复模型性能。结合第三章提出的攻击机制，可以认为剪枝策略通过识别对损失函数最敏感的参数，使攻击集中作用于模型的关键路径，从而显著增强了扰动在顺序传播过程中的破坏性和稳定性。




图 4.2 SVHN 与 CIFAR-10 数据集下不同队列位置的攻击效果

此外,实验结果还表明数据复杂度对位置敏感性具有放大作用。高维视觉数据集在不同位置下表现出更明显的性能下降幅度,尤其在攻击位于队列末端时,准确率出现近似“断崖式”的下降。例如 CIFAR-10 的 Sign 向量可从前端约 70%–80% 区间骤降至尾部不足 30%;而图结构数据集 (CORA、CORA-ML) 虽同样呈下降趋势,但整体变化更为平缓,例如 CORA 的 Unit 向量下 Taylor 与 Fisher 多数位置维持在 65%–70% 区间,尾部下降至约 63% 左右。这表明高维任务中的深层网络依赖于复杂特征表示,一旦关键权重在训练后期被破坏,将直接影响最终决策边界;而图数据任务对局部参数扰动具有一定鲁棒性,因此其准确率下降趋势相对平缓,但仍保持后端攻击更强的总体规律。

从传播角度来看,该现象可以理解作为一种“攻击有效传播长度”问题。攻击者位于队列前部时,其扰动需要经过多个客户端的正常训练阶段才能到达最终模型,这一过程中扰动会不断被削弱;而位于队列后部时,扰动传播路径极短,几乎直接作用于最终模型,因此能够最大化保留攻击强度。换言之,客户端队列顺序本身构成了一条信息传递通道,其结构决定了攻击影响在系统中的扩散模式和衰减速度。

综合上述分析可以得出,恶意客户端在队列中的位置是影响投毒攻击效果的关键因素。队列后部位置能够显著增强攻击扰动在系统中的累积效应,从而导致更严重的模型性能下降;而队列前部位置由于存在后续训练修复过程,其攻击影响相对有限。该结果揭示了多客户端拆分学习系统在串行训练机制下的结构性安全隐患,即权重共享顺序不仅决定训练流程,也可能成为攻击传播的重要载体。一旦攻击者能够控制队列后端位置,其对系统的破坏能力将被显著放大,从而对整体模型安全构成更严重威胁。

4.5.2 扰动比例对攻击效果的影响

在共享权重投毒攻击中,扰动比例 α 控制着被修改参数的数量,是影响攻击强度的重要因素。较小的 α 可能不足以破坏模型结构,而过大的 α 则可能引入明显异常,降低攻击隐蔽性甚至影响攻击稳定性。为系统分析扰动规模对攻击效果的影响,本节在固定其他攻击参数的情况下,改变扰动比例 α (取值范围为 0.1 至 0.9),评估不同扰动规模下模型最终分类性能的变化情况。实验结果如图 4.3(a)–图 4.4(d) 所示,其中横轴表示扰动比例,纵轴表示模型准确率。

从整体趋势来看,扰动比例与攻击效果之间并非简单的单调关系,而呈现出明显的任务依赖性和非线性特征。在多数复杂任务中,随着 α 的增大,模型准确率整体呈下降趋势,即攻击强度逐渐增强;但在部分简单任务中,当 α 过大时,攻击效果反而趋于稳定甚至略有减弱,表明过度扰动可能破坏攻击的有效性。这一现象说明,扰动规模不仅决定攻击强度,还影响扰动在模型参数空间中的分布方式和传播路径。




图 4.3 MNIST 与 FMNIST 数据集下不同扰动比例的攻击效果

在低复杂度数据集上，模型对扰动比例具有较强鲁棒性。例如在 MNIST 数据集上，无论 Unit 还是 Sign 向量，模型准确率均保持在较高水平。在 Unit 向量下，Taylor 攻击的准确率始终位于约 84%–88% 区间，而 Fisher 攻击约为 90%–92%，即使 α 增大至 0.9，模型性能仍未出现明显崩塌。在 Sign 向量下亦呈现类似趋势，Taylor 曲线在 $\alpha = 0.1$ 时约为 94%，在 $\alpha = 0.5$ 时降至约 85%，随后趋于稳定。这表明在简单图像任务中，模型具有较高参数冗余度，即使较大比例的权重受到扰动，仍可通过剩余有效参数维持判别能力。

相比之下，在中等复杂度任务（如 FMNIST）中，扰动比例对攻击效果的影响更加明显。在 Unit 向量下，Taylor 攻击的准确率从 $\alpha = 0.1$ 时的约 67% 提升至 $\alpha = 0.7$ 时的约 72%，随后在 $\alpha = 0.9$ 时回落至约 66%，呈现先升后降的非单调变化；Fisher 攻击则从约 69% 上升至约 79%，表明适度增加扰动比例能够增强攻击效果，但过大扰动可能导致攻击稳定性下降。在 Sign 向量下，Taylor 在 $\alpha = 0.1$ 时约为 82%，在 $\alpha = 0.3$ 时下降至约 76%，随后在较大 α 区间恢复至约 80%，显示方向性扰动对模型收敛路径的影响更加复杂。

在高维复杂数据集上, 扰动比例对攻击效果的放大作用最为显著。例如在 CIFAR-10 的 Sign 向量下, Taylor 攻击在 $\alpha = 0.1$ 时准确率约为 18%, 随着 α 增大至 0.5 时降至约 16%, 在 $\alpha = 0.7$ 时略有回升至约 20%, 随后再次下降至约 17%, 整体保持在极低水平; Fisher 攻击则稳定在约 12%–15% 区间, 远低于无剪枝攻击的约 35% 左右。类似地, 在 SVHN 的 Unit 向量下, Fisher 攻击从 $\alpha = 0.1$ 时的约 54% 波动至 $\alpha = 0.7$ 时约 60%, 随后下降至约 51%, 表明在复杂视觉任务中, 即使中等规模扰动也能显著破坏模型性能。




图 4.4 SVHN 与 CIFAR-10 数据集下不同扰动比例的攻击效果

进一步比较两种扰动模式可以发现, Unit 与 Sign 在不同 α 区间具有不同的攻击特性。Unit 向量主要改变权重幅值, 对模型稳定性影响较为平滑, 因此曲线变化相对缓和; Sign 向量则通过改变梯度方向直接影响优化路径, 在高维任务中更容易造成剧烈性能下降。例如在 CIFAR-10 上, Sign 向量下准确率整体远低于 Unit 向量, 说明方向性扰动更容易破坏深层特征表示。

此外, 剪枝策略在不同扰动比例下同样表现出明显差异。Taylor 方法在多数任务中表现较为稳定, 准确率随 α 变化波动较小; 而 Fisher 方法在部分数据集上能够产

生更极端的攻击效果，例如在 CIFAR-10 的 Sign 向量中始终保持最低准确率，但在简单任务上优势不明显。这说明不同重要性评估方法对扰动规模的敏感性不同，从而影响攻击在参数空间中的有效分布。

从机制角度来看，扰动比例决定了攻击在模型中的“覆盖范围”。较小 α 仅影响少量关键参数，可能不足以改变模型整体决策结构；适中 α 能够在关键路径上形成连续扰动，从而显著破坏模型收敛；而过大 α 则可能同时改变大量非关键参数，使扰动呈随机分布，反而削弱对关键表示的集中破坏效果。这种“适度扰动最有效”的现象解释了部分曲线出现非单调变化的原因。

综合上述分析可以得出，扰动比例是影响共享权重投毒攻击效果的重要因素，其作用具有明显的任务依赖性和非线性特征。适度增加扰动比例能够显著增强攻击效果，但过大扰动并不一定带来额外收益。该结果表明，在设计投毒攻击时需要在攻击强度与扰动规模之间进行权衡，同时也为后续防御策略提供了参考，即通过限制参数更新幅度或检测异常更新比例，可能有效缓解此类攻击带来的影响。

4.5.3 不同攻击策略对攻击效果的影响

为进一步评估共享权重投毒攻击在更复杂对抗场景下的实际破坏能力，本节在前述“单一攻击者 + 单一攻击类型”的基础上，进一步引入多攻击者协同、攻击位置变化、攻击类型切换以及剪枝策略组合等因素，系统比较不同攻击策略对最终模型性能的影响。与 4.4–4.6 主要讨论单变量（整体有效性、队列位置、扰动比例）不同，本节关注“策略层面”的组合效应，即当攻击者在同一轮或跨轮次采用多种配置时，攻击效果是否会出现叠加增强，抑或产生相互干扰导致效果下降。根据扰动方式与参数选择机制的不同，实验共设计九种攻击策略，分为三类：基础扰动策略（Strategy 1–3）、扰动模式组合策略（Strategy 4–6）以及重要性剪枝组合策略（Strategy 7–9）。其中，Strategy 1–3 分别对应 Basic、Fisher 与 Taylor 单一策略；Strategy 4–6 通过结合 Unit 与 Sign 两种扰动模式形成组合攻击（U+S）；Strategy 7–9 则结合 Fisher 与 Taylor 两种重要性评估方法（F+T），以扩大关键参数覆盖范围。通过系统比较单一策略与组合策略在不同任务上的表现，可以揭示攻击设计中各组成模块对整体破坏能力的贡献，并验证多策略协同是否能够进一步增强攻击效果。实验结果如图 4.5(a)–图 4.6(d) 所示。

(a) 策略集合定义

为覆盖代表性组合，本节共设计九种攻击策略（策略 1–策略 9），其差异体现在攻击者数量、队列位置、攻击类型（Unit/Sign）、扰动比例 α 以及是否结合剪枝策略（Fisher/Taylor）等要素。具体定义如下。

策略 1: 单一攻击者位于队列末端 (client ID=9), 采用单一攻击类型 (Unit 或 Sign), 扰动比例 $\alpha = 30\%$ 。该策略与前述单攻击者实验设置保持一致, 用于刻画“孤立攻击者在末端位置”对全局模型的直接破坏效果。

策略 2: 两个攻击者位于队列中部 (client ID=4 和 6), 扰动比例 $\alpha = 15\%$, 用于模拟“队列中段协同攻击者”在较温和扰动规模下是否能够产生累积效应。

策略 3: 两个攻击者分别位于队列首尾 (client ID=2 和 9), 扰动比例 $\alpha = 15\%$, 用于评估“首尾夹击”式分布在空间位置上更分散的攻击者是否能够产生更强的协同破坏。

在上述三种策略中, 攻击类型保持单一 (要么全 Unit, 要么全 Sign), 主要考察攻击者数量与位置分布对攻击效果的影响。

进一步地, 为考察“攻击类型组合/切换”是否能增强破坏, 本节引入 Unit 与 Sign 的交替使用:

策略 4: 单一攻击者位于队列末端 (client ID=9), 在同一轮训练中交替采用 Unit 与 Sign 两种攻击类型, 扰动比例 $\alpha = 30\%$, 用于验证“单攻击者在末端通过交替攻击类型”是否能够增强效果。

策略 5: 两个攻击者位于队列中部 (client ID=4 和 7), 在同一轮训练中交替采用 Unit 与 Sign, 扰动比例 $\alpha = 15\%$, 用于评估“多攻击者 + 交替类型”在中段位置是否呈现更强累积。

策略 6: 两个攻击者位于队列首尾 (client ID=2 和 9), 交替采用 Unit 与 Sign, 扰动比例 $\alpha = 15\%$, 用于评估“首尾夹击 + 交替类型”的综合效果。

最后, 为考察“剪枝策略组合”在综合策略场景中是否仍能带来增益 (或反而引发副作用), 本节引入同时使用 Fisher 与 Taylor 的组合:

策略 7: 单一攻击者位于队列末端 (client ID=9), 同时结合两种攻击 (Unit/Sign) 与两种剪枝方法 (Taylor/Fisher), 扰动比例 $\alpha = 30\%$ 。该策略旨在最大化策略多样性, 观察“多模块融合”是否能进一步增强破坏性。

策略 8: 两个攻击者位于队列中部 (client ID=4 和 7), 交替采用 Unit/Sign 并结合剪枝组合 (Taylor/Fisher), 扰动比例 $\alpha = 15\%$, 用于评估“多攻击者 + 多模块融合”在中段位置的综合影响。

策略 9: 两个攻击者位于队列首尾 (client ID=2 和 9), 交替采用 Unit/Sign 并结合剪枝组合 (Taylor/Fisher), 扰动比例 $\alpha = 15\%$, 用于评估“首尾夹击 + 多模块融合”是否能在传播路径与关键参数破坏两个层面形成叠加。

上述九种策略覆盖了从“单一策略”到“多因素融合”的不同复杂度配置, 使得本节能够更接近真实对抗场景: 攻击者可能不再局限于单点、单类型、单参数, 而是通过协同与策略切换不断尝试最大化系统级破坏效果。




图 4.5 MNIST 与 FMNIST 数据集下不同攻击策略的攻击效果

从整体趋势来看,所有策略均能够在不同程度上降低模型分类准确率,表明共享权重投毒攻击具有较强的通用性。然而,不同策略之间的攻击强度差异显著,其中基于参数重要性的剪枝策略普遍优于基础扰动,而组合策略在部分任务中能够产生更强的破坏效果。这说明攻击效果不仅取决于扰动幅度,还与扰动在模型参数空间中的分布方式和关键路径覆盖程度密切相关。

首先,在单一策略比较中,Strategy 1–3 展示了不同参数选择方法对攻击强度的影响。以 MNIST 数据集为例,在 Unit 向量下,Strategy 1 (Basic) 将准确率从基线约 99% 降至约 93%,Strategy 2 (Fisher) 约为 92%,Strategy 3 (Taylor) 进一步降至约 87%,表明针对关键参数的定向扰动能够产生更显著的性能退化。在 FMNIST 数据集上,这种差异更加明显: Basic 攻击约为 80%,Fisher 约为 74%,Taylor 约为 73%,说明在中等复杂度任务中,重要性筛选对攻击效果具有放大作用。

其次,Strategy 4–6 通过组合 Unit 与 Sign 两种扰动模式,在参数幅值与方向两个维度同时施加干扰,从而增强攻击效果。在 MNIST 数据集上,U+S 组合策略能够将准确率稳定控制在约 97% 左右,略低于单一策略;而在 FMNIST 数据集上,该组合策略将准确率降至约 80% 左右,相较于单一扰动模式表现出更强破坏能力。这表明

在复杂任务中，同时改变权重幅值与方向能够更有效地扰乱模型优化路径，使模型在后续训练中难以恢复。

进一步地，Strategy 7-9 结合 Fisher 与 Taylor 两种重要性评估方法，在参数选择阶段扩大关键权重覆盖范围，从而形成更加全面的攻击。在 MNIST 数据集上，F+T 组合策略将准确率降至约 96%，优于单一剪枝方法；在 FMNIST 数据集上，该策略将准确率降至约 78%，同样低于 Strategy 1-3 的结果。这说明不同重要性评估方法在识别关键参数时具有互补性，其组合能够覆盖更多高敏感区域，从而增强攻击效果。




图 4.6 MNIST 与 FMNIST 数据集下组合攻击策略的攻击效果

从机制角度分析，策略差异主要体现在攻击在参数空间中的作用方式。基础策略对所有权重进行均匀扰动，难以集中破坏模型关键表示；剪枝策略通过选择高重要性参数，使攻击集中作用于模型决策路径；而组合策略则在多个维度同时施加干扰，形成更复杂的扰动结构。尤其是在多客户端拆分学习环境中，权重在客户端之间顺序传播，早期注入的扰动会被后续训练部分修复，而集中攻击关键参数或多个关键路径能够提高扰动在传播过程中的保留程度，从而放大系统层面的影响。

此外，不同数据复杂度下策略差异同样存在放大效应。在简单数据集（如 MNIST）

上, 各策略之间性能差距相对较小, 因为模型具有较高冗余度; 而在复杂数据集 (如 FMNIST) 上, 不同策略的攻击效果差异更加明显, 组合策略能够产生更显著的性能下降。这表明高维任务中模型对关键参数依赖更强, 因此策略设计对攻击效果的影响更加敏感。

综合来看, 本节实验结果表明, 攻击策略的设计对共享权重投毒攻击的性能具有决定性影响。基础扰动能够产生一定效果, 但针对关键权重的剪枝策略能够显著增强攻击强度, 而多策略组合在复杂任务中能够进一步扩大破坏范围。该结果不仅验证了第三章提出的攻击设计思想, 也说明在多客户端拆分学习环境中, 通过合理组合不同攻击模块可以实现更高效且隐蔽的模型破坏, 为后续研究防御方法提供了重要参考。

4.6 防御实验

为验证所提出防御机制在多客户端拆分学习环境中的有效性, 本节在最强攻击配置下评估防御策略对模型性能的恢复能力。具体而言, 首先选择各数据集上破坏效果最显著的攻击结果作为“最佳攻击”(Best Attack), 然后在此基础上分别应用基于 Fisher 信息与 Taylor 一阶近似的异常权重检测与修复方法, 比较防御前后模型分类准确率的变化情况。实验结果如表 4.6 所示。

数据集	无攻击	最优攻击	有防御时 (Fisher)	有防御时 (Taylor)
MNIST	98.88	87.37	94.83	94.95
FMNIST	89.45	73.33	79.90	77.28
SVHN	95.48	54.07	87.65	85.89
CIFAR10	85.52	13.03	69.36	69.05
CORA	90.12	63.22	80.33	81.50
CORA-ML	88.47	69.87	77.35	78.20

表 4.6 防御机制对投毒攻击的缓解效果验证 (分类准确率, %)

从整体结果来看, 所提出的防御机制能够在所有数据集上显著恢复模型性能, 说明通过识别并修正异常共享权重, 可以有效抑制投毒攻击在系统中的传播影响。在无攻击条件下, 各模型在不同数据集上均取得较高准确率, 例如 MNIST 与 FMNIST 分别达到 98.88% 和 89.45%, SVHN 与 CIFAR10 分别为 95.48% 和 85.52%, 图数据集 CORA 与 CORA-ML 也达到 90.12% 与 88.47%。这些结果表明多客户端拆分学习系统在正常情况下具有良好的收敛性能。

在引入最强攻击后, 模型性能出现显著下降。例如在 CIFAR10 数据集上, 准确率从 85.52% 急剧下降至 13.03%, 接近随机猜测水平; 在 SVHN 上由 95.48% 降至 54.07%; 在 FMNIST 上由 89.45% 降至 73.33%。这些结果验证了攻击对共享权重传播

机制的破坏能力。然而,在应用防御机制后,各数据集准确率均明显回升。在 CIFAR10 上, Fisher 防御将准确率恢复至 69.36%, Taylor 防御为 69.05%, 性能恢复超过 55 个百分点; 在 SVHN 上恢复至 87.65% 与 85.89%, 接近无攻击水平; 在 MNIST 上恢复至约 95%, 仅比基线低约 4 个百分点。说明防御策略能够有效修复被污染的关键权重, 使模型重新获得较好的判别能力。

在图结构数据集上, 防御同样表现出稳定效果。例如在 CORA 数据集上, 攻击后准确率降至 63.22%, 应用 Fisher 与 Taylor 防御后分别恢复至 80.33% 和 81.50%; 在 CORA-ML 上由 69.87% 恢复至约 77%–78%。这一结果表明所提出方法不仅适用于欧式数据任务, 也能够图神经网络场景下检测并修复异常参数, 缓解攻击对邻域聚合与特征传播的影响。

进一步比较两种防御策略可以发现, Fisher 与 Taylor 方法在多数数据集上均表现出相似的恢复能力, 但在部分任务中存在细微差异。例如在 MNIST 上 Taylor 防御略优于 Fisher, 而在 FMNIST 与 SVHN 上 Fisher 防御恢复效果稍强。这说明不同重要性评估方法对异常权重的识别能力存在差异: Fisher 更侧重于参数对整体损失函数的统计贡献, 而 Taylor 更强调局部梯度变化对性能的影响, 因此在不同模型结构与数据分布下表现不同。

从机制角度分析, 防御能够取得显著效果的原因在于多客户端拆分学习中攻击主要通过共享权重传播。一旦在权重更新前识别出异常参数并进行修复, 后续客户端训练将基于相对干净的权重继续进行, 从而阻断攻击扩散路径。与联邦学习中依赖鲁棒聚合的防御方法不同, 该方法直接针对权重传递阶段进行干预, 更符合 MCSL 的串行训练特性。

此外, 防御后的模型性能虽然显著恢复, 但仍略低于无攻击水平, 尤其在 CIFAR10 等高复杂度数据集上差距较为明显。这表明攻击对模型表示能力仍可能造成不完全恢复的损伤, 说明在复杂任务中需要结合更强的鲁棒训练或多轮修复机制以进一步提升防御效果。

综合来看, 本节实验结果表明, 所提出的基于异常权重检测与历史恢复的防御机制能够在多客户端拆分学习环境中有效缓解共享权重投毒攻击带来的性能下降, 且在不同任务与模型结构下均具有良好的泛化能力。该结果为构建安全可靠的 MCSL 系统提供了重要支撑, 也为后续研究更强鲁棒防御策略奠定了基础。

4.7 本章小结

本章围绕多客户端拆分学习 (MCSL) 环境下共享权重投毒攻击的有效性与影响机制展开了系统实验分析。首先, 在实验环境与参数设置的基础上, 对所提出攻击在不同数据集、模型结构及拆分学习架构中的表现进行了全面评估。实验结果表明, 所

提出的 DASH-MSL 攻击能够显著降低模型分类性能，尤其在高维复杂任务中可将模型准确率降至接近随机水平，验证了攻击在多客户端顺序训练与权重共享机制下的系统级破坏能力。

随后，本章从多个关键因素出发分析了攻击效果的影响机制。通过改变恶意客户端在队列中的位置，发现攻击效果随攻击者位置向队列后端移动而显著增强，说明顺序权重传递机制会放大后端攻击的累积影响；通过调整扰动比例，揭示了攻击强度与扰动规模之间的非线性关系，即适度扰动即可产生显著效果，而过大扰动可能因训练过程修复而削弱攻击能力；通过比较不同攻击策略，进一步说明攻击效果不仅取决于扰动幅度，还与攻击者数量、位置分布及策略组合方式密切相关，其中末端攻击与首尾协同攻击在多数场景下表现出更稳定的破坏能力。

在对比实验中，将所提出攻击与三种代表性的联邦学习模型投毒方法进行迁移比较，结果表明传统基于并行聚合设计的攻击在 MCSL 环境中效果有限，而针对共享权重传播路径设计的 DASH-MSL 在复杂视觉任务与图数据任务中均表现出显著优势，验证了攻击设计对分布式学习范式差异的适应性。进一步的防御实验显示，基于异常权重检测与修复的防御机制能够在多数任务中有效恢复模型性能，说明通过干预权重共享阶段可以在一定程度上缓解攻击影响，但在高复杂度数据集上仍存在残余损伤，表明系统安全性仍有提升空间。

综合上述实验结果，可以得出以下结论：多客户端拆分学习在串行训练与共享权重机制下存在结构性安全隐患，攻击者可通过篡改共享权重在客户端之间传播并逐步累积，从而对全局模型造成严重影响；攻击效果受攻击者位置、扰动规模与策略配置等因素共同作用，其中针对关键传播路径的攻击最具威胁；针对权重传递阶段的防御方法能够有效抑制攻击扩散，但仍需进一步研究更鲁棒的保护机制。本章实验不仅验证了第三章所提出攻击与防御方案的有效性，也为后续构建安全可靠的多客户端拆分学习系统提供了重要参考。

第五章 总结与展望

5.1 工作总结

本文针对多客户端拆分学习中因串行训练与权重共享机制带来的投毒攻击风险展开系统性研究。现有拆分学习安全研究多关注客户端与服务器之间的中间激活、梯度以及标签信息泄露问题，对权重在客户端间顺序传递所引发的传播式投毒威胁缺乏深入分析与专门的攻防方法。针对这一不足，本文按照系统建模、攻击设计、防御构建、实验验证的完整技术路线，完成了多客户端拆分学习环境下共享权重投毒攻击与防御方法的研究。

在系统分析与建模方面，本文首先梳理了多客户端拆分学习的运行机制，明确了串行训练、权重顺序传递与共享的核心特征，指出共享权重是实现多方协同训练的关键，同时也成为恶意扰动跨客户端扩散的主要载体。在此基础上，本文建立了对应的系统模型与威胁模型，明确了攻击者能力、攻击位置与攻击目标，为后续攻击与防御方法的提出奠定了基础。

在攻击方法研究方面，本文提出了面向共享权重传播链路的投毒攻击方法 DASH-MSL。该方法结合参数敏感性分析，采用 Fisher 信息与一阶 Taylor 近似对权重重要性进行评估，筛选出对模型性能影响显著的关键参数，并在有限扰动预算下构造定向、可控的权重扰动。同时，本文设计了对应的扰动构造策略与攻击优化方式，使恶意扰动能够在客户端队列中持续传播并逐步放大影响，最终实现对全局模型性能的有效破坏。该攻击充分利用多客户端拆分学习的结构特点，区别于传统联邦学习与单客户端拆分学习中的攻击方式。

在防御机制研究方面，针对多客户端拆分学习缺少并行聚合冗余、传统鲁棒防御难以直接迁移的问题，本文提出了基于异常检测与历史权重恢复的防御机制。该机制通过对共享权重更新过程进行稳健统计分析，识别关键参数中的异常变化，并利用历史权重对异常参数进行修复，从而在不改变原有串行训练架构的前提下，抑制投毒扰动在客户端之间的进一步扩散，提升系统在训练过程中的安全性。

在实验验证与分析方面，本文在标签共享与标签保护两类典型拆分学习架构上，分别使用图像数据集与图数据集开展了大量对比实验。实验结果验证了 DASH-MSL 能够显著降低模型分类性能，在复杂视觉任务中破坏能力尤为突出，且效果优于多种迁移自联邦学习的投毒攻击方法。同时，实验分析了恶意客户端位置、扰动比例、攻击策略等因素对攻击效果的影响，揭示了权重传播链路对攻击效果的放大规律。防御实验结果表明，本文提出的防御机制能够有效缓解投毒攻击带来的性能下降，在不同

任务与模型结构下均具有较好的适用性。

总体而言，本文系统研究了多客户端拆分学习中由权重共享带来的投毒攻击问题，提出了场景专用的攻击与防御方法，完善了该场景下的安全研究体系，为多客户端拆分学习的安全部署与实际应用提供了理论支撑与技术参考。

5.2 未来展望

尽管本文围绕多客户端拆分学习中的共享权重投毒攻击与防御问题开展了较为系统的研究，并取得了一定成果，但从更广泛的研究与应用视角来看，相关问题仍有进一步深入探索的空间。未来可从以下几个方面继续展开研究。

首先，可进一步完善多客户端拆分学习场景下攻击模型的研究。本文主要关注单一恶意客户端在共享权重传递链路中的投毒行为，并重点分析其对系统整体分类性能的影响。然而在实际部署环境中，攻击者能力可能更加复杂。例如，多个恶意客户端可能分布在训练队列的不同位置，并通过协同方式实施分阶段攻击，使扰动在不同轮次、不同客户端之间呈现更强的隐蔽性和累积性。又如，攻击者可能不仅希望降低整体精度，还可能试图诱导模型在特定类别、特定样本模式或特定触发条件下产生目标错误行为，从而形成更具针对性的后门式攻击。因此，未来可以进一步研究多攻击者协同场景、隐蔽性更强的长期持续性攻击，以及面向特定任务目标的定向攻击机制，以更全面地刻画多客户端拆分学习中的安全威胁边界。

其次，可进一步加强共享权重投毒攻击的理论分析。本文目前主要从参数重要性、攻击传播过程和实验现象三个层面论证方法有效性，但对于扰动在共享权重链路中为何能够持续传播、在何种条件下更容易被后续训练放大、以及攻击强度与系统结构之间的定量关系，仍有进一步理论化分析的空间。未来可以结合优化理论、动态系统分析或表示学习分析方法，对多客户端拆分学习中共享权重的演化规律进行更严格建模，进一步揭示恶意扰动在串行训练协议下的传播机理与影响边界。这不仅有助于提高攻击分析的解释性，也能够为防御策略的设计提供更稳固的理论支撑。

再次，可继续提升防御机制的自适应性与鲁棒性。本文提出的防御方法主要基于关键参数异常检测与历史权重恢复，其核心思想是在共享权重继续传递之前识别并修复可疑更新。该方法在当前实验设置下取得了较好的防御效果，但在面对更隐蔽、更复杂或更高强度的攻击时，仍可能存在检测灵敏度与误报控制之间的权衡问题。未来可进一步研究自适应阈值选择、更加细粒度的参数异常建模以及结合模型训练阶段信息的动态防御机制。例如，可以根据训练轮次、参数层次结构和近期权重变化趋势动态调整检测范围与判定标准，使防御方法能够在不同训练阶段保持更好的稳定性与适应性；也可以结合轻量化表示分析或局部验证集反馈，对可疑权重进行多维度校验，以进一步提升防御效果。

此外,未来还可将研究范围扩展到更加复杂和更贴近真实应用的系统环境。本文实验主要基于典型数据集和标准模型结构开展,虽然能够较好验证所提方法的有效性,但与实际部署环境相比仍相对理想化。未来可进一步考虑客户端之间数据分布高度异构、模型切分位置动态变化、通信链路不稳定、客户端上线时间不一致以及算力资源差异显著等复杂条件。在这些更真实的系统环境中,攻击传播规律与防御方法表现可能与当前实验结果存在差异。特别是在医疗、金融、工业互联网等高敏感场景中,不同参与方往往具有不同的数据规模、不同的资源条件和不同的安全约束,这些因素都可能影响共享权重投毒攻击的实施难度与传播效果。因此,在更加复杂的系统配置下开展评估,将有助于提升研究成果的工程适用性与实际参考价值。

进一步地,未来还可以从模型内部行为层面对共享权重投毒攻击进行更深入研究。本文主要通过最终分类准确率来衡量攻击效果,但攻击对模型中间特征表示、类别分布结构、决策边界形态以及模型泛化能力的具体影响仍有待深入分析。未来可结合可解释性分析、特征空间可视化和鲁棒性评估等工具,从模型内部表征变化的角度研究恶意扰动如何影响后续客户端训练过程,以及为何某些关键参数位置在攻击中具有更强破坏性。通过这些分析,可以更深入地理解共享权重投毒攻击的作用机理,并为设计更精准的参数筛选方法和更具针对性的防御策略提供支持。

最后,可考虑将共享权重安全防护与其他安全增强技术进行融合,以构建更完整的多层次防护体系。多客户端拆分学习在真实部署中面临的不仅是投毒攻击问题,还可能涉及参与方身份可信性、训练过程可审计性、参数传输完整性以及隐私保护强度等多个维度的挑战。未来可以探索将本文提出的异常检测与历史恢复机制,与可信执行环境、安全多方计算、区块链审计、差分隐私或完整性校验机制相结合,从而在保障训练安全的同时兼顾系统可验证性与隐私保护能力。通过不同安全技术的协同设计,有望进一步提升多客户端拆分学习系统在复杂场景下的整体安全性与可部署性。

总体而言,多客户端拆分学习作为一种适用于资源受限数据持有方的重要分布式训练范式,具有广阔的应用前景,但其安全问题仍处于持续发展和不断深化的研究阶段。随着参与主体数量增加、应用环境复杂化以及攻击者能力增强,共享权重链路上的安全风险将更加突出。未来仍需围绕攻击机理建模、防御方法优化、理论分析深化与实际部署验证等方面持续开展研究,以推动构建更加安全、可靠且可扩展的多客户端拆分学习系统。

参考文献

- [1] VEPAKOMMA P, GUPTA O, SWEDISH T, Split learning for health: distributed deep learning without sharing raw patient data. arXiv preprint arXiv:1812.00564, 2018.
- [2] POIROT M G, VEPAKOMMA P, CHANG K, Split learning for collaborative deep learning in healthcare. arXiv preprint arXiv:1912.12115, 2019.
- [3] GAO Y R, KIM M, ABUADBBA S, End-to-end evaluation of federated learning and split learning for internet of things//Proceedings of the 2020 IEEE 39th International Symposium on Reliable Distributed Systems (SRDS). Piscataway, NJ, USA: IEEE, 2020: 185-194. DOI: 10.1109/SRDS51741.2020.00026.
- [4] AYAD A, RENNER M, SCHMEINK A. Improving the communication and computation efficiency of split learning for IoT applications//Proceedings of the 2021 IEEE Global Communications Conference (GLOBECOM). Piscataway, NJ, USA: IEEE, 2021: 1-6. DOI: 10.1109/GLOBECOM46510.2021.9685493.
- [5] LIN Z, QU G, CHEN X, Split learning in 6G edge networks. arXiv preprint arXiv:2401.07450, 2024.
- [6] SINGH A, VEPAKOMMA P G, GUPTA O, Detailed comparison of communication efficiency of split learning and federated learning. arXiv preprint arXiv:1909.09145, 2019.
- [7] HU Z, ZHOU T, WU B, A review and experimental evaluation on split learning. Future Internet, 2025, 17(2): 87. DOI: 10.3390/fi17020087.
- [8] KIM J, SHIN S, YU Y, Multiple classification with split learning//Proceedings of the 9th International Conference on Smart Media and Applications (SMA 2020). New York, NY, USA: ACM, 2021: 49-52. DOI: 10.1145/3426020.3426131.
- [9] WU W, LI M, QU K, Split learning over wireless networks: parallel design and resource management. arXiv preprint arXiv:2305.18742, 2023.
- [10] SAMIKWA E, DI MAIO A, BRAUN T. Ares: adaptive resource-aware split learning for internet of things. Computer Networks, 2022, 218: 109380. DOI: 10.1016/j.comnet.2022.109380.
- [11] JEON J, KIM J. Privacy-sensitive parallel split learning//Proceedings of the 2020 International Conference on Information Networking (ICOIN). Piscataway, NJ, USA: IEEE, 2020: 12-14. DOI: 10.1109/ICOIN48656.2020.9016499.
- [12] PHAM N D, PHAN T K, ABUADBBA A, Split learning without local weight sharing to enhance client-side data privacy. arXiv preprint arXiv:2404.05190, 2024.
- [13] THAPA C, MAHAWAGA ARACHCHIGE P C, CAMTEPE S, SplitFed: when federated learning meets split learning//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 36: 8. 2022:

- 8485-8493. DOI: 10.1609/aaai.v36i8.20825.
- [14] SHEN J, CHENG N, WANG X, RingSFL: an adaptive split federated learning towards taming client heterogeneity. *IEEE Transactions on Mobile Computing*, 2024, 23(5): 5462-5477. DOI: 10.1109/TMC.2023.3309633.
- [15] PASQUINI D, ATENIESE G, BERNASCHI M. Unleashing the tiger: inference attacks on split learning//*Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security*. New York, NY, USA: ACM, 2021: 2113-2129. DOI: 10.1145/3460120.3484557.
- [16] 刘雅欣, 王鹃, 杨梦达, 拆分学习系统的隐私攻击和防御技术综述. *计算机研究与发展*, 2026, 63(3): 710-734. DOI: 10.7544/issn1000-1239.202440703.
- [17] XU X, YANG M, YI W, A stealthy wrongdoer: feature-oriented reconstruction attack against split learning. *arXiv preprint arXiv:2401.16781*, 2024.
- [18] ERDOGAN E, KUPCU A, CICEK A E. UnSplit: data-oblivious model inversion, model stealing, and label inference attacks against split learning//*Proceedings of the 21st Workshop on Privacy in the Electronic Society*. ACM, 2022: 115-130. DOI: 10.1145/3559613.3563201.
- [19] LIU J LYU X. Distance-based online label inference attacks against split learning//*ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing*. IEEE, 2023: 1-5. DOI: 10.1109/ICASSP49357.2023.10096955.
- [20] LIU J LYU X. Clustering label inference attack against practical split learning. *arXiv preprint arXiv:2211.13501*, 2022.
- [21] KARIYAPPA S QURESHI M K. ExPLoIt: extracting private labels in split learning//*Proceedings of the 2022 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW)*. IEEE, 2022: 360-365. DOI: 10.1109/EuroSPW55150.2022.00044.
- [22] KARIYAPPA S QURESHI M K. Gradient inversion attack: leaking private labels in two-party split learning//*Proceedings of the 2021 IEEE Conference on Communications and Network Security (CNS)*. IEEE, 2021: 1-2. DOI: 10.1109/CNS52011.2021.9705035.
- [23] LI O, SUN J, YANG X, Label leakage and protection in two-party split learning. *arXiv preprint arXiv:2202.12437*, 2022.
- [24] YU F, ZENG B, ZHAO K, Chronic poisoning: backdoor attack against split learning//*Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 15*. 2024: 16474-16482. DOI: 10.1609/aaai.v38i15.29585.
- [25] TAJALLI B, ERSOY O, PICEK S. On feasibility of server-side backdoor attacks on split learning. *arXiv preprint arXiv:2311.09995*, 2023.
- [26] RIEGER P, PEGORARO A, KUMARI K, SafeSplit: a novel defense against client-side backdoor attacks in split learning//*Proceedings of the Network and Distributed System Security Symposium*

- (NDSS). Internet Society, 2025. DOI: 10.14722/ndss.2025.241698.
- [27] GUPTA O RASKAR R. Distributed learning of deep neural network over multiple agents. *Journal of Network and Computer Applications*, 2018, 116: 1-8. DOI: 10.1016/j.jnca.2018.05.003.
- [28] ABEDI A KHAN S S. FedSL: federated split learning on distributed sequential data in recurrent neural networks. *Multimedia Tools and Applications*, 2023, 82(26): 40439-40459. DOI: 10.1007/s11042-023-15184-5.
- [29] TRAN N P, DAO N N, NGUYEN T V, Privacy-preserving learning models for communication: a tutorial on advanced split learning//*Proceedings of the 2022 13th International Conference on Information and Communication Technology Convergence (ICTC)*. Piscataway, NJ, USA: IEEE, 2022: 706-711. DOI: 10.1109/ICTC55196.2022.9952628.
- [30] QIU X, LEONTIADIS I, MELIS L, EXACT: extensive attack for split learning. *arXiv preprint arXiv:2304.14811*, 2023.
- [31] XIE S, YANG X, YAO Y, Label inference attack against split learning under regression setting. *arXiv preprint arXiv:2310.02451*, 2023.
- [32] ERDOĞAN E, KÜPÇÜ A, ÇİÇEK A E. SplitGuard: detecting and mitigating training-hijacking attacks in split learning//*Proceedings of the 21st Workshop on Privacy in the Electronic Society (WPES '22)*. New York, NY, USA: ACM, 2022: 135-147. DOI: 10.1145/3559613.3563198.
- [33] GAO X ZHANG L. PCAT: functionality and data stealing from split learning by pseudo-client attack //*Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security*. ACM, 2022: 1163-1177. DOI: 10.1145/3548606.3560662.
- [34] GAWRON G STUBBINGS P. Feature space hijacking attacks against differentially private split learning. *arXiv preprint arXiv:2206.05944*, 2022.
- [35] LECUN Y, BOTTOU L, BENGIO Y, Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324. DOI: 10.1109/5.726791.
- [36] HE K, ZHANG X, REN S, Deep residual learning for image recognition//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Piscataway, NJ, USA: IEEE, 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [37] KIPF T N WELLING M. Semi-supervised classification with graph convolutional networks//*Proceedings of the International Conference on Learning Representations (ICLR)*. OpenReview, 2017.
- [38] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, Graph attention networks//*Proceedings of the International Conference on Learning Representations (ICLR)*. OpenReview, 2018.
- [39] HAN S, POOL J, TRAN J, Learning both weights and connections for efficient neural networks//*Advances in Neural Information Processing Systems (NeurIPS)*: vol. 28. Curran Associates, Inc.,

- 2015: 1135-1143.
- [40] CHENG H, ZHANG M, SHI J Q. A survey on deep neural network pruning: taxonomy, comparison, analysis, and recommendations. arXiv preprint arXiv:2308.06767, 2023.
 - [41] KIRKPATRICK J, PASCANU R, KUMARAN D, Overcoming catastrophic forgetting in neural networks. Proceedings of the National Academy of Sciences (PNAS), 2017, 114(13): 3521-3526. DOI: 10.1073/pnas.1611835114.
 - [42] THEIS L, KORSHUNOVA I, TEJANI A, Faster gaze prediction with dense networks and fisher pruning//Proceedings of the International Conference on Artificial Neural Networks (ICANN). Berlin, Germany: Springer, 2018: 471-481. DOI: 10.1007/978-3-030-01418-6_46.
 - [43] MOLCHANOV P, TYREE S, KARRAS T, Pruning convolutional neural networks for resource efficient inference//Proceedings of the International Conference on Learning Representations (ICLR). OpenReview, 2017.
 - [44] MOLCHANOV P, MALLYA A, TYREE S, Importance estimation for neural network pruning//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway, NJ, USA: IEEE, 2019: 11264-11272. DOI: 10.1109/CVPR.2019.01152.
 - [45] DOU Z, CUI D, WANG W, SecureSplit: mitigating backdoor attacks in split learning//Proceedings of the ACM Web Conference 2026 (WWW '26). New York, NY, USA: ACM, 2026: 3021-3032. DOI: 10.1145/3774904.3792484.
 - [46] BAI Y, CHEN Y, ZHANG H, VILLAIN: backdoor attacks against vertical split learning//Proceedings of the 32nd USENIX Security Symposium (USENIX Security 23). USENIX Association, 2023: 2743-2760.
 - [47] AICH A. Elastic weight consolidation (EWC): nuts and bolts. arXiv preprint arXiv:2105.04093, 2021.
 - [48] MADAAN H, GAWALI M, KULKARNI V, Vulnerability Due to Training Order in Split Learning //Proceedings of the International Conference on ICT Systems and Sustainability (ICT4SD). Singapore: Springer, 2022: 103-112. DOI: 10.1007/978-981-16-5987-4_11.
 - [49] ZHANG C, ZHOU B, HE Z, OBLIVION: poisoning federated learning by inducing catastrophic forgetting//Proceedings of the IEEE Conference on Computer Communications (INFOCOM). Piscataway, NJ, USA: IEEE, 2023: 1-10. DOI: 10.1109/INFOCOM53939.2023.10228981.
 - [50] HE Y, ZHANG X, SUN J. Channel pruning for accelerating very deep neural networks//Proceedings of the IEEE International Conference on Computer Vision (ICCV). Piscataway, NJ, USA: IEEE, 2017: 1389-1397. DOI: 10.1109/ICCV.2017.155.
 - [51] LUO J H, WU J, LIN W. ThiNet: a filter level pruning method for deep neural network compression //Proceedings of the IEEE International Conference on Computer Vision (ICCV). Piscataway, NJ,

- USA: IEEE, 2017: 5058-5066. DOI: 10.1109/ICCV.2017.541.
- [52] LEE N, AJANTHAN T, TORR P H S. SNIP: single-shot network pruning based on connection sensitivity//Proceedings of the International Conference on Learning Representations (ICLR). Open-Review, 2019.
- [53] TANAKA H, KUNIN D, YAMINS D L K, Pruning neural networks without any data by iteratively conserving synaptic flow//Proceedings of the Advances in Neural Information Processing Systems (NeurIPS): vol. 33. Curran Associates, Inc., 2020: 6377-6389.
- [54] WANG C, ZHANG G, GROSSE R. Picking winning tickets before training by preserving gradient flow//Proceedings of the International Conference on Learning Representations (ICLR). OpenReview, 2020.
- [55] HASSIBI B STORK D G. Second order derivatives for network pruning: optimal brain surgeon//Proceedings of the Advances in Neural Information Processing Systems (NeurIPS): vol. 5. Morgan-Kaufmann, 1993: 164-171.
- [56] SHEJWALKAR V HOUMANSADR A. Manipulating the Byzantine: optimizing model poisoning attacks and defenses for federated learning//Proceedings of the Network and Distributed System Security Symposium (NDSS). Internet Society, 2021. DOI: 10.14722/ndss.2021.24498.
- [57] KIRKPATRICK S, GELATT C D, VECCHI M P. Optimization by simulated annealing. Science, 1983, 220(4598): 671-680. DOI: 10.1126/science.220.4598.671.
- [58] DEKKERS A AARTS E H L Global optimization and simulated annealing. Memorandum COSOR 88-21. 1988.
- [59] BERTSIMAS D NOHADANI O. Robust optimization with simulated annealing. Journal of Global Optimization, 2010, 48(2): 323-334. DOI: 10.1007/s10898-009-9496-x.
- [60] ROUSSEEUW P J CROUX C. Alternatives to the median absolute deviation. Journal of the American Statistical Association, 1993, 88(424): 1273-1283. DOI: 10.1080/01621459.1993.10476408.
- [61] JIANG Y, SHEN J, LIU Z, Towards efficient and certified recovery from poisoning attacks in federated learning. arXiv preprint arXiv:2401.08216, 2024.
- [62] ARACHCHIGE C N P G PRENDERGAST L A. Confidence intervals for median absolute deviations. Communications in Statistics - Simulation and Computation, 2026, 55(1): 13-22. DOI: 10.1080/03610918.2024.2376198.
- [63] DENG L. The MNIST database of handwritten digit images for machine learning research. IEEE Signal Processing Magazine, 2012, 29(6): 141-142. DOI: 10.1109/MSP.2012.2211477.
- [64] XIAO H, RASUL K, VOLLGRAF R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms. arXiv preprint arXiv:1708.07747, 2017.
- [65] NETZER Y, WANG T, COATES A, Reading digits in natural images with unsupervised feature

- learning//Proceedings of the NIPS Workshop on Deep Learning and Unsupervised Feature Learning. 2011.
- [66] KRIZHEVSKY A Learning multiple layers of features from tiny images. Tech. rep. TR-2009. 2009.
- [67] MCCALLUM A K, NIGAM K, RENNIE J, Automating the construction of internet portals with machine learning. *Information Retrieval*, 2000, 3(2): 127-163. DOI: 10.1023/A:1009953814988.
- [68] SEN P, NAMATA G, BILGIC M, Collective classification in network data. *AI Magazine*, 2008, 29(3): 93-106. DOI: 10.1609/aimag.v29i3.2157.
- [69] MA Z, HUANG X, LIU Z, FedGhost: Data-Free Model Poisoning Enhancement in Federated Learning. *IEEE Transactions on Information Forensics and Security*, 2025, 20: 2631-2645. DOI: 10.1109/TIFS.2025.3539087.
- [70] XIE Y, ..., Model Poisoning Attacks to Federated Learning via Multi-Round Consistency// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2025.
- [71] YANG L, MIAO Y, LIU Z, Enhanced Model Poisoning Attack and Multi-Strategy Defense in Federated Learning. *IEEE Transactions on Information Forensics and Security*, 2025, 20: 3877-3892. DOI: 10.1109/TIFS.2025.3555193.
- [72] 郭晶晶, 刘玖樽, 马勇, 基于模型水印的联邦学习后门攻击防御方法. *计算机学报*, 2024, 47(3): 613-631.
- [73] 王波, 代晓蕊, 王伟. 面向联邦学习的对抗样本投毒攻击. *中国科学: 信息科学*, 2023, 53(3): 470-484.

致 谢

岁月流转，三载读研生涯行将落幕。本论文之成，既为学业小结，更赖师长引路、同窗相助、家人相伴，谨致谢忱。

首谢吾师肖阳副教授。自选题立意、研思路径至撰文修改，先生皆悉心点拨、谆谆启导。从方向定夺、难点攻坚到实验与文稿打磨，先生严谨治学、笃实求真之风，于学问立身皆令我受益良多，没齿难忘。

次谢实验室诸位师长与同门学友。学术研讨、实验调试、文稿修订之际，多承高见，使研究日臻完善。实验室良序笃学、互助共进之风，为论文完成提供莫大助力。

复谢学院与母校，以优渥之科研环境、丰赡之文献馆藏、完备之实验设备及各类学术交流，为治学研究筑牢根基。

尤谢家人。多年来始终倾力支持、温言勉励，于困顿压力之时包容相伴，使我能潜心向学。若无身后之托，难有今日之进益。

谨以此文，敬谢所有关怀、扶持与助我之人。来日定持严谨求实之心，笃行不怠，以报母校培育、社会期许。

惟愿南校区夏日，恒常明媚。

作者：吕硕

2026.4.8

作者简介

1. 基本情况

吕硕，男，内蒙古巴彦淖尔人，1999 年 9 月出生于河北定州，西安电子科技大学网络与信息安全学院网络空间安全专业 2023 级硕士研究生。

2. 教育背景

2019.09~2023.06 西安电子科技大学，本科，专业：信息安全
2023.09~ 西安电子科技大学，硕士研究生，专业：网络空间安全

3. 攻读硕士学位期间的研究成果

3.1 学术论文

[1] 学生二作. Defed: An Edge Feature Enhanced Image Denoised Networks Against Adversarial Attacks for Secure Internet-of-Things,
期刊: IEEE Internet of Things Journal, 发表日期: 2023.4.15

3.2 申请（授权）专利

[1] 第一学生发明人. 一种基于参数扰动的拆分学习模型测试方法及装置, 申请专利号: 202410952291.8, 申请日期: 2024 年 07 月 16 日
[2] 第二学生发明人. 一种面向图对抗攻击的防御模型及其构建方法, 专利号: ZL 2023 1 0468686.6, 申请日期: 2023 年 04 月 27 日
授权公告号: CN116502087B, 授权公告日: 2025 年 06 月 27 日
[3] 第二学生发明人. 基于群智背景下的少样本时空序列数据处理方法及数据预测方法, 申请号: 2024104233432, 申请日: 2024 年 04 月 09 日

3.3 奖学金

[1] 学业特等奖学金, 2023
[2] 学业三等奖学金, 2024
[3] 学业二等奖学金, 2025

